



HSBA

Wirtschaftsstatistik

Sommersemester 2026
Prof. Dr. Sönke Hartmann

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 1

Überblick

1. Einleitung
2. Deskriptive Statistik
3. Korrelation und Regression
4. Wahrscheinlichkeiten
5. Diskrete Wahrscheinlichkeitsverteilungen
6. Stetige Wahrscheinlichkeitsverteilungen
7. Konfidenzintervalle und Stichprobengrößen
8. Hypothesentests

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 2

Literatur

Englisch:

- › A. G. Bluman: Elementary Statistics – A brief version. McGrawHill.
- › **B. L. Bowerman, R. T. O'Connell: Business Statistics in Practice. McGraw-Hill.**
(Empfohlenes Buch mit vielen Beispielen und Übungsaufgaben)
- › D. Rumsey: Statistics for Dummies. Wiley and Sons.
- › N. Sharpe, R. D. De Veaux, P. Velleman: Business Statistics. Pearson.

Deutsch:

- › L. Fahrmeir, C. Heumann, R. Künstler, I. Pigeot, G. Tutz: Statistik: Der Weg zur Datenanalyse. Springer.
- › R. Schlittgen: Einführung in die Statistik. Oldenbourg.
- › T. Schuster, A. Liesen: Statistik für Wirtschaftswissenschaftler: Ein Lehr- und Übungsbuch für das Bachelor-Studium. Springer.

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 3

Allgemeine Anmerkungen

Klausur:

- › 90 Minuten, 6 Credits
- › Tabellen und Formeln aus dem Zusatzmaterial werden verteilt
- › Es sind nur nichtprogrammierbare Taschenrechner ohne CAS zugelassen
- › Auch Ansatz, Rechenweg und Notation sind Gegenstand der Bewertung
- › Alle Kapitel sind klausurrelevant, es wird nichts ausgeschlossen

Rundungsregel:

- › Üblicherweise reicht es, auf zwei Stellen nach dem Komma zu runden
- › Bei Wahrscheinlichkeiten sind (mindestens) vier Stellen nach dem Komma anzugeben

Sonstiges:

- › Aus Gründen der Kompatibilität mit der englischen Variante des Skripts werden auch in diesem Skript die Symbole der englischen Variante verwendet
- › Teile dieser Vorlesung sind Grundlage für weitere Vorlesungen (z.B. für Principles of Finance und Quantitative Methoden)

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 4

Kapitel 1

Einleitung

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 5

Statistik: Einige Praxisanwendungen

Marketing: Wie lässt sich ermitteln, ob ein neues Design eines Werbebanners wirklich mehr Klicks generiert als das alte Design?

Logistik: Wie groß sollte der Lagerbestand eines Produkts sein, damit die Nachfrage der nächsten Woche mit einer bestimmten Wahrscheinlichkeit gedeckt ist?

Meinungsforschung: Wie zuverlässig ist eine Umfrage mit 1.000 Befragten, wenn man das Wahlverhalten der Bevölkerung prognostizieren möchte?

Revenue Management: Wie stark sollte eine Fluggesellschaft überbuchen, wenn bekannt ist, dass typischerweise nicht alle Passagiere erscheinen?

Health Care: Wie lässt sich herausfinden, ob ein neu entwickeltes Medikament tatsächlich besser wirkt als ein altes?

Glücksspiel: Welcher Anteil des Geldes, das in einen bestimmten Spielautomaten gesteckt wird, wird in Form von Gewinnen an die Spieler ausgezahlt?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 6

Einige Begriffe

Beschreibende (deskriptive) Statistik: Aufbereitung und Zusammenfassung von Daten

Schließende (induktive) Statistik: Rückschlüsse von einer Stichprobe auf die Grundgesamtheit, Prognosen, Analyse des Zusammenhangs zwischen Variablen

Grundgesamtheit: Die Menge aller Objekte, die uns interessiert

Stichprobe: Eine Menge von Objekten aus einer Grundgesamtheit. Wenn Daten der Grundgesamtheit nicht verfügbar sind und die Grundgesamtheit groß ist, wird i.d.R. eine Stichprobe genommen (meist zufällig)

Primärdaten: Daten, die speziell für eine bestimmte Fragestellung neu erhoben werden, z. B. durch Umfragen

Sekundärdaten: Bereits vorhandene Daten, die für eine Analyse wiederverwendet werden, z.B. vorhandene Bestelldaten in einem Online-Shop

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 7

Variablen

Variable: Eine Eigenschaft, die verschiedene Werte annehmen kann

Zufallsvariable: Eine Variable, deren Werte zufällig bestimmt sind

Qualitative Variable: Werte sind Kategorien, Beschreibungen etc.
Beispiele: Nationalität, Marke

Quantitative Variable: Numerische Werte
Beispiele: Alter, Einkommen

Diskrete Variable: Werte sind ganzzahlig (z.B. Anzahlen).
Beispiele: Anzahl Bestellungen, Anzahl Passagiere

Stetige Variable: Eine Variable, die zwischen zwei möglichen Werten immer noch weitere mögliche Werte hat ("Kommazahlen", z.B. Messungen)
Beispiele: Größe, Temperatur

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 8

Statistische Studien

Auf **Beobachtungen** basierende Studien

- › Es wird beobachtet, was passiert (oder passiert ist)
- › Dann werden aus den Beobachtungen Schlüsse gezogen

Beispiel: Medizinische Studie

- › Jeder teilnehmende Patient erhält ein bestimmtes Medikament
- › Zwei Tage später wird gezählt, wie vielen Patienten es besser geht

Auf **Experimenten** basierende Studien

- › Eine Variable wird gezielt manipuliert
- › Dann wird der Einfluss der Manipulation auf andere Variable untersucht

Beispiel: Medizinische Studie

- › Die teilnehmenden Patienten werden zufällig in zwei Gruppen aufgeteilt
- › Eine Gruppe erhält ein Medikament, die andere ein Placebo
- › Es wird in jeder Gruppe gezählt, wie vielen Patienten es besser geht

Experimentelle Studien können helfen, Ursache und Wirkung zu analysieren

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 9

Kapitel 2

Deskriptive Statistik

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 10

Deskriptive Statistik

In der Praxis sind zunächst meist **Rohdaten** vorhanden, die aufbereitet werden

Rohdaten können aus einer Grundgesamtheit stammen

- Beispiel: Alter und Gehalt aller Angestellten eines Unternehmens

Rohdaten können auch aus einer Stichprobe stammen

- Beispiel: Alter und Gehalt von iPhone-Nutzern, die an einer Befragung teilgenommen haben

In der deskriptiven Statistik werden die Daten aufbereitet:

- **Aggregation** der Daten (z.B. Häufigkeitsverteilungen)
- **Diagramme** zur Illustration der Daten (z.B. Balkendiagramme)
- **Kennzahlen** (z.B. Durchschnitt)

Das Ziel ist, die Daten so auf wichtige Größen zu reduzieren, dass die relevanten Eigenschaften des Datensatzes klar herausgestellt werden

Kapitel 2

Deskriptive Statistik

1 Kennzahlen für die zentrale Tendenz

2 Kennzahlen für die Streuung

3 Kennzahlen für die Position

Zentrale Tendenz: Mittelwert

Der **Mittelwert** (Durchschnitt) ist die Summe aller Werte geteilt durch die Anzahl der Werte

Die Notation unterscheidet sich für Grundgesamtheit und Stichprobe
(die Berechnung ist aber dieselbe):

- Der Mittelwert der Werte $X_1, X_2, \dots, X_N$ einer Grundgesamtheit ist $\mu = \frac{1}{N} \sum_{i=1}^N X_i$
- Der Mittelwert der Werte $X_1, X_2, \dots, X_n$ einer Stichprobe ist $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

Beispiel:

- In einer Marktforschungsstudie wurden die 8 Personen einer Stichprobe gebeten, eine neues Produkt auf einer Skala von 1 (schlecht) bis 9 (sehr gut) zu bewerten
- Die Ratings waren 2, 8, 6, 5, 3, 7, 9, 7
- Das Durchschnittsrating ist $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{8} (2 + 8 + 6 + 5 + 3 + 7 + 9 + 7) = 5,875$

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 13

Zentrale Tendenz: Mittelwert

Bei **Häufigkeitsverteilungen** gibt es k unterschiedliche Werte, f_i ist die Häufigkeit von Wert X_i

Die Stichprobengröße entspricht der Summe der Häufigkeiten, also $n = \sum_{i=1}^k f_i$

Der Mittelwert einer Stichprobe wird berechnet mit

$$\bar{X} = \frac{1}{n} \sum_{i=1}^k f_i \cdot X_i$$

Beispiel: Sternbewertungen eines Produkts in einem Online-Shop

Durchschnittliche Bewertung:

$$\bar{X} = \frac{1}{80} (23 \cdot 5 + 37 \cdot 4 + \dots) = 3,86 \text{ Sterne}$$

Sterne X_i	Häufigkeit f_i
5	23
4	37
3	12
2	2
1	6

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 14

Zentrale Tendenz: Median & Modus

Der **Median** M_d ist der Mittelpunkt eines Datensatzes, d.h. die eine Hälfte der Werte ist kleiner als der Median, die andere Hälfte ist größer

Zunächst werden die Daten sortiert. Dann ist der Median...

- der mittlere Wert, wenn die Anzahl der Werte ungerade ist
- der Mittelwert der beiden mittleren Werte, wenn die Anzahl der Werte gerade ist

Beispiel mit 8 Werten:

2 3 5 6 7 7 8 9

$$\text{Median: } M_d = \frac{6+7}{2} = 6.5$$

Beispiel mit 9 Werten:

2 3 4 5 6 7 7 8 9


$$\text{Median: } M_d = 6$$

Der **Modus** (oder **Modalwert**) M_o ist der Wert, der im Datensatz am häufigsten vorkommt

Anders als Mittelwert und Median eignet sich der Modus auch zur Auswertung qualitativer Daten

Kennzahlen für die Zentrale Tendenz

Beispiel: Alter aller HSBA-Studierenden (Bachelor und Master, echte Daten)



Rechtsschiefe Verteilung: Modus < Median < Mittelwert

Linksschiefe Verteilung: Mittelwert < Median < Modus

Der Median ist weniger anfällig für extreme Werte als der Mittelwert

Kapitel 2

Deskriptive Statistik

- 1 Kennzahlen für die zentrale Tendenz
- 2 Kennzahlen für die Streuung**
- 3 Kennzahlen für die Position

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 17

Streuung: Spannweite

Letzter Abschnitt: **Zentrale Tendenz** → Wie lässt sich die Mitte des Datensatzes beschreiben?

Dieser Abschnitt: **Streuung** → Wie unterschiedlich sind die Werte des Datensatzes?

Beispiel: Bei zwei Smartphones A und B wurde untersucht, wie viele Stunden der Akku bei normaler Nutzung hält. Jedes Smartphone wurde 5 mal aufgeladen. Ergebnisse:

A	15,5	15,2	15,9	16,2	15,7
B	15,1	18,0	16,6	15,7	13,1

Welches Smartphone würden Sie kaufen? Weshalb?

Die **Spannweite** ist die Differenz aus größtem und kleinstem Wert des Datensatzes

- ▶ Akku-Beispiel, Marke A: Spannweite = 1, Marke B: Spannweite = 4,9
- ▶ Was ist der Nachteil der Spannweite, wenn man sie als Kennzahl nutzt?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 18

Streuung: Varianz

Die **Varianz** ist die durchschnittliche quadrierte Abweichung der einzelnen Werte vom Mittelwert

Symbol und Berechnung unterscheiden sich für Grundgesamtheit und Stichprobe:

- ▶ Für die Grundgesamtheit berechnet man $\sigma^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2$
- ▶ Für eine Stichprobe berechnet man $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

Akku-Beispiel:

- ▶ Smartphone A: $\bar{X}_A = 15,7$ $s_A^2 = \frac{1}{5-1} ((15,5 - 15,7)^2 + (15,2 - 15,7)^2 + \dots) = 0,145$
- ▶ Smartphone B: $\bar{X}_B = 15,7$ $s_B^2 = 3,305$

Nachteil der Varianz: Durch das Quadrieren ist das Ergebnis nicht unbedingt intuitiv

Streuung: Standardabweichung

Die **Standardabweichung** ist die Wurzel der Varianz

- ▶ Grundgesamtheit: $\sigma = \sqrt{\sigma^2}$
- ▶ Stichprobe: $s = \sqrt{s^2}$

Eigenschaften der Standardabweichung:

- ▶ Obwohl die Wurzel gezogen wird, gibt die Standardabweichung nicht genau die durchschnittliche Abweichung der Werte vom Mittelwert an
- ▶ Einige große Abweichungen vom Mittelwert können zu einer größeren Varianz / Standardabweichung führen als viele kleine
- ▶ Nur die Standardabweichung wird auf derselben Skala gemessen wie die Daten

Akku-Beispiel:

- ▶ Smartphone A: $s_A = \sqrt{0,145} = 0,381$
- ▶ Smartphone B: $s_B = \sqrt{3,305} = 1,818$

Streuung: Standardabweichung

Für **Häufigkeitsverteilungen**:

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^k f_i (X_i - \bar{X})^2}$$

k Werte, f_i = Häufigkeit

Beispiel: Sterne-Bewertungen in einem Online-Shop

$$\bar{X} = 3,86$$

$$s = \sqrt{\frac{1}{80-1} (23(5 - 3,86)^2 + \dots)} = 1,10$$

Sterne X_i	Häufigkeit f_i
5	23
4	37
3	12
2	2
1	6

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 21

Kapitel 2

Deskriptive Statistik

- 1 Kennzahlen für die zentrale Tendenz
- 2 Kennzahlen für die Streuung
- 3 Kennzahlen für die Position**

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 22

Perzentile

Perzentile geben die Position innerhalb eines Datensatzes an

Das p -te **Perzentil** ist ein Wert X , so dass...

- ▶ $p\%$ der Daten kleiner oder gleich X sind
- ▶ $100 - p\%$ der Daten größer oder gleich X sind

Beispiele (Quelle: bpb.de):

- ▶ 18% der deutschen Bevölkerung sind 19 Jahre alt oder jünger
- ▶ 75% der Erwachsenen in Deutschland haben ein Vermögen von bis zu 126.000 €

Ziel: Im folgenden ist ein Prozentwert p gegeben, wir wollen den zugehörigen Wert X bestimmen

Perzentile

p ist gegeben. Wir sortieren alle Werte aufsteigend und berechnen den Index $i = \frac{n \cdot p}{100}$

- ▶ Wenn i nicht ganzzahlig ist, dann ist das p -te Perzentil X gleich dem Wert an Position $\lceil i \rceil$, wobei $\lceil i \rceil$ die nächstgrößere ganze Zahl nach i ist
- ▶ Wenn i ganzzahlig ist, dann ist X der Mittelwert der Werte an den Positionen i und $i + 1$

$$X = \begin{cases} \frac{X_i + X_{i+1}}{2} & \text{wenn } i \text{ ganzzahlig ist} \\ X_{\lceil i \rceil} & \text{sonst} \end{cases}$$

Hinweis: Dies ist kein Standard – es gibt verschiedene Ansätze zur Berechnung

Beispiel: In einer Stichprobe der Käufer einer bestimmten Marke haben wir folgende Altersangaben (bereits sortiert): 19, 21, 24, 28, 28, 30, 34, 36, 39, 45 ($n = 10$)

- ▶ 30. Perzentil: $i = 3$ und damit $X = \frac{24+28}{2} = 26$
- ▶ 75. Perzentil: $i = 7,5$, also $\lceil i \rceil = 8$ und damit $X = 36$
- ▶ 25. Perzentil: ...?

Perzentile: Anwendung

Das European Credit Transfer and Accumulation System (ECTS) ergänzt die üblichen absoluten Noten um relative Noten, um zu beschreiben, wie die Leistungen von Studierenden in Relation zu den anderen Studierenden desselben Studiengangs sind:

- Note A: beste 10 %
- Note B: nächste 25 %
- Note C: nächste 30 %
- Note D: nächste 25 %
- Note E: nächste 10 %

Übung: In einer Klausur wurden die folgenden (absoluten) Noten erzielt:

2.7, 3.7, 1.0, 2.0, 1.3, 4.0, 3.3, 2.0, 1.7, 2.7, 3.0, 2.0, 3.7

Bitte bestimmen Sie, für welche Note man welche ECTS-Note erhält (1.0 ist die beste Note).

Quartile

Die drei **Quartile** Q_1 , Q_2 und Q_3 teilen die Werte eines Datensatzes in vier Gruppen auf:

- Das erste Quartil Q_1 ist das 25. Perzentil
- Das zweite Quartil Q_2 ist das 50. Perzentil
- Das dritte Quartil Q_3 ist das 75. Perzentil

Zusätzlich kann man die Extremwerte angeben ("five-number summary"):

- Minimum des Datensatzes
- Erstes Quartil Q_1
- Zweites Quartil Q_2
- Drittes Quartil Q_3
- Maximum des Datensatzes

Aus diesen fünf Werten kann man wesentliche Informationen ablesen:


- Die zentrale Tendenz
- Die Variation der Daten
- Die Spannweite des Datensatzes

Quartile & Boxplot

Ein **Boxplot** ist eine grafische Darstellung der "five-number summary"

Beispiel: In der schon betrachteten Stichprobe haben wir die folgenden Altersangaben (bereits sortiert): 19, 21, 24, 28, 28, 30, 34, 36, 39, 45.

Daraus ergeben sich die folgenden Werte:



Es gibt noch erweiterte Boxplot-Varianten (hier nicht betrachtet)


Wirtschaftsstatistik 2026 | © Sönke Hartmann | 27

Quartile & Boxplot: Anwendung

Das Jahreseinkommen (je nach Branche, Ausbildung, Berufserfahrung etc.) wird oft als Boxplot dargestellt

Beispiel: Jahreseinkommen (in 1000 €) von Absolventen in Wirtschaftswissenschaften in Abhängigkeit von der Berufserfahrung

Minimum und Maximum sind nicht angegeben (warum?)



Echte Daten, Quelle: www.personalmarkt.de

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 28

Identifikation von Ausreißern

Ausreißer (extrem große oder kleine Werte) treten in der Praxis nicht selten auf:

- Ein Wert wurde falsch gemessen oder eingetippt
- Ein Wert ist korrekt, tritt aber eigentlich nur sehr selten auf

Ausreißer können Kennzahlen wie Mittelwert und Standardabweichung verzerren

Wie können Ausreißer objektiv identifiziert werden?

Der **Interquartilsabstand** (interquartile range, IQR) ist definiert als $IQR = Q_3 - Q_1$ (Spannweite der mittleren 50% der Daten)

Verbreitete Kriterien zur Identifikation von Ausreißern:

- **(Milde) Ausreißer:**
Werte, die mehr als $1.5 \cdot IQR$ über Q_3 oder mehr als $1.5 \cdot IQR$ unter Q_1 liegen
- **Extreme Ausreißer:**
Werte, die mehr als $3 \cdot IQR$ über Q_3 oder mehr als $3 \cdot IQR$ unter Q_1 liegen

Übung: Gibt es Ausreißer im Beispiel mit den Altersangaben?

Kapitel 3

Korrelation und Regression

Kapitel 3

Korrelation und Regression

- 1 **Korrelationskoeffizient**
- 2 Aufbau von Regressionsmodellen
- 3 Güte von Regressionsmodellen


Wirtschaftsstatistik 2026 | © Sönke Hartmann | 31

Scatter Plots

Ziel: Wir möchten die Beziehung zwischen zwei Variablen X und Y beschreiben, basierend auf Beobachtungen der Form $(x_1, y_1), (x_2, y_2), \dots (x_n, y_n)$

Scatterplots können eine Beziehung zwischen X und Y visualisieren

Beispiel: Es gibt eine Beziehung zwischen der zurückgelegten Strecke und der Fahrzeit



Wirtschaftsstatistik 2026 | © Sönke Hartmann | 32

Kovarianz

Ziel: Wir möchten die Beziehung zwischen zwei Variablen in einer einzigen Kennzahl ausdrücken

Zunächst erweitern wir die Definition der Varianz auf zwei Variable

Die **Kovarianz** für eine Stichprobe ist definiert als

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})(y_i - \bar{Y})$$

Wenn ein Wert y_i über dem Mittelwert liegt, wann immer der zugehörige Wert x_i ebenfalls über dem Durchschnitt liegt (und analog y_i und x_i jeweils unter dem Durchschnitt), dann erhalten wir einen großen Wert für die Kovarianz

Nachteil der Kovarianz: Eine Interpretation kann schwierig sein, weil die Größe der Kovarianz von den verwendeten Einheiten der Daten abhängt

Korrelation

Wir normieren die Kovarianz und erhalten damit eine leichter zu interpretierende Größe:

Der **Korrelationskoeffizient** ist definiert als

$$r = \frac{\text{Cov}(X, Y)}{s_X s_Y} = \frac{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})(y_i - \bar{Y})}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2} \cdot \sqrt{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{Y})^2}} = \frac{\sum_{i=1}^n (x_i - \bar{X})(y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{X})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{Y})^2}}$$


s_X und s_Y sind die Standardabweichungen der beiden Variablen.

Eigenschaften des Korrelationskoeffizienten:


- ▶ Der Korrelationskoeffizient liegt zwischen -1 und 1 , also $r \in [-1, 1]$
- ▶ Er gibt Stärke und Richtung eines linearen Zusammenhangs an
- ▶ Wenn r dicht bei 1 liegt, gibt es einen starken positiven linearen Zusammenhang zwischen den beiden Variablen (d.h. wenn x steigt, steigt meist auch y)
- ▶ Für nichtlineare Zusammenhänge ist der Korrelationskoeffizient nicht gut geeignet

Korrelation: Beispiele


$r = 1$: perfekter positiver Zusammenhang




$r = -1$: perfekter negativer Zusammenhang



$r = 0,75$: positiver Zusammenhang



$r \approx 0$: kein Zusammenhang



Wirtschaftsstatistik 2026 | © Sönke Hartmann | 35

Korrelation vs. Kausalität

Wenn es eine starke Korrelation zwischen zwei Variablen gibt, ist noch nicht klar, **weshalb** es diesen Zusammenhang gibt. Es gibt drei mögliche Arten des Zusammenhangs:

Direkte **Ursache-Wirkung**-Beziehung: X beeinflusst Y (oder Y beeinflusst X)

Beispiel: Es gibt eine positive Korrelation zwischen Temperatur und Eis-Absatz – wenn es warm ist, wird mehr Eis gekauft

Die Beziehung zwischen X und Y wird von einer **dritten Variablen Z** verursacht

Beispiel: Eine Korrelation zwischen Orangen-Absatz und der Anzahl Personen mit Erkältung liegt an einer dritten Variable, die beide beeinflusst: die Jahreszeit

Es gibt eine Korrelation, aber die Beziehung zwischen X und Y ist rein **zufällig**

Beispiel: In verschiedenen Gegenden haben Forscher eine Korrelation zwischen Storch-Population und der Geburtenrate (bei Menschen) gefunden

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 36

Korrelation vs. Kausalität

Übung: Diskutieren Sie die folgenden Beispiele und geben Sie sinnvolle Erklärungen an!

- Es gibt eine Korrelation zwischen dem Eis-Absatz und der Anzahl ertrunkener Menschen
- Absatz eines Produkts und Anzahl Fernsehspots für dieses Produkt sind stark positiv korreliert
- Der Preis eines gebrauchten VW Golf und der km-Stand sind korreliert mit einem Korrelationskoeffizienten von $r = -0,41$ (Basis: Datensatz mit $n = 34$ Autos)
- Wenn man die Reihen im Seminarraum von vorn nach hinten durchnummeriert, ergibt sich vermutlich eine positive Korrelation zwischen Reihe während der Vorlesung und Klausurnote der Studierenden


Kapitel 3

Korrelation und Regression

- 1 Korrelationskoeffizient
- 2 Aufbau von Regressionsmodellen**
- 3 Güte von Regressionsmodellen


Korrelation vs. Regression

Korrelation misst, wie stark der Zusammenhang zwischen X und Y ist



Der Korrelationskoeffizient r zeigt, wie breit die Punktwolke der Beobachtungen ist


Regression beschreibt, wie der Zusammenhang zwischen X und Y aussieht



Die Regressionsgerade $\hat{y} = b_0 + b_1x$ zeigt die Steigung der Punktwolke

Lineare Regression

Beispiel: Das Management eines Fast Food-Restaurants hat für die letzten Wochen jeweils den Umsatz und die Anzahl Radiospots zusammengetragen:




Frage: Wie beeinflussen die Radiospots (unabhängige Variable x) den Umsatz (abhängige Variable y)? Und inwiefern wäre das relevant?

Lineare Regression

Annahme: Lineare Funktion $y = \beta_0 + \beta_1 x + \varepsilon$ (y = Umsatz, x = Anzahl Spots, ε = Fehler)

Wir kennen die "echten" Werte von β_0 und β_1 nicht, also schätzen wir $y = \beta_0 + \beta_1 x + \varepsilon$ durch $\hat{y} = b_0 + b_1 x$ anhand einer Stichprobe mit n Beobachtungen (x_i, y_i)

Grafisch bedeutet das, dass wir eine Gerade schätzen, die möglichst "dicht" an den Beobachtungen (also an der Realität) ist. Dafür gibt es aber viele Möglichkeiten:



Wirtschaftsstatistik 2026 | © Sönke Hartmann | 41

Lineare Regression

Bei nur zwei Beobachtungen könnte man b_0 und b_1 leicht berechnen, denn zwei Punkte definieren eine Gerade

Beispiel-Beobachtungen:


Umsatz (in 1000 €)	Radiospots
136	10
161	26

Wir können b_0 und b_1 aus dem folgenden linearen Gleichungssystem ermitteln:

$$b_0 + 10b_1 = 136$$

$$b_0 + 26b_1 = 161$$

Aber nur zwei Beobachtungen würden viel zu wenig Informationen aus der Realität enthalten




Wirtschaftsstatistik 2026 | © Sönke Hartmann | 42

Lineare Regression

Bei drei oder mehr Beobachtungen ist es i.d.R. unmöglich, eine Gerade zu finden, die durch alle Punkte geht

Beispiel-Beobachtungen:

Umsatz (in 1000 €)	Radiospots
140	20
136	10
161	26



Lineares Gleichungssystem:

$$b_0 + 20b_1 = 140$$

$$b_0 + 10b_1 = 136$$

$$b_0 + 26b_1 = 161$$


Mehr Gleichungen als Unbekannte, deshalb hat das Gleichungssystem meist keine Lösung. Wir benötigen eine Näherung!

Lineare Regression

Frage: Welche Gerade wäre eine "gute" Näherung?

Idee: Die Summe der quadrierten **Residuen** (= Differenz zwischen beobachteten Werten y_i und mit der Gerade geschätzten Werten $\hat{y}_i$) soll minimal sein

Also: Bestimme b_0 und b_1 so, dass $\sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (b_0 + b_1 x_i))^2$ minimal ist (mit welcher Methode?)



Lineare Regression

Wir erhalten $b_1 = \frac{\sum(x_i - \bar{X})(y_i - \bar{Y})}{\sum(x_i - \bar{X})^2} = \frac{Cov(X, Y)}{s_X^2}$ und $b_0 = \bar{Y} - b_1\bar{X}$

Wir können die Daten in Excel eingeben und das Regressions-Add-In anwenden:

Umsatz (in 1000 €)	Radiospots
140	20
136	10
94	5
190	22
161	26
112	12
143	16
151	7
103	6
181	34
176	18
128	4

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 45

Lineare Regression: Ergebnisse

AUSGABE: ZUSAMMENFASSUNG

Regressions-Statistik	
Multipler Korrelationskoeff.	0,762
Bestimmtheitsmaß	0,580
Adjust. Bestimmtheitsmaß	0,539
Standardfehler	20,862
Beobachtungen	12

ANOVA

	Freiheits- grade (df)	Quadrat- summen (SS)	Mittlere Quadrat- summe (MS)	Prüfgröße (F)	F krit
Regression	1	6022,509	6022,509	13,837	0,004
Residue	10	4352,407	435,241		
Gesamt	11	10374,917			

	Koeffizienten	Standard- fehler	t-Statistik	P-Wert	Untere 95%	Obere 95%
Schnittpunkt	105,463	11,732	8,989	0,000	79,322	131,604
Radiospots	2,497	0,671	3,720	0,004	1,001	3,993

Ergebnis: Die Regressionsfunktion ist $\hat{y} = b_0 + b_1x = 105,463 + 2,497x$

$\hat{y}$ ist der erwartete Umsatz bei x Radiospots

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 46

Lineare Regression: Ergebnisse

Korrelation vs. Regression:

- Korrelation: Wie stark ist der (lineare) Zusammenhang zwischen den Variablen?
- Regression: Wie lässt sich der Zusammenhang beschreiben?

Analyse: Die Regressionsfunktion $\hat{y} = b_0 + b_1x = 105,463 + 2,497x$ gibt an, wie der Umsatz von der Anzahl Radiospots abhängt:

- Jeder Radiospot erhöht den Umsatz um $2,497 \cdot 1000 \text{ €} \approx 2500 \text{ €}$
- Ohne Radiospots läge der Umsatz bei $105,463 \cdot 1000 \text{ €} \approx 105.500 \text{ €}$

Prognose: Wir können die Regression für Prognosen nutzen

- Interpolation: Bei 10 Spots wäre ein Umsatz von 130.432 € zu erwarten
- Extrapolation: Bei 50 Spots wäre ein Umsatz von 230.308 € zu erwarten

Wichtig: Wenn es keinen hinreichend starken linearen Zusammenhang gibt, sollten wir die Regression nicht anwenden oder gar Prognosen auf Basis der Regressionsergebnisse machen

Multiple Lineare Regression

Oft reicht eine unabhängige Variable nicht aus, um eine abhängige Variable zu erklären

Multiples Regressionsmodell: $\hat{y} = b_0 + b_1x_1 + b_2x_2 + \dots = b_0 + \sum_{j=1}^m b_jx_j$

Beispiel: Auch die Radiospots des Konkurrenten könnten einen Einfluss auf den Umsatz unseres Fast-Food-Restaurants haben

Beispiel-Ergebnis:

$$\hat{y} = 114.18 + 2.47 \cdot x_{\text{radio}} - 0.69 \cdot x_{\text{competitor}}$$

Wie kann dieses Ergebnis interpretiert werden?

Umsatz in 1000 €	Radiospots	Radiospots (Konkurrent)
140	20	18
136	10	0
94	5	24
190	22	0
161	26	18
112	12	12
143	16	12
151	7	18
103	6	0
181	34	18
176	18	0
128	4	24

Multiple Lineare Regression

Häufig sind in der Praxis Informationen, die als unabhängige Variable verwendet werden sollen, qualitativ und nicht quantitativ

In solchen Fällen werden sogenannte **Dummy-Variable** verwendet, die nur 0 oder 1 sein können

Beispiel: Das Fast-Food-Restaurant bietet in einigen Wochen Burger-Specials an

In einer Woche mit Burger-Special ist

$x_{special} = 1$, ansonsten $x_{special} = 0$

Beispielergebnis:

$$\hat{y} = 100,33 + 2,00x_{radio} + 0,01x_{competitor} + 30,01x_{special}$$

Umsatz in 1000 €	Radiospots	Radiospots (Konkurrent)	Special Burger 0=nein, 1=ja
140	20	18	0
136	10	0	1
94	5	24	0
190	22	0	1
161	26	18	0
112	12	12	0
143	16	12	0
151	7	18	1
103	6	0	0
181	34	18	1
176	18	0	1
128	4	24	0

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 49

Lineare Regression: Übungen

1. Welche weiteren unabhängigen Variablen könnten noch in das Modell des Fast-Food-Restaurants einbezogen werden?
2. Betrachten Sie noch einmal das Beispiel-Ergebnis von oben. Nehmen Sie an, der Koeffizient für die Radiospots des Konkurrenten wäre 1.24 (statt -0.69). Wie könnte ein solches Ergebnis interpretiert werden, wäre es plausibel?
3. Das Management eines anderen Fast-Food-Restaurants möchte ebenfalls den Einfluss der Radiospots auf den Umsatz mit Hilfe der Regression untersuchen. Die verfügbaren Daten sind in der Tabelle (rechts) gegeben. Diskutieren Sie die Situation!

Umsatz in 1000 €	Radiospots
140	22
136	22
94	22
190	22
161	22
112	22
143	22
151	22

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 50

Kapitel 3

Korrelation und Regression

- 1 Korrelationskoeffizient
- 2 Aufbau von Regressionsmodellen
- 3 Güte von Regressionsmodellen**



Wirtschaftsstatistik 2026 | © Sönke Hartmann | 51

Residuen

Es gibt nahezu immer Abweichungen zwischen den Beobachtungen und der Regressionslinie

Frage: Wie groß ist die Abweichung der beobachteten y -Werte von den geschätzten $\hat{y}$ -Werten auf der Regressionsgeraden?

Je kleiner die Abweichungen, desto besser die Güte des Modells (und möglicher Prognosen)



Wirtschaftsstatistik 2026 | © Sönke Hartmann | 52

Residuen

Ein **Residuum** ist die Differenz zwischen beobachtetem und geschätztem Wert: $e_i = y_i - \hat{y}_i$

Betrachten Sie das erste Fast-Food-Modell, in dem nur Radiospots vorkamen:

- Der beobachtete Umsatz der ersten Woche war $y_1 = 140$ (bei $x_1 = 20$ Radiospots)
- Die Schätzung für diese Woche ist $\hat{y}_1 = b_0 + b_1 x_1 = 105,463 + 2,497 \cdot 20 = 155,4$
- Das Residuum dieser Woche ist $e_1 = y_1 - \hat{y}_1 = 140 - 155,4 = -15,4$

Die Residuen lassen sich leicht in Excel berechnen (entweder mit eigenen Formeln oder automatisch von Excel)

Übung: Berechnen Sie die Residuen für die ersten beiden Wochen des letzten Fast-Food-Beispiels (das mit Radiospots, Konkurrent und Special)

Woche	Umsatz (in 1000 €)	Radiospots	Schätzung	Residuum
i	y_i	x_i	$\hat{y}_i$	e_i
1	140	20	155,4	-15,4
2	136	10	130,4	5,6
3	94	5	117,9	-23,9
4	190	22	160,4	29,6
5	161	26	170,4	-9,4
...	...	...	...	...



Bestimmtheitsmaß

Wenn wir Variable x nicht verwenden würden, könnten wir y nur durch $\bar{Y}$ schätzen

- Der Schätzfehler wäre dann $y_i - \bar{Y}$

Wenn wir Variable x verwenden, schätzen wir die y -Werte mit $\hat{y} = b_0 + b_1 x$

- Der Schätzfehler ist dann $y_i - \hat{y}_i$
- Bei der Berechnung der Regressionsgeraden werden die quadrierten Schätzfehler (also die Residuen) minimiert (s.o.)



Bestimmtheitsmaß

Das **Bestimmtheitsmaß** ist $R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{Y})^2}$

Das Bestimmtheitsmaß gibt an, welcher Anteil der quadrierten Abweichung der Beobachtungen vom Mittelwert von der Regressionsgerade erklärt wird

Es gilt immer $0 \leq R^2 \leq 1$. Je dichter R^2 an 1 ist, desto besser die Güte des Regressionsmodells (und möglicher Prognosen)

Man kann zeigen, dass R^2 das Quadrat des Korrelationskoeffizienten r ist

Restaurant-Beispiel

mit einer unabhängigen Variable:

Regressions-Statistik	
Multipler Korrelationskoeff.	0,7619
Bestimmtheitsmaß	0,5805
Adjust. Bestimmtheitsmaß	0,5385
Standardfehler	20,8624
Beobachtungen	12

mit drei unabhängigen Variablen:

Regressions-Statistik	
Multipler Korrelationskoeff.	0,9000
Bestimmtheitsmaß	0,8100
Adjust. Bestimmtheitsmaß	0,7388
Standardfehler	15,6959
Beobachtungen	12

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 55

Lineare Regression: Übung 1

Ein Online-Shop, der Spielzeug verkauft, hat eine Umfrage zur Messung der Kundenzufriedenheit durchgeführt. Eine Stichprobe der Kunden wurde gebeten, den Shop anhand der folgenden Kriterien zu bewerten:

- ▶ Variable 1: Rating der Produktauswahl
- ▶ Variable 2: Rating der Rückgabemöglichkeiten
- ▶ Variable 3: Rating der Lieferzeit

Die Teilnehmer wurden außerdem gebeten, ihre Gesamtzufriedenheit anzugeben

Alle Ratings wurden auf einer Skala von 0 (schlecht) bis 10 (sehr gut) angegeben

Das Management möchte nun analysieren, wie die drei Einzelkriterien die Gesamtzufriedenheit beeinflussen, also wie wichtig die drei Faktoren für die Gesamtzufriedenheit sind

Es wurde eine lineare Regression durchgeführt mit den drei Einzelkriterien als unabhängige und der Gesamtzufriedenheit als abhängige Variable

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 56

Lineare Regression: Übung 1

Ergebnisse aus Excel:

<i>Regressions-Statistik</i>		<i>Koeffizienten</i>	
Multipler Korrelationskoeffizient	0.8108	Schnittpunkt	-0.2465
Bestimmtheitsmaß	0.6573	Auswahl	0.2034
Adjustiertes Bestimmtheitsmaß	0.5931	Rückgabe	0.5510
Standardfehler	1.8798	Lieferzeit	0.3890
Beobachtungen	20		

Aufgaben:

- › Geben Sie die Regressionsfunktion an und interpretieren Sie die Koeffizienten.
- › Ein Kunde hat die Auswahl mit 5, die Rückgabe mit 3 und die Lieferzeit mit 9 bewertet, bei einer Gesamtzufriedenheit von 8. Bestimmen Sie das Residuum für diesen Kunden.
- › Diskutieren Sie das Bestimmtheitsmaß. Ist es gut? Weshalb?
- › Welcher drei Einzelfaktoren sollte verbessert werden? Warum?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 57

Lineare Regression: Übung 2

Durchführung einer Regressionsanalyse für Gebrauchtwagen, um...

- › den Einfluss der Fahrzeugeigenschaften auf den Preis zu sehen
- › ein Modell zu erhalten, das Prognosen für Gebrauchtwagenpreise auf Basis der Fahrzeugeigenschaften ermöglicht

Praxisbeispiel einer solchen Anwendung: Schwacke.de

Vorgehensweise:

- › Festlegung der relevanten Automarken und -typen
- › Festlegung der für den Preis vermutlich relevanten Fahrzeugeigenschaften
- › Sammeln von realen Daten (www.autoscout24.de...)
- › Anwendung der Regressionsanalyse, z.B. in Excel
- › Gründliche Diskussion der Ergebnisse: Interpretation und Plausibilität der Koeffizienten, Beurteilung von Residuen und Bestimmtheitsmaß
- › Diskussion möglicher Schwachpunkte des Modells

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 58

Lineare Regression: Übung 2

Daten: Preise gebrauchter Autos (hier: Beschränkung auf unfallfreie VW Golf). Echtdaten.

Preis (€)	km-Stand	PS	Alter	Farbe	Preis (€)	km-Stand	PS	Alter	Farbe
7490	61000	80	7	silber	18450	11879	110	2	silber
7990	36036	75	8	silber	18980	8287	102	1	silber
8250	40985	80	7	silber	18990	25500	122	3	schwarz
8900	6400	75	4	schwarz	19229	9500	105	2	silber
9950	49900	75	6	schwarz	19490	12934	122	3	schwarz
10950	19420	80	4	silber	19900	20964	160	3	schwarz
10975	48000	102	5	silber	19900	17000	105	1	silber
11790	47600	116	6	silber	21200	6000	105	1	schwarz
12990	49800	105	5	schwarz	22500	40000	300	6	silber
13490	43425	102	3	schwarz	22650	42500	140	2	schwarz
13800	26720	102	3	silber	23870	15126	160	1	silber
13900	7000	80	1	schwarz	23900	37300	230	4	schwarz
14975	24623	80	1	schwarz	23987	17512	200	4	schwarz
14995	4850	80	2	silber	25990	8105	140	1	schwarz
15900	8600	80	2	silber	28890	16466	211	2	schwarz
17400	48000	105	4	schwarz	29490	31500	170	2	schwarz
17829	26500	105	2	schwarz	44540	5000	271	1	schwarz

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 59

Lineare Regression: Übung 2

Ergebnisse aus Excel:

Regressions-Statistik		Koeffizienten	
Multipler Korrelationskoeffizient	0,9346	Schnittpunkt	12515,226
Bestimmtheitsmaß	0,8735	km-Stand	-0,016
Adjustiertes Bestimmtheitsmaß	0,8560	PS	95,207
Standardfehler	2866,1472	Alter	-1713,974
Beobachtungen	34	Farbe = silber	-1227,009

Diskussion:

- ▶ Geben Sie die Regressionsfunktion an und interpretieren Sie die Koeffizienten
- ▶ Was sollte ein schwarzer 5 Jahre alter Golf mit 100 PS und 45.000 km kosten?
- ▶ Bestimmen Sie das Residuum des ersten Autos des Datensatzes
- ▶ Interpretieren Sie das Bestimmtheitsmaß
- ▶ Ist lineare Regression ein geeigneter Ansatz zur Prognose von Gebrauchtwagenpreisen?
Was sind mögliche Nachteile?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 60

Kapitel 4

Wahrscheinlichkeiten

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 61

Kapitel 4

Wahrscheinlichkeiten

- 1 Grundlagen
- 2 Rechnen mit Wahrscheinlichkeiten
- 3 Kombinatorik und Wahrscheinlichkeiten

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 62

Wahrscheinlichkeiten: Grundlagen

Die **Wahrscheinlichkeit** ist die Chance, dass ein Ereignis eintritt

Wahrscheinlichkeiten werden oft bei Glücksspielen, Versicherungen, für Prognosen und für die Analyse von Ergebnissen aus Stichproben benötigt

Ein **Zufallsexperiment** ist ein Zufallsprozess, der zu wohldefinierten Ergebnissen führt, wobei vorher nicht bekannt ist, welches Ergebnis eintreten wird

Ein **Ergebnis** ist ein mögliches Resultat eines Zufallsexperiments

Ein **Ergebnisraum** ist die Menge aller möglichen Ergebnisse eines Zufallsexperiments

Beispiel:

- Würfeln ist ein Zufallsexperiment
- 1, 2, ... sind Ergebnisse
- $S = \{1, 2, 3, 4, 5, 6\}$ ist der Ergebnisraum

Wahrscheinlichkeiten: Grundlagen

Ein **Ereignis** ist eine Menge von Ergebnissen eines Zufallsexperiments

Die Wahrscheinlichkeit $P(E)$ eines Ereignisses E ist eine Zahl zwischen 0 und 1, d.h.
 $0 \leq P(E) \leq 1$

- Wenn ein Ereignis nicht auftreten kann, ist die Wahrscheinlichkeit 0: $P(E) = 0$
- Wenn ein Ereignis sicher auftreten wird, ist die Wahrscheinlichkeit 1: $P(E) = 1$

Die Summe der Wahrscheinlichkeiten aller Ergebnisse der Ergebnisraums ist 1

Beispiel: Würfeln

- Eine ungerade Zahl zu würfeln entspricht dem Ereignis $E = \{1, 3, 5\}$
- $P(\{1, 3, 5\}) = 0,5$
- $P(\{7\}) = 0$
- $P(S) = P(\{1, 2, 3, 4, 5, 6\}) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = 1$

Wahrscheinlichkeiten: Grundlagen

Die **theoretische Wahrscheinlichkeit** für ein Ereignis E ist die Summe der Wahrscheinlichkeiten der einzelnen Ergebnisse von E . Wenn alle Ergebnisse die gleiche Wahrscheinlichkeit haben, ergibt sich

$$P(E) = \frac{|E|}{|S|} = \frac{\text{Anzahl Ergebnisse in Ereignis } E}{\text{Gesamtzahl aller Ergebnisse im Ergebnisraum } S}$$

Beispiel: Die Wahrscheinlichkeit für "rot" beim Roulette ist $P(\text{rot}) = \frac{18}{37} = 0,4865$

Die **empirische Wahrscheinlichkeit** basiert auf Beobachtungen (Daten) aus der Vergangenheit:

$$P(E) = \frac{f}{n} = \frac{\text{Häufigkeit des Auftretens von Ereignis } E}{\text{Summe aller Häufigkeiten}}$$

Beispiel: Eine Fluggesellschaft hat 12.000 Tickets untersucht und festgestellt, dass der Flug in 934 Fällen nicht angetreten wurde, also $P(\text{Flug wird nicht angetreten}) = \frac{934}{12000} = 0,0778$

Wahrscheinlichkeiten: Grundlagen

Gesetz der großen Zahlen: Wenn ein Zufallsexperiment mehrfach, aber nicht sehr häufig wiederholt wird, stimmen die empirische und die theoretische Wahrscheinlichkeit meist nicht überein. Mit zunehmender Anzahl an Wiederholungen wird sich die empirische Wahrscheinlichkeit jedoch der theoretischen Wahrscheinlichkeit tendenziell annähern.

Beispiel: Wahrscheinlichkeit für Kopf beim Münzwurf

# Würfe	# Kopf	Empirische Wahrscheinlichkeit
10	7	0,700
100	58	0,580
1000	531	0,531

Wahrscheinlichkeiten: Grundlagen

Übung 1: Mit welcher Wahrscheinlichkeit erhält man vier Punkte, wenn man mit zwei Würfeln würfelt und die beiden Augenzahlen addiert?

Übung 2: Angenommen, Sie sind in einem Casino. Sie haben die letzten 12 Runden an einem Roulette-Tisch beobachtet und die Ergebnisse in Form von rot (R) und schwarz (S) notiert:

R – S – R – S – S – S – S – S – S – S – S – S

Worauf sollten Sie in der nächsten Runde setzen?

Kapitel 4

Wahrscheinlichkeiten

- 1 Grundlagen
- 2 Rechnen mit Wahrscheinlichkeiten**
- 3 Kombinatorik und Wahrscheinlichkeiten

Rechnen mit Wahrscheinlichkeiten

Das **Gegenereignis** eines Ereignisses E beinhaltet diejenigen Ergebnisse des Ergebnisraums S , die nicht in Ereignis E enthalten sind

Das Gegenereignis von Ereignis E wird geschrieben als $\bar{E}$. Es gilt also: $\bar{E} = S \setminus E$

Beispiel: Würfel, für $E = \{1, 3, 5\}$ ist $\bar{E} = \{2, 4, 6\}$

Für die zugehörigen Wahrscheinlichkeiten gilt:

$$P(E) + P(\bar{E}) = 1 \Rightarrow P(E) = 1 - P(\bar{E})$$

Anwendung: Manchmal ist es schwierig, $P(E)$ direkt zu berechnen. Evtl. kann es einfacher sein, zunächst $P(\bar{E})$ zu berechnen und mit dieser Formel $P(E)$ zu bestimmen.

Rechnen mit Wahrscheinlichkeiten

Zwei Ereignisse A und B **schließen sich gegenseitig aus**, wenn sie kein Ergebnis gemeinsam haben, also wenn $A \cap B = \emptyset$ ist.

Also: Zwei Ereignisse, die sich gegenseitig ausschließen, können nicht gleichzeitig auftreten.

Beispiel: Beim Roulette schließen sich die Ereignisse "gerade Zahl" und "ungerade Zahl" gegenseitig aus, die Ereignisse "gerade Zahl" und "rote Zahl" aber nicht.

Daraus ergeben sich die folgenden Rechenregeln für die Wahrscheinlichkeit, dass ein Ereignis A **oder** ein Ereignis B eintritt:

- ▶ Wenn A und B **sich gegenseitig ausschließen**:

$$P(A \text{ oder } B) = P(A) + P(B)$$

- ▶ Wenn A und B **sich nicht gegenseitig ausschließen**:

$$P(A \text{ oder } B) = P(A) + P(B) - P(A \text{ und } B)$$

Rechnen mit Wahrscheinlichkeiten

Nun werden **zwei Versuche** betrachtet. Einige Definitionen:

- ▶ Zwei Ereignisse A und B sind **unabhängig**, wenn das Eintreten von A die Wahrscheinlichkeit für das Eintreten von B nicht verändert
- ▶ Zwei Ereignisse A und B sind **abhängig**, wenn das Eintreten von A die Wahrscheinlichkeit für das Eintreten von B beeinflusst
- ▶ Wenn A und B abhängig sind, dann ist die **bedingte Wahrscheinlichkeit** $P(B|A)$ die Wahrscheinlichkeit, dass Ereignis B eintritt, wenn A eingetreten ist

Daraus ergeben sich die folgenden Rechenregeln für die Wahrscheinlichkeit, dass ein Ereignis A **und** ein Ereignis B eintreten:

- ▶ Wenn A und B **unabhängig** sind: $P(A \text{ und } B) = P(A) \cdot P(B)$
- ▶ Wenn A und B **abhängig** sind: $P(A \text{ und } B) = P(A) \cdot P(B|A)$

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 71

Rechnen mit Wahrscheinlichkeiten: Übungen

1. Mit welcher Wahrscheinlichkeit würfelt man mit einem Wurf...
 - ▶ ...eine gerade Zahl oder eine 3?
 - ▶ ...eine ungerade Zahl oder eine Zahl größer als 4?
2. In Deutschland haben 37% der Bevölkerung Blutgruppe A+. Mit welcher Wahrscheinlichkeit haben vier zufällig gewählte Deutsche die Blutgruppe A+?
3. Eine Münze wird viermal geworfen. Mit welcher Wahrscheinlichkeit tritt mindestens einmal Kopf auf?
4. Im folgenden wird ein Kartenspiel mit 52 Karten betrachtet.
 - ▶ Eine Karte wird gezogen und danach wieder zurück in den Stapel gelegt. Dann wird eine zweite Karte gezogen. Mit welcher Wahrscheinlichkeit zieht man erst einen König und dann eine Dame?
 - ▶ Wie ändert sich die Wahrscheinlichkeit, wenn man die erste Karte nicht wieder zurück in den Stapel legt, bevor man die zweite zieht?


Wirtschaftsstatistik 2026 | © Sönke Hartmann | 72

Rechnen mit Wahrscheinlichkeiten

Ein **Baumdiagramm** kann bei der Analyse von Wahrscheinlichkeiten hilfreich sein

- ▶ Alle Ergebnisse werden systematisch erfasst
- ▶ Bedingte Wahrscheinlichkeiten können untersucht werden

Beispiel: Eine Karte wird aus einem Kartenspiel mit 52 Karten gezogen und nicht wieder in den Stapel zurückgelegt. Dann wird eine zweite Karte gezogen. Mit welcher Wahrscheinlichkeit zieht man zwei Könige?



Wirtschaftsstatistik 2026 | © Sönke Hartmann | 73

Rechnen mit Wahrscheinlichkeiten

Gegeben: Ereignisse $A_1, \dots, A_n$ mit $A_1 \cup \dots \cup A_n = S$ und $A_i \cap A_j = \emptyset$ für alle $i \neq j$

Satz der totalen Wahrscheinlichkeit:

$$P(B) = P(A_1)P(B|A_1) + \dots + P(A_n)P(B|A_n)$$

Spezialfall: $P(B) = P(A)P(B|A) + P(\bar{A})P(B|\bar{A})$

Übung: Ein Computer-Hersteller bezieht RAM-Chips von drei verschiedenen Lieferanten. 1,6% aller RAM-Chips sind defekt. Außerdem ist folgendes bekannt:

- ▶ 30% der Chips kommen von Lieferant A, und 1% davon sind defekt
- ▶ 50% der Chips kommen von Lieferant B, und 1,8% davon sind defekt
- ▶ 20% der Chips kommen von Lieferant C

Welcher Anteil der RAM-Chips von Lieferant C ist defekt?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 74

Rechnen mit Wahrscheinlichkeiten

Der **Satz von Bayes** beschreibt das Verhältnis der bedingten Wahrscheinlichkeiten $P(A|B)$ und $P(B|A)$:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Übung: Ein Unternehmen hat einen Test für eine seltene, aber gefährliche Krankheit entwickelt. Nun soll die Zuverlässigkeit des Tests analysiert werden.

- ▶ Die Testgenauigkeit ist gut:
Die Wahrscheinlichkeit, dass eine kranke Person positiv getestet wird, beträgt 0,98
Die Wahrscheinlichkeit, dass eine gesunde Person negativ getestet wird, beträgt 0,99
- ▶ 0,5% der getesteten Personen sind krank
- ▶ Wie wahrscheinlich ist es, dass eine positiv getestete Person wirklich krank ist?
- ▶ Notation: "K": Person ist krank "+" : Person wurde positiv getestet
 "N": Person ist nicht krank "-" : Person wurde negativ getestet

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 75

Kapitel 4

Wahrscheinlichkeiten

- 1 Grundlagen
- 2 Rechnen mit Wahrscheinlichkeiten
- 3 Kombinatorik und Wahrscheinlichkeiten**

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 76

Kombinatorik

Fundamentalprinzip der Kombinatorik: Wir betrachten eine Folge von n Ereignissen, wobei es...

- für das erste Ereignis k_1 Möglichkeiten gibt,
- für das zweite Ereignis k_2 Möglichkeiten gibt usw.

Dann ist die Gesamtanzahl der Möglichkeiten $k_1 \cdot k_2 \cdot \dots \cdot k_n$

Ein Baumdiagramm kann genutzt werden, um die Möglichkeiten darzustellen

Beispiel: Ein Möbelhaus bietet einen Kleiderschrank in zwei Höhen, acht Farben und mit drei Türvarianten an. Dann sind $2 \cdot 8 \cdot 3 = 48$ verschiedene Kleiderschränke möglich. Ikea scheint so zu rechnen:



Übung: Wie viele verschiedene QR-Codes der abgebildeten Größe gibt es?



Wirtschaftsstatistik 2026 | © Sönke Hartmann | 77

Kombinatorik

Eine **Permutation** ist eine Anordnung von Objekten in einer Reihenfolge

Die Anzahl möglicher Reihenfolgen (Permutationen) von n Objekten entspricht der Fakultät:

$$n! = n \cdot (n - 1) \cdot (n - 2) \cdot \dots \cdot 2 \cdot 1$$

Beispiel: Wie viele Möglichkeiten gibt es, acht Biermarken zu sortieren?

$$8! = 8 \cdot 7 \cdot 6 \cdot 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1$$

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 78

Kombinatorik

Eine **Kombination** ist eine Auswahl verschiedener Objekte aus einer Menge ohne Berücksichtigung der Reihenfolge und ohne Zurücklegen (d.h. jedes Objekt kann höchstens einmal gewählt werden)

Die Anzahl der Möglichkeiten, k aus n Objekten ohne Berücksichtigung der Reihenfolge und ohne Zurücklegen auszuwählen, ist

$$\binom{n}{k} = \frac{n!}{k! \cdot (n-k)!}$$

Statt $\binom{n}{k}$ wird gelegentlich auch ${}_nC_k$ geschrieben (bzw. auf Taschenrechnern nCr oder auch nCr)

Beispiel: Wie viele Möglichkeiten gibt es, drei aus acht Biermarken ohne Berücksichtigung der Reihenfolge zu wählen, wobei eine Marke maximal einmal gewählt werden darf?

$$\binom{8}{3} = \frac{8!}{3! \cdot (8-3)!} = \frac{8 \cdot 7 \cdot 6 \cdot 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1}{3 \cdot 2 \cdot 1 \cdot 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1} = \frac{8 \cdot 7 \cdot 6}{3 \cdot 2 \cdot 1}$$

Kombinatorik und Wahrscheinlichkeiten

Beispiel: Wir betrachten das Lotto "6 aus 49".
Was ist die Wahrscheinlichkeit für "4 Richtige"?

Also: Man kreuzt 6 von 49 Zahlen an. Dann werden 6 der 49 Zahlen zufällig gezogen. Wie groß ist die Wahrscheinlichkeit, dass 4 der angekreuzten Zahlen unter den 6 gezogenen sind?

1	2	3	4	5	6	7
8	9	10	11	12	13	14
15	16	17	18	19	20	21
22	23	24	25	26	27	28
29	30	31	32	33	34	35
36	37	38	39	40	41	42
43	44	45	46	47	48	49



Ansatz und Lösung:


- ▶ 4 der 6 gezogenen Zahlen wurden angekreuzt (Reihenfolge ist nicht relevant): $\binom{6}{4}$
- ▶ 2 der 43 nicht gezogenen Zahlen wurden angekreuzt: $\binom{43}{2}$
- ▶ Anzahl der Möglichkeiten, 6 aus 49 Zahlen zu wählen: $\binom{49}{6}$
- ▶ Die Wahrscheinlichkeit für "4 Richtige" ist $\frac{\binom{6}{4} \cdot \binom{43}{2}}{\binom{49}{6}} = 0,00097 \approx 0,1\%$

Kombinatorik und Wahrscheinlichkeiten: Übungen

Übung 1: Ein Müsli-Hersteller bietet 14 Varianten seines Müslis an. Ein Supermarkt möchte 8 davon in sein Sortiment nehmen. Wie viele Möglichkeiten gibt es, 8 Sorten auszuwählen?

Übung 2: Eine Wirtschaftsprüferin untersucht, wie viele Rechnungen sie stichprobenartig prüfen müsste, um mit hinreichender Wahrscheinlichkeit einen Fehler zu entdecken. Angenommen, 5 von 50 Rechnungen sind tatsächlich fehlerhaft. Wie groß ist die Wahrscheinlichkeit, keine fehlerhafte Rechnung zu finden, wenn sie 10 der 50 prüfen würde?

Übung 3: Domino's bietet Pizza in zwei Größen, drei Boden-Varianten und mit zehn Belägen an. Für eine Pizza kann ein Belag höchstens einmal gewählt werden. Ein Domino's-Fan möchte jeden Tag eine andere Pizza essen. Wie viele Jahre dauert es, bis er alle Möglichkeiten probiert hat?



81

Kapitel 5

Diskrete Wahrscheinlichkeitsverteilungen

Kapitel 5

Diskrete Wahrscheinlichkeitsverteilungen

- 1 Grundlagen
- 2 Die Binomialverteilung
- 3 Weitere diskrete Wahrscheinlichkeitsverteilungen

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 83

Diskrete Wahrscheinlichkeitsverteilungen

Diskrete Zufallsvariable nehmen diskrete (zählbare) Werte an

Eine diskrete Wahrscheinlichkeitsverteilung ordnet jedem Wert x_i eine Wahrscheinlichkeit zu

Eine diskrete Wahrscheinlichkeitsverteilung kann als Tabelle dargestellt werden:

x_1	x_2	x_3	...	x_{n-1}	x_n
$P(x_1)$	$P(x_2)$	$P(x_3)$	...	$P(x_{n-1})$	$P(x_n)$

Beispiel: Würfel

x_i	1	2	3	4	5	6
$P(x_i)$	1/6	1/6	1/6	1/6	1/6	1/6

Die Wahrscheinlichkeiten können theoretisch oder empirisch sein

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 84

Diskrete Wahrscheinlichkeitsverteilungen

Die **kumulative Verteilung** einer diskreten Zufallsvariable ist definiert als

$$P(X \leq x_k) = P(X = x_1) + P(X = x_2) + \dots + P(X = x_k) = \sum_{i=1}^k P(X = x_i)$$

Beispiel: Dauer des BWL-Studiums an einer bestimmten Universität in Semestern

► Verteilung:

x_i	6	7	8	9	10	11
$P(X = x_i)$	0,01	0,66	0,19	0,07	0,05	0,02

► Kumulative Verteilung:

x_i	6	7	8	9	10	11
$P(X \leq x_i)$	0,01	0,67	0,86	0,93	0,98	1,00

Diskrete Wahrscheinlichkeitsverteilungen

Der **Erwartungswert** $E(X)$ einer diskreten Zufallsvariable ist der Mittelwert der Verteilung:

$$E(X) = \mu = \sum_{i=1}^n x_i \cdot P(X = x_i)$$

Die **Varianz** ist

$$\sigma^2 = \sum_{i=1}^n (x_i - \mu)^2 \cdot P(X = x_i)$$

Die **Standardabweichung** σ ist die Wurzel aus der Varianz σ^2

Beispiel: Bestimmen Sie die erwartete Studiendauer (in Semestern), die Varianz und die Standardabweichung für die folgende Verteilung:

x_i	6	7	8	9	10	11
$P(X = x_i)$	0,01	0,66	0,19	0,07	0,05	0,02

Anwendung: Gesundheitswesen

Um festzustellen, ob eine Person eine bestimmte Krankheit hat, kann eine Blutprobe untersucht werden

Da die Untersuchung einer Blutprobe teuer sein kann, werden Blutproben mehrerer Personen oft zusammen untersucht ("Pooling"). Dies kann die Kosten senken, wenn die Krankheit selten auftritt:

- ▶ Wenn keine der Personen die Krankheit hat, reicht ein Test aus – in diesem Fall werden mehrere Tests eingespart
- ▶ Wenn aber mindestens eine Person krank ist, muss für jede Person anschließend eine separate Blutuntersuchung durchgeführt werden

Übung: Welcher Anteil der Kosten kann eingespart werden, wenn...

- ▶ die Wahrscheinlichkeit, dass eine Person krank ist, bei 0,04 liegt und
- ▶ die Blutproben von 10 Patienten zusammen untersucht werden?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 87

Kapitel 5

Diskrete Wahrscheinlichkeitsverteilungen

- 1 Grundlagen
- 2 Die Binomialverteilung**
- 3 Weitere diskrete Wahrscheinlichkeitsverteilungen

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 88

Binomialverteilung

Viele Zufallsexperimente haben nur zwei mögliche Ergebnisse oder können auf nur zwei relevante Ergebnisse reduziert werden:

- Medikament bei einem Patienten: Nebenwirkung oder nicht
- Wahlumfrage: Person würde Partei X wählen oder nicht
- Qualitätskontrolle: Produkt ist defekt oder nicht
- Marketing: Person würde Marke X kaufen oder nicht

Wir betrachten nun Experimente der folgenden Form:

- Jeder Versuch hat zwei mögliche Ergebnisse (allgemein: Erfolg und Misserfolg)
- Die Anzahl der Versuche ist fest und wird als n bezeichnet
- Die Ergebnisse der einzelnen Versuche sind unabhängig voneinander
- Die Erfolgswahrscheinlichkeit p ist in jedem Versuch gleich (die Misserfolgswahrscheinlichkeit $q = 1 - p$ ebenfalls)

Beispiel: Fünfmal eine Münze werfen, Kopf zählt als Erfolg.

Dann ist $n = 5$, $p = 0,5$ und $q = 0,5$.

Binomialverteilung

Die **Binomialverteilung** gibt die Wahrscheinlichkeit für jede mögliche Anzahl Erfolge zwischen 0 und n an

Bei n Versuchen, einer Erfolgswahrscheinlichkeit von p und einer Misserfolgswahrscheinlichkeit von $q = 1 - p$ beträgt die Wahrscheinlichkeit für x Erfolge

$$P(X = x) = \binom{n}{x} \cdot p^x \cdot q^{n-x} = \frac{n!}{x! \cdot (n-x)!} \cdot p^x \cdot q^{n-x}$$

Beispiel: Ein Unternehmen stellt Glühbirnen her, die in Fünferpacks verkauft werden.

Es ist bekannt, dass 10% der Glühbirnen defekt sind.

- $n = 5$ Versuche bzw. Glühbirnen
- Wenn "defekt" als Erfolg definiert wird, haben wir $p = 0,1$ und $q = 0,9$
- Es gibt zwischen 0 und 5 defekte Glühbirne pro Fünferpack

x	0	1	2	3	4	5
$P(X = x)$	0.5905	0.3281	0.0729	0.0081	0.0005	0.0000

Binomialverteilung: Übungen

Übung 1: In einem Onlineshop ist bekannt, dass die Wahrscheinlichkeit, dass ein bestellter Artikel nicht auf Lager ist, 0.09 beträgt. Wir betrachten einen Kunden, der 10 Produkte bestellt hat. Wie hoch ist die Wahrscheinlichkeit, dass...

- ▶ ... genau zwei Produkte nicht auf Lager sind?
- ▶ ... höchstens ein Produkt nicht auf Lager ist?
- ▶ ... mindestens acht Produkte auf Lager sind?

Übung 2: Wir nehmen an, dass 4% aller Studierenden, die an einer bestimmten Klausur teilnehmen, eine 1,0 bekommen. Wie hoch ist die Wahrscheinlichkeit, dass in einem Kurs mit 18 Studierenden mehr als zwei eine 1,0 erhalten?

Binomialverteilung

Erwartungswert der Binomialverteilung: $E(X) = \mu = n \cdot p$

Varianz der Binomialverteilung: $\sigma^2 = n \cdot p \cdot q$

Standardabweichung der Binomialverteilung: $\sigma = \sqrt{n \cdot p \cdot q}$

Beispiel 1: Eine Münze wird 50-mal geworfen

- ▶ Dann kann im Durchschnitt 25-mal Kopf erwartet werden
- ▶ Die Kopf-Anzahl schwankt jedoch, die Standardabweichung beträgt 3,54

Beispiel 2: Dem Management eines Hotels mit 100 Zimmern ist bekannt, dass durchschnittlich 18% der Gäste mit dem Auto anreisen

- ▶ Dann sind im Durchschnitt $E(X) = 18$ belegte Parkplätze zu erwarten
- ▶ Die Anzahl mit dem Auto anreisender Gäste schwankt von Tag zu Tag, die Standardabweichung liegt bei $\sqrt{100 \cdot 0,18 \cdot 0,82} = 3,84$
- ▶ Die Binomialverteilung kann helfen, die Anzahl benötigter Parkplätze zu bestimmen

Binomialverteilung: Anwendung

Fluggesellschaften überbuchen ihre Flüge häufig, d.h. sie verkaufen mehr Tickets als Plätze vorhanden sind

- › Damit nutzen sie aus, dass Personen, die ein Ticket haben, den Flug mit einer gewissen Wahrscheinlichkeit nicht antreten
- › Fluggesellschaften müssen abwägen zwischen dem zusätzlichen Umsatz und dem Risiko, dass mehr Personen zum Flug erscheinen als Plätze vorhanden sind
- › Dieses Risiko muss berücksichtigt werden, wenn die Anzahl zuviel angebotener Tickets bestimmt wird

Übung: Es sei bekannt, dass auf einer bestimmten Flugroute durchschnittlich 6% der Personen mit Ticket nicht zum Abflug erscheinen. Wir betrachten einen Flug mit 45 Plätzen, für den 47 Tickets verkauft wurden.

- › Mit wie vielen Passagieren ist im Durchschnitt zu rechnen?
- › Mit welcher Wahrscheinlichkeit erscheinen nicht mehr als 45 Passagiere?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 93

Kapitel 5

Diskrete Wahrscheinlichkeitsverteilungen

- 1 Grundlagen
- 2 Die Binomialverteilung
- 3 Weitere diskrete Wahrscheinlichkeitsverteilungen**

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 94

Gleichverteilung

Die **Gleichverteilung** ordnet jedem Ergebnis dieselbe Wahrscheinlichkeit zu

Wenn wir k mögliche Ergebnisse haben, beträgt die Wahrscheinlichkeit für jedes Ergebnis

$$p = \frac{1}{k}$$

Beispiel: Würfeln, $p = \frac{1}{6}$ für jede Augenzahl zwischen 1 und 6

x_i	1	2	3	4	5	6
$P(X = x_i)$	1/6	1/6	1/6	1/6	1/6	1/6

Benford-Verteilung

Die **Benford-Verteilung** ordnet jeder Ziffer d zwischen 1 und 9 eine Wahrscheinlichkeit zu:

$$P(d) = \log_{10} \left(1 + \frac{1}{d} \right), \quad d = 1, \dots, 9$$

d	1	2	3	4	5	6	7	8	9
$P(X = d)$	0,301	0,176	0,125	0,097	0,079	0,067	0,058	0,051	0,046

Die 1 tritt deutlich häufiger als führende Ziffer auf als die 9 (30,1% vs. 4,6%)

Benfordsches Gesetz: In vielen empirischen Datensätzen folgt die Häufigkeitsverteilung der ersten Ziffern von Zahlen der Benford-Verteilung

Praxisanwendung in der Wirtschaft:

- › Das Benfordsche Gesetz gilt aufgrund von Wachstumsprozessen (Zinsen, Inflation etc.)
- › Das Benfordsche Gesetz kann verwendet werden, um mögliche Manipulationen in Bilanzen zu finden (manipulierte Bilanzen folgen dem Benfordschen Gesetz meist nicht)
- › Zur Überprüfung benötigt man einen Hypothesentest (vgl. Kapitel 8)

Kapitel 6

Stetige Wahrscheinlichkeitsverteilungen

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 97

Kapitel 6

Stetige Wahrscheinlichkeitsverteilungen

- 1 Grundlagen**
- 2 Die Normalverteilung
- 3 Verteilung von Stichproben-Mittelwerten
- 4 Approximation der Binomialverteilung

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 98

Stetige Wahrscheinlichkeitsverteilungen

Die Ergebnisse einer stetigen Zufallsvariable sind reelle Zahlen (z.B. Größe, Gewicht)


Die Wahrscheinlichkeitsverteilung ergibt sich aus

- › einer **Dichtefunktion** $f(x)$
- › einer **Verteilungsfunktion** $F(x)$

Ansatz: Eine Wahrscheinlichkeit entspricht einer Fläche unter der Dichtefunktion

Beispiel: Körpergröße

Mit welcher Wahrscheinlichkeit ist eine zufällig gewählte Person höchstens 1,90 m groß?



$$P(X \leq 190) = F(190) = \int_0^{190} f(x)dx$$

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 99

Stetige Wahrscheinlichkeitsverteilungen

Die folgenden Annahmen gelten:

- › Die Dichtefunktion ist nicht negativ:

$$f(x) \geq 0 \text{ für alle } x$$

- › Die Fläche unter der Dichtefunktion ist 1:

$$\int_{-\infty}^{\infty} f(x)dx = 1$$

- › Die Verteilungsfunktion ist die Stammfunktion der Dichtefunktion und gibt die Wahrscheinlichkeit an:

$$P(X \leq x) = F(x) = \int_{-\infty}^x f(x)dx$$

- › Die Wahrscheinlichkeit eines einzelnen Wertes ist 0: $P(X = x) = 0$ für alle x

Übung: Wie können die folgenden Wahrscheinlichkeiten mit Hilfe der Verteilungsfunktion ausgedrückt werden?

$$P(X < x) =$$


$$P(a \leq X \leq b) =$$

$$P(a < X < b) =$$

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 100

Diskrete vs. stetige Verteilungen

Diskrete Wahrscheinlichkeitsverteilungen




$$P(x_a \leq X \leq x_b) = \sum_{i=a}^b P(X = x_i)$$

$$P(X = x) \geq 0$$

$$\sum_{i=1}^n P(X = x_i) = 1$$

Stetige Wahrscheinlichkeitsverteilungen



$$P(a \leq X \leq b) = \int_a^b f(x) dx = F(b) - F(a)$$

$$P(X = x) = 0$$

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 101

Typische Formen stetiger Verteilungen

Normalverteilung

Symmetrisch, glockenförmig




Anwendungen:

- › IQ
- › Ergebnisse vieler Uni-Zulassungstests
- › Wöchentliche Absatzmenge eines Produkts im Supermarkt
- › Analyse von Stichproben (siehe später)

Andere stetige Verteilungen

Beispiel hier: rechtsschiefe Verteilung



Anwendungen:

- › Verteilung der Vermögen in einem Land
- › Verteilung der Einkommen in einem Land
- › Miete pro Quadratmeter in einer Stadt
- › Gesprächsdauer in einem Call Center
- › Lebensdauern von Geräten/Maschinen

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 102

Kapitel 6

Stetige Wahrscheinlichkeitsverteilungen

- 1 Grundlagen
- 2 Die Normalverteilung**
- 3 Verteilung von Stichproben-Mittelwerten
- 4 Approximation der Binomialverteilung


Wirtschaftsstatistik 2026 | © Sönke Hartmann | 103

Normalverteilung

Die Normalverteilung mit Mittelwert μ und Standardabweichung σ besitzt die folgende Dichtefunktion:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Die Dichtefunktion der Normalverteilung entspricht einer glockenförmigen Kurve, die symmetrisch zum Mittelwert ist:




Aufgrund der Symmetrie sind der Median und der Modus gleich dem Mittelwert

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 104


Normalverteilung

Bei der Normalverteilung hängen die Wahrscheinlichkeiten nur von μ und σ ab

Beispiele:



Anwendung: Der IQ ist normalverteilt mit $\mu = 100$ und $\sigma = 15$




Wirtschaftsstatistik 2026 | © Sönke Hartmann | 105

Normalverteilung

Mit zunehmender Entfernung vom Mittelwert nähert sich die Dichtefunktion 0 an

Viele Größen in der Praxis sind (zumindest annähernd) normalverteilt, allerdings mit unterschiedlichen Mittelwerten und Standardabweichungen

Die Form der Dichtefunktion ist immer gleich, der Mittelwert bestimmt allerdings die Position, und die Standardabweichung bestimmt die Breite der Kurve:



Wirtschaftsstatistik 2026 | © Sönke Hartmann | 106

Normalverteilung

Die Normalverteilung mit Mittelwert 0 und Standardabweichung 1 heißt

Standardnormalverteilung

Wofür wird die Standardnormalverteilung benötigt?

- Es gibt keine Formel zur direkten Berechnung von Wahrscheinlichkeiten der Normalverteilung, aber man kann Näherungswerte in Tabellen finden
- Man würde aber separate Tabellen für verschiedene Werte von μ und σ benötigen, das wäre nicht praktikabel
- Idee daher: Eine beliebige Normalverteilung wird in die Standardnormalverteilung transformiert
- Dann können alle Wahrscheinlichkeiten in nur einer Tabelle – der für die Standardnormalverteilung – nachgesehen werden

Notation für die Standardnormalverteilung:

- Die Zufallsvariable wird als Z geschrieben
- Die Verteilungsfunktion wird oft wie folgt geschrieben: $P(Z \leq z) = \Phi(z)$

Normalverteilung: z-Wert

Wir möchten $P(X \leq x)$ für eine gegebene Normalverteilung mit gegebenen μ und σ und für einen bestimmten Wert x berechnen

Zunächst berechnen wir den **z-Wert**: $z = \frac{x - \mu}{\sigma}$

Dann sehen wir z in der Tabelle der Standardnormalverteilung nach und erhalten

$$P(X \leq x) = P(Z \leq z)$$

Eigenschaften von z :


- z gibt an, wie viele Standardabweichungen x über bzw. unter dem Mittelwert liegt
- Ein negativer z -Wert bedeutet, dass x unter dem Mittelwert liegt

Mit anderen Worten: Wir können die Wahrscheinlichkeit für einen Wert von höchstens x nicht direkt bestimmen. Stattdessen bestimmen wir die Wahrscheinlichkeit dafür, dass ein Wert höchstens z Standardabweichungen über dem Mittelwert liegt – diese Wahrscheinlichkeit ist für alle Normalverteilungen gleich

Normalverteilung

Beispiel: Welcher Anteil der Bevölkerung hat einen IQ von bis zu 120?

$$P(X \leq 120) = P\left(Z \leq \frac{x - \mu}{\sigma}\right) = P\left(Z \leq \frac{120 - 100}{15}\right) = P(Z \leq 1,33) = 0,9082$$



Normalverteilung des IQ:	$\mu = 100$	$x = 120$	$(\sigma = 15)$
Standardnormalverteilung:	$\mu = 0$	$z = 1.33$	$(\sigma = 1)$

Normalverteilung

Die meisten Tabellen der Standardnormalverteilung...

- ▶ enthalten die Wahrscheinlichkeit für den Bereich links von z , also $P(Z \leq z)$
- ▶ enthalten nur Wahrscheinlichkeiten für $z \geq 0$ (aufgrund der Symmetrie)

Übungen: Mit welcher Wahrscheinlichkeit hat eine zufällig gewählte Person...

- ▶ ...einen IQ von mehr als 125?
- ▶ ...einen IQ von höchstens 90?

Rechenregeln: $P(X \leq x) = P(Z \leq z) = P\left(Z \leq \frac{x - \mu}{\sigma}\right)$

$$P(X < x) = P(X \leq x) = P(Z \leq z)$$

$$P(X > x) = 1 - P(X \leq x) = 1 - P(Z \leq z)$$

$$P(x_1 \leq X \leq x_2) = P(X \leq x_2) - P(X < x_1) = P(Z \leq z_2) - P(Z < z_1)$$

$$P(Z \leq -z) = 1 - P(Z \leq z)$$

Normalverteilung

Bisher: Wert war gegeben, die zugehörige Wahrscheinlichkeit war gesucht

Jetzt: Wahrscheinlichkeit (oder auch Prozentsatz) ist gegeben, der zugehörige Wert ist gesucht

Wir verwenden die Formel $z = \frac{x - \mu}{\sigma} \Rightarrow x = \mu + z \cdot \sigma$

Beispiel: Was ist der minimale IQ der 5% intelligentesten Menschen?

- ▶ Für die obersten 5% finden wir $z \approx 1,64$ in der Tabelle
- ▶ Also: Der IQ einer solchen Person liegt mindestens 1,64 Standardabweichungen über dem Mittelwert von 100
- ▶ Anwendung der Formel: $x = \mu + z \cdot \sigma = 100 + 1,64 \cdot 15 = 124,6$
- ▶ Ergebnis: Eine Person, die zu den 5% intelligentesten Menschen gehört, hat einen IQ von mindestens 124,6

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 111

Normalverteilung: Übungen

Übung 1: Die Leitung einer Drogerie untersucht die wöchentliche Nachfrage nach einer bestimmten Zahnpasta. Sie ermittelt folgende Werte: $\mu = 124$ und $\sigma = 18$ (die Nachfrage ist annähernd normalverteilt).

- ▶ Mit welcher Wahrscheinlichkeit reicht ein Lagerbestand von 150 Tuben für eine Woche aus?
- ▶ Mit welcher Wahrscheinlichkeit werden mehr als 115 Tuben in einer Woche verkauft?
- ▶ Wie viele Tuben sollten zu Wochenbeginn auf Lager sein, damit das Risiko, dass die Nachfrage größer ist als der Lagerbestand, bei höchstens 2,5% liegt?

Übung 2: 50% der Neugeborenen sind kleiner als 49,5 cm, und 3% sind kleiner als 45,5 cm. Wir nehmen an, dass die Werte normalverteilt sind.

- ▶ Welcher Anteil der Neugeborenen ist größer als 52 cm?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 112

Kapitel 6

Stetige Wahrscheinlichkeitsverteilungen

- 1 Grundlagen
- 2 Die Normalverteilung
- 3 Verteilung von Stichproben-Mittelwerten**
- 4 Approximation der Binomialverteilung

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 113

Verteilung von Stichproben-Mittelwerten

Nehmen wir an, dass viele Stichproben derselben Größe n aus derselben Grundgesamtheit gezogen werden. Wie lässt sich die Verteilung der Stichprobenmittelwerte beschreiben?

Der Mittelwert der Stichprobenmittelwerte $\mu_{\bar{X}}$ entspricht dem Mittelwert der Grundgesamtheit μ :

$$\mu_{\bar{X}} = \mu$$

Die Standardabweichung der Stichprobenmittelwerte $\sigma_{\bar{X}}$ ist kleiner als die Standardabweichung der Grundgesamtheit σ . Sie hängt von der Stichprobengröße n ab und wird auch als Standardfehler des Mittelwerts bezeichnet:

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

Zentraler Grenzwertsatz: Mit steigender Stichprobengröße n nähert sich die Verteilung der Stichprobenmittelwerte immer mehr einer Normalverteilung mit Mittelwert $\mu_{\bar{X}} = \mu$ und Standardfehler $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$ an.

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 114

Verteilung von Stichproben-Mittelwerten

Einzelwert: Mit welcher Wahrscheinlichkeit hat eine zufällig gewählte Person einen IQ von mehr als 110?

$$P(X > 110) = 1 - P(X \leq 110) = 1 - P\left(Z \leq \frac{110 - 100}{15}\right) = 1 - P(Z \leq 0,67) = 0,2514$$

Durchschnitt: Mit welcher Wahrscheinlichkeit haben 25 zufällig gewählte Personen einen durchschnittlichen IQ von mehr als 110?

- Der durchschnittliche IQ ist der Stichproben-Mittelwert, also $\mu_{\bar{X}} = 100$ und $\sigma_{\bar{X}} = \frac{15}{\sqrt{25}} = 3$
- Wir erhalten den folgenden z-Wert: $z = \frac{\bar{X} - \mu_{\bar{X}}}{\sigma_{\bar{X}}} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$
- Damit ergibt sich:

$$P(\bar{X} > 110) = 1 - P(\bar{X} \leq 110) = 1 - P\left(Z \leq \frac{110 - 100}{15/\sqrt{25}}\right) = 1 - P(Z \leq 3,33) = 0,0004$$

Verteilung von Stichproben-Mittelwerten

Analyse von Einzelwerten x aus einer normalverteilten Grundgesamtheit:

Wir benutzen den Mittelwert der Grundgesamtheit μ und die Standardabweichung σ

Wir verwenden $z = \frac{x - \mu}{\sigma}$ und die Standardnormalverteilung

Analyse von Mittelwerten $\bar{X}$ aus Stichproben der Größe n aus einer normalverteilten Grundgesamtheit:

Wir benutzen den Mittelwert der Grundgesamtheit μ und den Standardfehler $\frac{\sigma}{\sqrt{n}}$

Wir verwenden $z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$ und die Standardnormalverteilung

Bei genügend großen Stichproben können wir näherungsweise die Normalverteilung auch dann verwenden, wenn die Einzelwerte nicht normalverteilt sind

Dies wird bei der Auswertung von Stichproben angewendet (Konfidenzintervalle in Kapitel 7 und Hypothesentests in Kapitel 8)

Verteilung von Stichproben-Mittelwerten: Übung

Ein Unternehmen hat ein Medikament entwickelt, das den LDL-Cholesterinspiegel senkt. Nach Herstellerangaben senkt das Medikament den Cholesterinspiegel durchschnittlich um 42 mg/dl (bei einer Standardabweichung von 12 mg/dl).

Mit welcher Wahrscheinlichkeit beträgt die Senkung des Cholesterinspiegels bei einer Person nur bis zu 38 mg/dl?

Mit welcher Wahrscheinlichkeit beträgt die Senkung des Cholesterinspiegels bei einer Stichprobe von 64 Personen im Durchschnitt nur bis zu 38 mg/dl?

Nehmen Sie nun an, dass die durchschnittliche Senkung bei 64 Personen tatsächlich 38 mg/dl betrug. Was lässt sich daraus folgern?

Dieser Ansatz ist die Basis von Hypothesentests (Kapitel 8).

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 117

Kapitel 6

Stetige Wahrscheinlichkeitsverteilungen


- 1 Grundlagen
- 2 Die Normalverteilung
- 3 Verteilung von Stichproben-Mittelwerten
- 4 Approximation der Binomialverteilung**

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 118

Approximation der Binomialverteilung

Wenn wir eine große Anzahl Versuche haben (also ein großes n), dann ähnelt die Form der Binomialverteilung der Form der Normalverteilung

Illustration anhand eines Beispiels:



Wirtschaftsstatistik 2026 | © Sönke Hartmann | 119

Approximation der Binomialverteilung



Wenn wir eine Wahrscheinlichkeit $P(X = x)$ der **Binomialverteilung** bestimmen wollen, können wir diese mit Hilfe der **Normalverteilung** annähern (sofern die Anzahl Versuche groß genug ist).
Vorgehensweise:

- ▶ n ist die Anzahl Versuche
- ▶ x ist die Anzahl Erfolge
- ▶ p ist die Erfolgswahrscheinlichkeit, q ist die Misserfolgswahrscheinlichkeit
- ▶ Der Mittelwert (Erwartungswert) der Binomialverteilung ist $\mu = np$
- ▶ Die Standardabweichung der Binomialverteilung ist $\sigma = \sqrt{npq}$
- ▶ Wir erhalten:

$$P(X \leq x \text{ Erfolge}) \approx P\left(Z \leq \frac{x - \mu}{\sigma}\right) = P\left(Z \leq \frac{x - np}{\sqrt{npq}}\right)$$

Diese Approximation wird nicht weiter behandelt (und ist nicht klausurrelevant), wird aber in den Kapiteln 7 und 8 für die Analyse von Anteilswerten (oder Prozentanteilen) in Stichproben angewendet

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 120

Kapitel 7

Konfidenzintervalle und Stichprobengrößen

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 121

Kapitel 7

Konfidenzintervalle und Stichprobengrößen

- 1 Konfidenzintervall für Mittelwerte**
- 2 Konfidenzintervall für Anteilswerte
- 3 Minimale Stichprobengröße
- 4 Konfidenzintervall für Regressionskoeffizienten

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 122

Punkt- vs. Intervallschätzung

Nehmen Sie an, dass wir eine bestimmte Größe bestimmen wollen (e.g. Einkommen, Alter...)

Wir möchten diese Größe für die Grundgesamtheit bestimmen, haben aber oft nur eine Stichprobe (also einen kleinen Ausschnitt aus der Grundgesamtheit)

Wir können die Größe für die Stichprobe berechnen und das Ergebnis dann als Schätzung für die Grundgesamtheit verwenden

Beispiel:

- › Wir möchten das Durchschnittsalter der Kunden eines Shops bestimmen
- › Wir können nicht alle Kunden befragen, also befragen wir eine Stichprobe mit 100 Kunden
- › Wir berechnen das Durchschnittsalter der Stichprobe und verwenden es als Schätzung für das Durchschnittsalter aller Kunden der Grundgesamtheit

Problem: Wir wissen nicht, wie gut diese Schätzung ist, also wie dicht sie am tatsächlichen Durchschnittsalter der Grundgesamtheit ist

Punkt- vs. Intervallschätzung

Der Stichproben-Mittelwert ist eine **Punktschätzung** für den Mittelwert der Grundgesamtheit

Nachteil: Punktschätzungen enthalten keine Informationen zur Genauigkeit

Ein **Konfidenzintervall** gibt nicht nur einen Punkt, sondern ein Intervall an, zusammen mit einer Wahrscheinlichkeit, dass der tatsächliche Wert im Intervall liegt

Die Wahrscheinlichkeit, dass der tatsächliche Wert der Grundgesamtheit im Intervall liegt, heißt **Konfidenzniveau**

Beispiel:

- › Punktschätzung: Das Durchschnittsalter der Kunden beträgt 34 Jahre
- › Konfidenzintervall: Mit einer Wahrscheinlichkeit von 95% liegt das tatsächliche Durchschnittsalter der Grundgesamtheit aller Kunden zwischen 32,6 und 35,4 Jahren (aber mit einer Wahrscheinlichkeit von 2,5% liegt es unter 32,6 Jahren, und mit einer Wahrscheinlichkeit von 2,5% liegt es über 35,4 Jahren)

Auswahl der Verteilung

Zur Bestimmung eines Konfidenzintervall für Mittelwerte benötigen wir eine geeignete Verteilung:

- › Wir nehmen an, dass die Werte näherungsweise normalverteilt sind
- › Wir nehmen an, dass die Standardabweichung σ der Werte der Grundgesamtheit unbekannt ist (das ist in der Praxis meist der Fall)
- › Dann verwenden wir die sogenannte t-Verteilung
- › Je größer die Stichprobe, desto mehr nähert sich die t-Verteilung der Normalverteilung an. Deshalb können wir bei größeren Stichproben auch die Normalverteilung verwenden.

Pragmatischer Ansatz für Konfidenzintervalle für Stichprobenmittelwerte:

- › **Kleine Stichprobe** ($n < 30$): Die **t-Verteilung** muss verwendet werden
- › **Große Stichprobe** ($n \geq 30$): Die **Normalverteilung** kann verwendet werden

Hinweis: Wenn die Verteilung stark von der Normalverteilung abweicht (was in der Praxis vorkommen kann), dann kann man die t- und die Normalverteilung erst bei größeren Stichproben verwenden (dieser Fall wird hier aus Vereinfachungsgründen nicht betrachtet).


Wirtschaftsstatistik 2026 | © Sönke Hartmann | 125

Konfidenzintervall: Normalverteilung

Aus Abschnitt 6.3 folgt, dass ein Stichprobenmittelwert mit einer Wahrscheinlichkeit von $1 - \alpha$ höchstens $z_{\alpha/2}$ Standardabweichungen vom Mittelwert der Grundgesamtheit entfernt ist.

Daraus folgt, dass der Mittelwert der Grundgesamtheit mit einer Wahrscheinlichkeit von $1 - \alpha$ höchstens $z_{\alpha/2}$ Standardabweichungen vom Stichprobenmittelwert entfernt ist:

$$\bar{X} - z_{\alpha/2} \frac{s}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \frac{s}{\sqrt{n}}$$



Berechnung des Konfidenzintervalls für Mittelwerte mit der Normalverteilung:

- › Berechnung von $\bar{X}$ und Standardabweichung s (oder σ falls bekannt)
- › Wahl des gewünschten Konfidenzniveaus (z.B. 95%); $\alpha = 1 - \text{Konfidenzniveau}$
- › Bestimmung von $z_{\alpha/2}$ (hier: aus Normalverteilungstabelle)
- › Berechnung der unteren und oberen Grenze des Konfidenzintervalls

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 126

Konfidenzintervall: Normalverteilung

Beispiel:

- Annahme: Das Alter der Kunden ist annähernd normalverteilt
- Aus einer Stichprobe mit $n = 100$ Kunden berechnen wir das Durchschnittsalter $\bar{X} = 34,0$ Jahre und die Standardabweichung $s = 7,2$ Jahre
- Wir wählen ein Konfidenzniveau von 95%, also ist $\alpha = 0,05$
- Wir bestimmen $z_{\alpha/2} = 1,96$ mit der Tabelle der Normalverteilung
- Wir erhalten das folgende Konfidenzintervall:

$$34 - 1,96 \frac{7,2}{\sqrt{100}} < \mu < 34 + 1,96 \frac{7,2}{\sqrt{100}} \Rightarrow 32,6 < \mu < 35,4$$

- **Mit einer Wahrscheinlichkeit von 95% liegt das Durchschnittsalter der Grundgesamtheit aller Kunden zwischen 32,6 und 35,4 Jahre**

Wie ändert sich das Konfidenzintervall...

- wenn wir eine größere Stichprobe haben?
- wenn wir sicherer sein wollen, dass der Wert wirklich im Intervall liegt?
- wenn die Standardabweichung größer ist?

Konfidenzintervall: t-Verteilung

Wenn σ unbekannt ist und die Stichprobe klein ($n < 30$), muss anstelle der Normalverteilung die **t-Verteilung** verwendet werden

Die t-Verteilung ähnelt der Normalverteilung (symmetrisch, glockenförmig), aber...

- die Varianz ist größer (und die Kurve flacher)
- sie hängt von den sogenannten **Freiheitsgraden** (degrees of freedom, df) ab; hier gilt: $df = n - 1$ mit n = Stichprobengröße

Mit steigender Stichprobengröße nähert sich die t-Verteilung immer mehr der Normalverteilung an

Wenn das Konfidenzintervall mit der t- statt mit der Normalverteilung berechnet wird, liegt der einzige Unterschied darin, dass wir $t_{\alpha/2}$ anstelle von $z_{\alpha/2}$ verwenden

Konfidenzintervall: t-Verteilung

Berechnung des Konfidenzintervalls für Mittelwerte mit der t-Verteilung:

- Berechnung von $\bar{X}$ und Standardabweichung s aus der Stichprobe
- Wahl des gewünschten Konfidenzniveaus (e.g. 95 %); $\alpha = 1 - \text{Konfidenzniveau}$
- Bestimmung von $t_{\alpha/2}$ aus der Tabelle der t-Verteilung (mit $df = n - 1$)
- Berechnung der unteren und oberen Grenze des Konfidenzintervalls

Mit Wahrscheinlichkeit $1 - \alpha$ liegt der Mittelwert der Grundgesamtheit μ im Intervall

$$\bar{X} - t_{\alpha/2} \frac{s}{\sqrt{n}} < \mu < \bar{X} + t_{\alpha/2} \frac{s}{\sqrt{n}}$$

Beispiel: Wie wäre das Konfidenzintervall für das Durchschnittsalter der Kunden, wenn die Stichprobengröße 25 Personen anstelle von 100 wäre?

- Wir haben wieder $\bar{X} = 34,0$ Jahre, $s = 7,2$ Jahre, Konfidenzniveau = 95%
- Nun haben wir $n = 25$ und $df = 25 - 1 = 24$ Freiheitsgrade
- Wir bestimmen $t_{\alpha/2} = 2,0639$ mit der Tabelle der t-Verteilung ($df = 24$)
- Mit einer Wahrscheinlichkeit von 95% liegt das Durchschnittsalter der Grundgesamtheit aller Kunden im Intervall $31,0 < \mu < 37,0$

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 129

Konfidenzintervall: Übung

Ein Hersteller von Mineralwasser möchte den Natriumgehalt des Wassers bestimmen

Die folgenden Messwerte einer Stichprobe liegen vor (in mg/l) :

112, 104, 116, 109, 111, 117, 112, 110, 112, 108

Bitte bestimmen Sie...

- das Konfidenzintervall für das 95%-Konfidenzniveau
- das Konfidenzintervall für das 99%-Konfidenzniveau

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 130

Kapitel 7

Konfidenzintervalle und Stichprobengrößen

- 1 Konfidenzintervall für Mittelwerte
- 2 Konfidenzintervall für Anteilswerte**
- 3 Minimale Stichprobengröße
- 4 Konfidenzintervall für Regressionskoeffizienten

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 131

Konfidenzintervall für Anteilswerte

Häufig sind wir nicht an Mittelwerten, sondern an **Anteilen** interessiert

Beispiele für Anteilswerte:

- ▶ Welcher Anteil der Kunden, die einen Onlineshop besuchen, kauft etwas?
- ▶ Wieviel Prozent der Stimmen kann eine Partei bei der nächsten Wahl erwarten?

Auch bei der Schätzung eines Anteilswertes kann eine Punktschätzung u.U. nicht ausreichen, dann sollte ein Konfidenzintervall bestimmt werden

Beispiel: Umfrage zwei Wochen vor einer Wahl

- ▶ Punktschätzung: Partei A erhält 5,1% der Stimmen
- ▶ Mögliches Konfidenzintervall: Mit einer Wahrscheinlichkeit von 95% erhält Partei A zwischen 5,0% und 5,2%
- ▶ Nicht zuletzt aufgrund der 5%-Hürde ist das Konfidenzintervall hilfreich (das Ergebnis hätte ebenso ein Konfidenzintervall von 3,1% bis 7,1% sein können, also eine Ungenauigkeit von $\pm 2\%$ statt $\pm 0,1\%$ – wir werden sehen, welche Intervallbreite realistisch ist)

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 132

Konfidenzintervall für Anteilswerte

Notation:

- ▶ p ist der (unbekannte) Anteilswert in der Grundgesamtheit
- ▶ x ist die Anzahl Objekte in der Stichprobe mit der gesuchten Eigenschaft
- ▶ n ist die Stichprobengröße
- ▶ $\hat{p}$ ist der Anteilswert in der Stichprobe, also $\hat{p} = \frac{x}{n}$ ($\hat{p}$ ist eine Punktschätzung von p)

x ist binomialverteilt und, wenn n groß genug ist, näherungsweise normalverteilt (s.o.).

Dann ist $\hat{p}$ näherungsweise normalverteilt mit Mittelwert p und Standardabweichung

$$\sqrt{\frac{p(1-p)}{n}} \approx \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Das **Konfidenzintervall für Anteilswerte** ist dann:

$$\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} < p < \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Beispiel: 95%-Konfidenzintervall für Partei A mit 5,1% Anteil in einer Umfrage mit 1000 Befragten

$$0,051 - 1,96 \sqrt{\frac{0,051(1-0,051)}{1000}} < p < 0,051 + 1,96 \sqrt{\frac{0,051(1-0,051)}{1000}} \rightarrow 0,0373 < p < 0,0646$$

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 133

Konfidenzintervall für Anteilswerte: Übung

Ein Hersteller von Digitalkameras möchte herausfinden, welcher Anteil der Käufer unzufrieden mit einem bestimmten Kameramodell ist

In einer Stichprobe mit 100 Personen sagen 19, dass sie mit der Kamera nicht zufrieden sind

Bitte bestimmen Sie das Konfidenzintervall für das 95%-Konfidenzniveau und diskutieren Sie Ihr Ergebnis

Nehmen Sie nun an, dass die Stichprobengröße 1000 beträgt, und dass 190 der 1000 Personen nicht zufrieden sind mit der Kamera. Wie ändert sich das Konfidenzintervall? Das Konfidenzniveau soll weiterhin 95% betragen.

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 134

Kapitel 7

Konfidenzintervalle und Stichprobengrößen

- 1 Konfidenzintervall für Mittelwerte
- 2 Konfidenzintervall für Anteilswerte
- 3 Minimale Stichprobengröße**
- 4 Konfidenzintervall für Regressionskoeffizienten

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 135

Minimale Stichprobengröße

Vorgehensweise bisher:

- Zunächst Bestimmung der Stichprobengröße n
- Dann Durchführung der Datenerhebung
- Schließlich Berechnung der Güte in Form eines Konfidenzintervalls

Beobachtung aus den letzten Abschnitten:

- Bei kleinen Stichproben erhält man oft große Konfidenzintervalle
- Große Konfidenzintervalle bedeuten, dass die Ergebnisse ungenau sind
- Größere Stichproben führen zu kleineren Konfidenzintervallen und damit zu höherer Genauigkeit

Vorgehensweise in diesem Abschnitt:

- Zunächst wird die gewünschte Größe des Konfidenzintervalls festgelegt (und damit die gewünschte Genauigkeit der Ergebnisse)
- Dann wird die dafür nötige Stichprobengröße n geschätzt
- Dann wird die Erhebung durchgeführt (und bei Bedarf das Konfidenzintervall bestimmt)

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 136

Stichprobengröße: Schätzung von Mittelwerten

Beispiel: Wie groß muss die Stichprobe sein, um das Durchschnittsalter der Grundgesamtheit mit einer Genauigkeit von ± 1 Jahr zu schätzen?

Die Grenzen des Konfidenzintervalls $\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$

können geschrieben werden als $\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$

Die Genauigkeit (oder der Fehlerbereich) ist $E = z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$

Frage: Was ist die minimale Stichprobengröße, die zu einer Genauigkeit von $\pm E$ führt?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 137

Stichprobengröße: Schätzung von Mittelwerten

Wir möchten nun die Genauigkeit E und das Konfidenzniveau festlegen, um dann den erforderlichen Stichprobenumfang n zu berechnen

$$\text{Ansatz: } E = z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \Rightarrow \sqrt{n} = z_{\alpha/2} \frac{\sigma}{E} \Rightarrow n = \left(z_{\alpha/2} \frac{\sigma}{E} \right)^2$$

Der nötige **Stichprobenumfang für Mittelwerte** mit einer Genauigkeit von $\pm E$ ist $n = \left(z_{\alpha/2} \frac{\sigma}{E} \right)^2$

Wenn σ der Grundgesamtheit unbekannt ist, muss es geschätzt werden, etwa auf Basis von s aus einer Stichprobe für eine frühere Studie

Beispiel:

- ▶ Wir möchten das Durchschnittsalter der Kunden mit einer Genauigkeit von ± 1 Jahr schätzen, also $E = 1$
- ▶ Das Konfidenzniveau soll bei 95% liegen, also $z_{\alpha/2} = 1,96$
- ▶ Wir schätzen die Standardabweichung auf $s = 7,2$ Jahre
- ▶ Ergebnis: $n = \left(z_{\alpha/2} \frac{s}{E} \right)^2 = \left(1,96 \frac{7,2}{1} \right)^2 = 199,15 \approx 200$ Personen (aufrunden)

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 138

Stichprobengröße: Schätzung von Anteilswerten

Beispiel: Wie groß muss die Stichprobe sein, wenn wir den Anteil von einer Partei A bei einer Wahl mit einer Genauigkeit von $\pm 0.5\%$ schätzen wollen?

Die Konfidenzintervall-Grenzen für Anteilswerte sind $\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

Die Genauigkeit ist also $E = z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

Der nötige **Stichprobenumfang für Anteilswerte** bei einer Genauigkeit von $\pm E$ ist

$$n = \hat{p}(1-\hat{p}) \left(\frac{z_{\alpha/2}}{E} \right)^2$$

Hinweis: Diese Formel benötigt bereits den Anteilswert aus der Stichprobe, die es ja noch gar nicht gibt. Ausweg:

- ▶ Wenn es z.B. aus einer früheren Studie eine Schätzung für den Anteil gibt, kann diese verwendet werden
- ▶ Ansonsten kann $\hat{p} = 0,5$ verwendet werden. Weshalb ist das sinnvoll?

Stichprobengröße: Übung

Wir wollen eine Umfrage zu den Anteilen der Parteien bei der nächsten Wahl durchführen

Wir können die folgenden Schätzwerte aus früheren Umfragen verwenden:

- ▶ Partei A 40%
- ▶ Partei B 30%
- ▶ Partei C 10%
- ▶ Partei D 5%

Die gewünschte Genauigkeit ist ± 0.005 ($\pm 0.5\%$)

Das gewünschte Konfidenzniveau ist 95%

Wie groß muss die Stichprobe sein?

Kapitel 7

Konfidenzintervalle und Stichprobengrößen

- 1 Konfidenzintervall für Mittelwerte
- 2 Konfidenzintervall für Anteilswerte
- 3 Minimale Stichprobengröße
- 4 Konfidenzintervall für Regressionskoeffizienten**

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 141

Konfidenzintervalle für Regressionskoeffizienten

Frage: Mit welcher Genauigkeit werden die Koeffizienten der linearen Regression geschätzt?

Wir verzichten hier auf eine Formel und übernehmen das von Excel berechnete 95%-Konfidenzintervall für jeden Koeffizienten

Beispiel: Fast-Food-Restaurant (s.o.)

- Punktschätzung: Jeder Radiospot steigert den Umsatz durchschnittlich um 2000 €
- Konfidenzintervall: Die durchschnittliche Umsatzsteigerung durch einen Radiospots liegt zwischen 772 € und 3228 € (mit einer Wahrscheinlichkeit von 95%)

	Koeffizienten	Standardfehler	t-Statistik	P-Wert	Untere 95%	Obere 95%
Schnittpunkt	100,329	11,913	8,422	0,000	72,857	127,801
Radiospots	2,000	0,533	3,754	0,006	0,772	3,228
Radiospots (Konkurrent)	0,007	0,554	0,012	0,991	-1,272	1,285
Special Burger	30,026	10,801	2,780	0,024	5,120	54,933

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 142

Konfidenzintervalle für Regressionskoeffizienten

Übung: Regressionsmodell für Gebrauchtwagenpreise (s.o.)

Ergebnisse aus Excel:

	<i>Koeffizienten</i>	<i>Standardfehler</i>	<i>t-Statistik</i>	<i>P-Wert</i>	<i>Untere 95%</i>	<i>Obere 95%</i>
Schnittpunkt	12515,226	1627,804	7,688	0,000	9185,993	15844,460
km-Stand	-0,016	0,045	-0,347	0,731	-0,108	0,077
PS	95,207	8,977	10,606	0,000	76,848	113,566
Alter	-1713,974	384,816	-4,454	0,000	-2501,011	-926,937
Farbe = silber	-1227,009	1080,331	-1,136	0,265	-3436,535	982,516

Diskutieren Sie die Konfidenzintervalle der Koeffizienten!

Kapitel 8

Hypothesentests

Hypothesentests

Im vorigen Abschnitt war das Ziel, einen Parameter (Mittelwert, Anteil) der Grundgesamtheit zu **schätzen**, hierzu wurden Konfidenzintervalle betrachtet

Beispiel: Mit einer Wahrscheinlichkeit von 95% liegt der Natriumgehalt eines Mineralwassers zwischen 17 und 21 mg/l

Manchmal reicht ein solches Ergebnis nicht: Wir wollen z.B. wissen, ob der Natriumgehalt unter 20 mg/l liegt oder nicht (wenn ja, können wir es als natriumarm kennzeichnen) – wir brauchen also ein Ergebnis der Form ja/nein

Daher wollen wir nun eine Aussage (Hypothese) zu einem Parameter **testen**, um festzustellen, ob sie für die Grundgesamtheit gilt oder nicht (wieder auf Basis einer Stichprobe)

Beispiel:

- Hypothese: Das Wasser ist nicht natriumarm (Natrium nicht unter 20 mg/l)
- Ergebnis: Die Hypothese wird verworfen, das Wasser ist natriumarm

Hypothesen

Eine statistische Hypothese ist eine Behauptung zu einem Parameter der Grundgesamtheit (z.B. Mittelwert, Anteilswert). Sie kann wahr oder falsch sein.

Wir definieren eine Nullhypothese H_0 und eine Gegenhypothese H_1

Je nach Situation besagt die **Nullhypothese** H_0 , dass...

- es keinen Unterschied gibt zwischen einem Parameter und einem Wert
- es keinen Unterschied gibt zwischen zwei Parametern

Die **Gegenhypothese** H_1 sagt, dass H_0 nicht gilt, also dass...

- es einen Unterschied gibt zwischen einem Parameter und einem Wert
- es einen Unterschied gibt zwischen zwei Parametern

Dass Ergebnis eines Hypothesentests ist entweder

- die Nullhypothese wird verworfen (und die Gegenhypothese wird angenommen) oder
- die Nullhypothese wird nicht verworfen

Kapitel 8

Hypothesentests

- 1 **Test für einen Mittelwert**
- 2 Test für einen Anteilswert
- 3 Test für zwei Mittelwerte
- 4 Chi-Quadrat-Tests
- 5 Test für Regressionskoeffizienten
- 6 Fehlerarten

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 147

Auswahl der Verteilung

Bei Hypothesentests für Mittelwerte erfolgt die Auswahl der Verteilung wie bei den Konfidenzintervallen für Mittelwerte:

- ▶ Wir nehmen wieder an, dass die Werte näherungsweise normalverteilt sind
- ▶ Wir nehmen wieder an, dass die Standardabweichung σ der Werte der Grundgesamtheit unbekannt ist (das ist in der Praxis meist der Fall)
- ▶ Dann verwenden wir die sogenannte t-Verteilung, können aber bei größeren Stichproben alternativ auch die Normalverteilung verwenden

Pragmatischer Ansatz für Hypothesentests für Stichprobenmittelwerte:

- ▶ **Kleine Stichprobe** ($n < 30$): Die **t-Verteilung** muss verwendet werden (**t-Test**)
- ▶ **Große Stichprobe** ($n \geq 30$): Die **Normalverteilung** kann verwendet werden (**z-Test**)

Hinweis: Wenn die Verteilung stark von der Normalverteilung abweicht (was in der Praxis vorkommen kann), dann kann man die t- und die Normalverteilung erst bei größeren Stichproben verwenden (dieser Fall wird hier aus Vereinfachungsgründen nicht betrachtet).

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 148

z-Test für einen Mittelwert

Beispiel: Forscher möchten herausfinden, ob ein neues Medikament unerwünschte Nebenwirkungen hat. Sie befürchten insbesondere, dass es zu einer Erhöhung der Pulsfrequenz führt.

Wir nehmen an, dass bekannt ist, dass die durchschnittliche Pulsfrequenz ohne das Medikament bei 70 Schlägen pro Minute liegt.

Daten aus einer Stichprobe mit $n = 40$ Patienten, die das Medikament nehmen:

- Der durchschnittliche Puls in dieser Stichprobe ist $\bar{X} = 74$.
- Die Standardabweichung in dieser Stichprobe ist $s = 9$.

Offensichtlich ist die Pulsfrequenz mit Medikament höher.

- Wenn sie nur wenig erhöht ist, kann es eine zufällige Schwankung sein – wir könnten nicht schlussfolgern, dass tatsächlich eine Nebenwirkung vorliegt.
- Wenn sie aber deutlich erhöht ist, ist es unwahrscheinlich, dass es nur eine zufällige Schwankung ist. Dann würden wir schließen, dass eine Nebenwirkung vorliegt (wir können allerdings nicht ganz sicher sein).

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 149

z-Test für einen Mittelwert

Schritt 1: Hypothesen definieren. Die Nullhypothese ist, dass das Medikament den Puls nicht erhöht, d.h. dass der Puls auch in der Grundgesamtheit der Menschen, die das Medikament nehmen, im Mittel bei 70 liegt. Das kann so aufgeschrieben werden:

- $H_0: \mu = 70$ ("kein Unterschied", "kein Einfluss", hier: kein Puls-Anstieg)
- $H_1: \mu \neq 70$

Aufgrund dieser Nullhypothese können wir nun im weiteren Verlauf mit $\mu = 70$ rechnen.

Schritt 2: Kritischen Wert bestimmen. Wir wählen als Signifikanzniveau $\alpha = 5\%$.

Dies ist die maximale Wahrscheinlichkeit, dass wir ein falsches Testergebnis erhalten, indem wir die Nullhypothese ablehnen, obwohl sie eigentlich wahr ist.

Da $n = 40 > 30$ ist, können wir die Normalverteilung verwenden und bestimmen den kritischen Wert mit Hilfe der Tabelle:

$$z_{kritisch} = 1.6449$$

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 150

z-Test für einen Mittelwert

Schritt 3: Testwert berechnen. Die Teststatistik ist

$$z = \frac{\text{beobachteter} - \text{erwarteter Wert}}{\text{Standardfehler}} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

Wir setzen alle Werte in die Formel ein (und verwenden s anstelle von σ):

$$z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{74 - 70}{9/\sqrt{40}} = 2.811$$

Also ist der Stichprobenmittelwert von 74 etwa 2,811 Standardabweichungen über 70.

Schritt 4: Schlussfolgerung. Wir vergleichen Testwert und kritischen Wert und sehen, dass $z > z_{\text{kritisch}}$ ist. Damit liegt die Teststatistik im kritischen Bereich, und wir verwerfen die Nullhypothese.

Wir schlussfolgern, dass das Medikament den Puls erhöht bei einem Signifikanzniveau von 5% (d.h. die Wahrscheinlichkeit, dass diese Schlussfolgerung falsch ist, beträgt maximal 5%).

z-Test für einen Mittelwert


Idee: Wir definieren eine Nullhypothese, die annimmt, dass es keine Nebenwirkung gibt, dass der Puls also auch mit Medikament im Durchschnitt bei 70 liegt.

Wenn der beobachtete Stichproben-Mittelwert von 74 "deutlich" über 70 (im "kritischen Bereich") liegt, dann verwerfen wir die Nullhypothese und folgern, dass eine Nebenwirkung vorliegt.

"Deutlich" bedeutet: Mehr als z_{kritisch} Standardfehler (also Standardabweichungen des Stichprobenmittelwertes, $\sigma/\sqrt{n}$).

Interpretation: Wenn der echte Mittelwert mit Medikament 70 wäre, dann wäre es sehr unwahrscheinlich (Wahrscheinlichkeit unter 5%), in der Stichprobe 74 zu haben.

Da wir aber 74 beobachtet haben, ist es sehr unwahrscheinlich, dass der tatsächliche Mittelwert bei 70 liegt (und dass es keine Nebenwirkung gibt).



Hypothesentests: Übungen

Übung 1: Wie können wir einen "kritischen Puls" bestimmen, ab dem man in der oben beschriebenen Situation eine Nebenwirkung finden würde?

Übung 2: Ein Institut untersucht Kaffee verschiedener Marken auf Rückstände des Schadstoffs Acrylamid, der beim Rösten entsteht. Laut EU-Verordnung liegt der Referenzwert bei 400 Mikrogramm pro kg Röstkaffee, dieser sollte nicht überschritten werden.

In einer Stichprobe von 36 Packungen einer bestimmten Marke hat sich ein durchschnittlicher Acrylamid-Gehalt von 419 µg/kg ergeben, die Standardabweichung lag bei 51 µg/kg. Lässt sich aus diesen Daten schlussfolgern, dass der durchschnittliche Acrylamid-Gehalt im Kaffee dieser Marke über dem EU-Referenzwert liegt? Bitte führen Sie einen Hypothesentest durch (Signifikanzniveau 5%).

Hypothesentests: p-Wert

Der **p-Wert** ist die Wahrscheinlichkeit, dass man den Stichproben-Wert (oder einen noch extremeren Wert) erhält, wenn die Nullhypothese wahr ist. Je kleiner der p-Wert, desto deutlicher die Hinweise, dass H_0 nicht wahr ist.

Im Beispiel ist der p-Wert die Wahrscheinlichkeit, dass wir einen Durchschnittspuls von mindestens 74 messen, obwohl die Nullhypothese (Puls = 70) wahr ist:

$$p = P(\bar{X} \geq 74 \mid H_0 \text{ ist wahr}) = P(\bar{X} \geq 74 \mid \mu = 70) = P(Z \geq 2,811) = 0,0025$$

Also: Wenn H_0 stimmt und es keine Nebenwirkung gibt, dann erhält man bei 40 Personen einen Durchschnittspuls von mindestens 74 mit einer Wahrscheinlichkeit von nur 0,0025.

Es wäre also sehr unwahrscheinlich, einen Durchschnittspuls von 74 zu messen, wenn es keine Nebenwirkung gibt. Da wir aber tatsächlich 74 gemessen haben, ist es wahrscheinlich, dass H_0 falsch ist und dass eine Nebenwirkung vorliegt.

Wir verwerfen die Nullhypothese, wenn $p < \alpha$ (hier: $0,0025 < 0,05$).

Das ist dasselbe wie das Verwerfen der Nullhypothese bei $z > z_{\text{kritisch}}$.

Hypothesentests: Schlussfolgerungen ziehen

Nun betrachten wir ein anderes Medikament, für das wir in einer Stichprobe (wieder $n = 40$) einen Durchschnittspuls von 71,6 haben. Liegt eine Nebenwirkung vor?

Wir berechnen $z = \frac{71,6-70}{9/\sqrt{40}} = 1,124$. Der Puls von 71,6 ist also weniger als 1,6449 Standardfehler über 70, wir können die Nullhypothese also nicht verwerfen.


Der p-Wert führt natürlich zum selbem Ergebnis:

$$p = P(\bar{X} \geq 71,6 \mid H_0 \text{ wahr}) = P(\bar{X} \geq 71,6 \mid \mu = 70) = P(Z \geq 1,124) = 0,1314 > 0,05$$

Es ist also nicht ganz unwahrscheinlich, dass man einen Durchschnittspuls von 71,6 erhält, wenn H_0 wahr ist. Das würde in mehr als jeder zehnten Stichprobe passieren.

Schlussfolgerung: Können wir daraus schließen, dass H_0 wahr ist und es keine Nebenwirkung gibt, also keine Erhöhung der Pulsfrequenz? Nein! Es gibt ja eine Erhöhung der Pulsfrequenz in der Stichprobe, sie ist nur nicht stark genug, um H_0 zu verwerfen und eine Nebenwirkung anzunehmen. Mit anderen Worten: Der Anstieg ist nicht signifikant.

z-Test für einen Mittelwert: Übersicht




Einseitige und zweiseitige Tests

Rechtsseitiger Test

"größer als", "Anstieg"

$$H_0: \mu = A \quad H_1: \mu > A$$

Der kritische Bereich ist rechts:




Beispiel: Steigt der Puls durch das Medikament?

Linksseitiger Test

"kleiner als", "Senkung"

$$H_0: \mu = A \quad H_1: \mu < A$$

Der kritische Bereich ist links:




Beispiel: Sinkt der Puls durch das Medikament?

Zweiseitiger Test

"ungleich", "Änderung"

$$H_0: \mu = A \quad H_1: \mu \neq A$$

Der kritische Bereich ist auf beide Seiten verteilt:



Beispiel: Ändert sich der Puls durch das Medikament?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 157

t-Test für einen Mittelwert

Wie oben erwähnt, wird der t-Test für Mittelwerte aus kleinen Stichproben verwendet ($n < 30$)

Schritt 1: Die Definition der Hypothesen ist analog zum z-Test

Schritt 2: Der kritische Wert $t_{kritisch}$ wird der Tabelle der t-Verteilung entnommen, wobei $df = n - 1$ Freiheitsgrade berücksichtigt werden (n ist die Stichprobengröße)

Schritt 3: Der Testwert wird berechnet mit $t = \frac{\bar{x} - \mu}{s/\sqrt{n}}$

Schritt 4: Der Vergleich von kritischem Wert und Teststatistik ist analog zum z-Test

Beispiel: Für die Medikament-Studie würde man einen t-Test durchführen, wenn in der Stichprobe nur $n < 30$ Patienten wären

Hinweis: Wenn die Stichprobe klein ist und die Werte (hier: die einzelnen Puls-Werte) nicht annähernd normalverteilt sind, kann dieser Test nicht verwendet werden

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 158

Hypothesentests: Übungen

Übung 1: Bei einem weiteren Medikament wird befürchtet, dass es den Puls ändern könnte. Testen Sie, ob der in einer Stichprobe mit 40 Patienten gemessene Durchschnittspuls von 72,6 eine signifikante Änderung gegenüber dem normalen Durchschnittspuls von 70 bedeutet (wieder $s = 9$ und $\alpha = 5\%$).

Übung 2: Nun betrachten wir noch einmal einen Mineralwasser-Hersteller. Er möchte herausfinden, ob das Wasser natriumarm ist, also weniger als 20 mg Natrium pro Liter enthält. In einer Stichprobe mit 20 untersuchten Flaschen war der Natrium-Durchschnittsgehalt 18,2 mg/l bei einer Stichproben-Standardabweichung von 1,7 mg/l. Bitte führen Sie einen entsprechenden Hypothesentest durch (Signifikanzniveau: 1%).

Kapitel 8

Hypothesentests

- 1 Test für einen Mittelwert
- 2 Test für einen Anteilswert**
- 3 Test für zwei Mittelwerte
- 4 Chi-Quadrat-Tests
- 5 Test für Regressionskoeffizienten
- 6 Fehlerarten

z-Test für einen Anteilswert

In diesem Abschnitt vergleichen wir einen Anteilswert mit einem gegebenen Wert:

- ▶ Rechtsseitiger Test: Ist der Anteilswert größer als ein gegebener Wert?
- ▶ Linksseitiger Test: Ist der Anteilswert kleiner als ein gegebener Wert?
- ▶ Zweiseitiger Test: Ist der Anteilswert verschieden von einem gegebenen Wert?

Wir verwenden wieder die folgende Notation:

- ▶ p ist der (unbekannte) Anteilswert in der Grundgesamtheit
- ▶ x ist die Anzahl Objekte in der Stichprobe mit der gesuchten Eigenschaft
- ▶ n ist die Stichprobengröße
- ▶ $\hat{p}$ ist der Anteilswert in der Stichprobe, also $\hat{p} = \frac{x}{n}$

Wir wenden einen z-Test an

- ▶ Er basiert auf der Approximation der Binomial- durch die Normalverteilung
- ▶ Der Test kann nur angewendet werden, wenn $n \cdot \hat{p} \geq 5$ und $n \cdot (1 - \hat{p}) \geq 5$ gilt

Beispiel: In einer Stichprobe mit 1000 Personen haben 5.6% gesagt, dass sie Partei A wählen würden. Reicht das aus, um bei einem Signifikanzniveau von 5% zu sagen, dass die Partei über die 5%-Hürde und damit ins Parlament kommt?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 161

z-Test für einen Anteilswert

Schritt 1: Rechtsseitiger Test (über der 5%-Hürde).

$H_0: p = 0,05$ und $H_1: p > 0,05$

Schritt 2: Für das 5%-Signifikanzniveau erhalten wir $z_{kritisch} = 1,6449$
(für Anteilswerte nehmen wir immer die Normalverteilung)

Schritt 3: Teststatistik: $z = \frac{\text{beobachtet} - \text{erwartet}}{\text{Standardfehler}} = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}}$

Gemäß Nullhypothese verwenden wir $p = 0,05$, damit erhalten wir

$$z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} = \frac{0,056 - 0,05}{\sqrt{\frac{0,05(1-0,05)}{1000}}} = 0,8706$$

Schritt 4: Wegen $z < z_{kritisch}$ ist z nicht im kritischen Bereich.

Wir können die Nullhypothese nicht verwerfen, die Partei ist also nicht signifikant über der 5%-Hürde.

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 162

z-Test für einen Anteilswert: Übung

Ein Unternehmen stellt eine Espressomaschine her. Aufgrund häufiger Reklamationen in der Vergangenheit wurde die Produktqualität verbessert. Das Unternehmen möchte nun untersuchen, ob die Reklamationsquote unter den Zielwert gesunken ist.

In einer Zufallsstichprobe von 400 Bestellungen wurden 11 Reklamationen festgestellt. Gibt es statistische Belege auf dem 5%-Signifikanzniveau dafür, dass die Reklamationsquote nun unter 4% liegt?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 163

Kapitel 8

Hypothesentests

- 1 Test für einen Mittelwert
- 2 Test für einen Anteilswert
- 3 Test für zwei Mittelwerte**
- 4 Chi-Quadrat-Tests
- 5 Test für Regressionskoeffizienten
- 6 Fehlerarten

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 164

Test für zwei Mittelwerte

In Abschnitt 8.1 haben wir Tests der folgenden Art betrachtet:

- › Ist der Mittelwert der Stichprobe signifikant größer/kleiner als ein bestimmter gegebener Wert?
- › Beispiel: Ist der Natriumgehalt signifikant kleiner als 20 mg/l?

In diesem Abschnitt vergleichen wir zwei Stichproben:

- › Sind die Mittelwerte der beiden Stichproben signifikant unterschiedlich?
- › Beispiel: Enthält Mineralwasser A signifikant weniger Natrium als Mineralwasser B?

Der Einfachheit halber betrachten wir in diesem Abschnitt...

- › nur Stichproben mit $n \geq 30$ und nur den z-Test (und nicht den t-Test)
- › nur Stichproben-Mittelwerte (und keine Anteile bzw. Prozentwerte)

Test für zwei Mittelwerte

Der allgemeine Ansatz ist wieder $Testwert = \frac{beobachtet - erwartet}{Standardfehler}$

Der beobachtete Wert ist nun die Differenz der beiden Stichproben-Mittelwerte, und der erwartete Wert ist die Differenz der Grundgesamtheits-Mittelwerte (gemäß Nullhypothese). Mit einer geeigneten Formel für die Standardabweichung erhalten wir für $n \geq 30$ die Teststatistik

$$z = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

Die Nullhypothese besagt immer, dass es keinen Unterschied gibt (also $H_0: \mu_1 = \mu_2$), daher gilt

$$z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

Test für zwei Mittelwerte: Anwendung

Wir betrachten kostenlose Smartphone-Spiele mit In-App-Käufen für zusätzliche Level, zusätzliche Leben usw.

Ein Unternehmen hat zwei Bezahlmodelle entwickelt und möchte wissen, welches besser ist.

Einige Spieler haben Bezahlmodell 1, andere Bezahlmodell 2. Von beiden Gruppen wird jeweils eine Stichprobe genommen. Im Durchschnitt geben die Spieler mit Modell 1 mehr aus als die mit Modell 2.

Das Unternehmen möchte wissen, ob der Unterschied zwischen den Bezahlmodellen signifikant ist.



Beispiel für In-App-Käufe

Test für zwei Mittelwerte

Wir möchten die durchschnittlichen Gesamtbeträge je Spieler der beiden Bezahlmodelle vergleichen. Gibt es einen signifikanten Unterschied?

Wir haben die folgenden Daten aus den Stichproben:

- Modell 1: $n_1 = 100$ Beobachtungen (Spieler), $\bar{X}_1 = 5,40$ €, $s_1 = 3,25$
- Modell 2: $n_2 = 100$ Beobachtungen (Spieler), $\bar{X}_2 = 4,81$ €, $s_2 = 2,63$

Schritt 1: Zweiseitiger Test, $H_0: \mu_1 = \mu_2$ und $H_1: \mu_1 \neq \mu_2$

Schritt 2: σ_1, σ_2 unbekannt, aber $n_1, n_2 \geq 30$, wir verwenden die Normalverteilung. Wir wählen ein Signifikanzniveau von 5%, zweiseitig, also $z_{kritisch} = \pm 1,96$.

Schritt 3: Teststatistik:
$$z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} = \frac{5,40 - 4,81}{\sqrt{\frac{3,25^2}{100} + \frac{2,63^2}{100}}} = 1,41$$

Schritt 4: z ist nicht im kritischen Bereich, H_0 nicht verwerfen. Kein signifikanter Unterschied zwischen den Bezahlmodellen.

Test für zwei Mittelwerte: Übung

Ein Online-Händler prüft, ob eine Erhöhung des Mindestbestellwerts für kostenlosen Versand den durchschnittlichen Bestellwert erhöht. Hierzu wird über einen Zeitraum von zwei Wochen ein Test durchgeführt: Besucher des Online-Shops werden zufällig entweder dem bisherigen oder dem erhöhten Mindestbestellwert zugeordnet. Betrachtet werden nur Besucher, die tatsächlich eine Bestellung aufgegeben haben.

In einer Stichprobe von 200 Bestellungen mit dem bisherigen Mindestbestellwert ergab sich ein durchschnittlicher Bestellwert von 56,70 € bei einer Standardabweichung von 18,58 €.

In einer weiteren Stichprobe von 200 Bestellungen mit dem erhöhten Mindestbestellwert ergab sich ein durchschnittlicher Bestellwert von 60,51 € bei einer Standardabweichung von 17,20 €.

- a) Untersuchen Sie mithilfe eines geeigneten Hypothesentests auf dem, ob der durchschnittliche Bestellwert durch die Anpassung signifikant erhöht wird (Signifikanzniveau 5%).
- b) Angenommen, in Teil a) ergibt sich ein statistisch signifikanter Anstieg. Bedeutet dies zwangsläufig, dass die Erhöhung des Mindestbestellwerts wirtschaftlich sinnvoll ist? Begründen Sie Ihre Antwort.

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 169

Kapitel 8

Hypothesentests

- 1 Test für einen Mittelwert
- 2 Test für einen Anteilswert
- 3 Test für zwei Mittelwerte
- 4 Chi-Quadrat-Tests**
- 5 Test für Regressionskoeffizienten
- 6 Fehlerarten

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 170

χ^2 -Unabhängigkeitstest

Zwei Versionen (A und B) eines Online-Banners wurden mit je 1200 Personen getestet. Hat Version B signifikant mehr Klicks erhalten oder ist der Unterschied nur zufallsbedingt?

Beobachtet O_i	A	B	gesamt
Klick	194	232	426
kein Klick	1006	968	1974
gesamt	1200	1200	2400

Wenn es keinen Unterschied zwischen den Bannern gibt, wären gleichviele Klicks zu erwarten:

Erwartet E_i	A	B
Klick	213	213
kein Klick	987	987

Ist die Abweichung groß genug, um zu sagen, dass Banner B mehr Klicks erhält als Banner A?

Der χ^2 -Unabhängigkeitstest untersucht, ob zwei Variable (hier: "Banner-Version" und "Klicks") unabhängig sind oder ob es eine Abhängigkeit zwischen beiden gibt.

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 171

χ^2 -Unabhängigkeitstest

Schritt 1: H_0 : Die Variablen sind unabhängig.
 H_1 : Die Variablen sind abhängig.

Banner-Beispiel:

H_0 : Das Banner-Design beeinflusst die Klicks nicht.
 H_1 : Das Banner-Design beeinflusst die Klicks.

Schritt 2: Wir wählen ein Signifikanzniveau α .
Wir verwenden die (bisher noch nicht betrachtete) χ^2 -Verteilung.
Die Zahl der Freiheitsgrade ist $df = (k_1 - 1)(k_2 - 1)$, dabei ist k_i die Anzahl der Ausprägungen von Variable i .
Aus der χ^2 -Tabelle entnehmen wir $\chi^2_{kritisch}$.

Beispiel:

Wir wählen $\alpha = 0,05$. Mit zwei Banner-Versionen und zwei Ausprägungen für Klicks (ja/nein) ist $df = (2 - 1)(2 - 1) = 1$, und wir erhalten aus der Tabelle $\chi^2_{kritisch} = 3,8415$.

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 172

χ^2 -Unabhängigkeitstest

Schritt 3: Erwartete Häufigkeiten E_i bestimmen (der Test ist nur anwendbar, wenn alle $E_i \geq 5$ sind). Nun Testwert berechnen:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

Beispiel:

$$E_1 = 2400 \cdot \frac{426}{2400} \cdot \frac{1200}{2400} = 213 \text{ usw., es sind alle } E_i \geq 5,$$

$$\chi^2 = \frac{(194-213)^2}{213} + \frac{(232-213)^2}{213} + \frac{(1006-987)^2}{987} + \frac{(968-987)^2}{987} = 4,121.$$

Schritt 4: Wenn $\chi^2 > \chi_{\text{kritisch}}^2$, dann liegt der Testwert im kritischen Bereich, und wir lehnen die Nullhypothese ab.

Beispiel:

$\chi^2 > \chi_{\text{kritisch}}^2$, der Testwert liegt im kritischen Bereich, so dass wir die Nullhypothese ablehnen. Der Unterschied zwischen Banner A und Banner B im Hinblick auf Klicks ist signifikant.

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 173

χ^2 -Unabhängigkeitstest

Praxisbezug: Ein **A/B-Test** vergleicht zwei Varianten einer Maßnahme oder Gestaltung anhand zufällig aufgeteilter Gruppen A und B, um festzustellen, ob sich ihre Wirkung signifikant unterscheidet. Der Begriff wird vor allem im Online-Marketing und in der digitalen Produktentwicklung verwendet. Beispiele sind die hier dargestellten Tests der Wirkung von Banner-Designs, Mindestbestellwerten in Online-Shops oder Bezahlmodellen in Spielen.

Weitere Anwendung: Produktzugaben werden häufig zur Absatzsteigerung eingesetzt

- Es ist oft schwer, den tatsächlichen Nutzen von Zugaben zu ermitteln
- Einfache Methode zum Testen des Einflusses einer Zugabe: Choice-Experiment mit zwei Gruppen von Befragten, Auswertung mit χ^2 -Test



Wirtschaftsstatistik 2026 | © Sönke Hartmann | 174

χ^2 -Unabhängigkeitstest: Produktzugaben

In **Gruppe A** wählten 63 Personen zwischen den folgenden Bier-Angeboten (gleicher Preis):

- Warsteiner (24 Flaschen)
- Beck's (24 Flaschen)

In **Gruppe B** wählten 57 Personen zwischen den folgenden Bier-Angeboten (gleicher Preis):

- Warsteiner (24 Flaschen)
- Beck's (24 Flaschen) mit einem kostenlosen Bierglas als Zugabe

Die Ergebnisse der Befragung (Echtdaten) waren:

	Gruppe A	Gruppe B
Warsteiner	35	25
Beck's	28	32

Übung: Ermitteln Sie mit einem χ^2 -Unabhängigkeitstest, ob das Glas als Zugabe einen signifikanten Einfluss auf die Markenwahl hatte ($\alpha = 0,05$).

χ^2 -Anpassungstest

Manchmal möchte man wissen, ob Daten einer bestimmten Verteilung folgen.

Empirische Daten folgen einer Verteilung i.d.R. nicht perfekt, deshalb benötigen wir einen Hypothesentest, der entscheidet, ob die Abweichungen zwischen Daten und Verteilung evtl. so groß sind, dass man nicht sagen kann, dass die Daten der Verteilung folgen.

Auf diese Weise können wir überprüfen, ob empirische Daten z.B. gleich- oder Benford-verteilt sind (auch die Normalverteilung ließe sich prüfen, dies wird hier jedoch nicht betrachtet)

Dieser Test basiert ebenfalls auf der χ^2 -Verteilung

Ansatz des χ^2 -Anpassungstests:

- Die Nullhypothese besagt, dass die betrachtete Verteilung gilt
- Wenn die Daten zu stark von dieser Verteilung abweichen, verwerfen wir die Nullhypothese und schließen, dass die Verteilung nicht gilt

χ^2 Anpassungstest

Für einen Würfel liegen die folgenden Beobachtungen vor. Ist er fair?

	1	2	3	4	5	6
beobachtete Häufigkeit O_i	24	32	28	24	30	42

Wenn der Würfel fair ist, müsste die Gleichverteilung vorliegen, also

$$P(X = 1) = \frac{1}{6} \quad P(X = 2) = \frac{1}{6} \quad \text{usw.}$$

Bei Gleichverteilung wäre also zu erwarten:

	1	2	3	4	5	6
erwartete Häufigkeit E_i	30	30	30	30	30	30

Ist die Abweichung von der Gleichverteilung groß genug, um zu sagen, dass der Würfel nicht fair ist?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 177

χ^2 Anpassungstest

Schritt 1: H_0 : Die betrachtete Verteilung gilt.
 H_1 : Die betrachtete Verteilung gilt nicht.

Würfel-Beispiel:

H_0 : Die Gleichverteilung gilt, hier also $P(X = i) = \frac{1}{6}$ für $i = 1, \dots, 6$
 H_1 : Die Gleichverteilung gilt nicht (d.h. der Würfel ist nicht fair)

Schritt 2: Wir wählen ein Signifikanzniveau α . Die Zahl der Freiheitsgrade entspricht der Anzahl verschiedener Werte minus 1, also $df = k - 1$ (das gilt für die Gleich- und die Benford-Verteilung). Aus der χ^2 -Tabelle bestimmen wir $\chi^2_{kritisch}$.

Beispiel:

Wir wählen $\alpha = 0,05$.

Mit $k = 6$ verschiedenen Zahlen auf dem Würfel und

$df = k - 1 = 6 - 1 = 5$ erhalten wir aus der Tabelle $\chi^2_{kritisch} = 11,07$.

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 178

χ^2 Anpassungstest

Schritt 3: Erwartete Häufigkeiten: $E_i = n \cdot P(X = X_i)$ mit $n = \sum_{i=1}^k O_i$.
Der Test ist nur anwendbar, wenn alle $E_i \geq 5$ sind.

Testwert:
$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

Beispiel:

$n = 24 + 32 + \dots = 180$ und $E_1 = E_2 = \dots = 180 \cdot \frac{1}{6} = 30$ (≥ 5).

$$\chi^2 = \frac{(24-30)^2}{30} + \frac{(32-30)^2}{30} + \dots = 7,47$$

Schritt 4: Wenn $\chi^2 > \chi_{kritisch}^2$, dann liegt der Testwert im kritischen Bereich, und wir lehnen die Nullhypothese ab.

Beispiel:

$\chi^2 < \chi_{kritisch}^2$, der Testwert liegt nicht im kritischen Bereich, so dass wir die Nullhypothese nicht ablehnen. Es gibt keine ausreichenden Hinweise darauf, dass der Würfel nicht fair ist.

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 179

χ^2 Anpassungstest

Anwendung: Eine Bilanz soll auf mögliche Manipulation untersucht werden.
Die folgende Tabelle enthält die Häufigkeiten der führenden Ziffern der Bilanz:

Ziffer	1	2	3	4	5	6	7	8	9
Häufigkeit	87	59	33	60	27	35	42	26	21

Übung: Führen Sie einen χ^2 -Anpassungstest durch, um zu prüfen, ob die Bilanz signifikant von der Benford-Verteilung abweicht ($\alpha = 0,01$)

Was wären die Konsequenzen eines solchen Tests, wenn...

- ... die Nullhypothese verworfen wird?
- ... die Nullhypothese nicht verworfen wird?

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 180

Kapitel 8

Hypothesentests

- 1 Test für einen Mittelwert
- 2 Test für einen Anteilswert
- 3 Test für zwei Mittelwerte
- 4 Chi-Quadrat-Tests
- 5 Test für Regressionskoeffizienten**
- 6 Fehlerarten

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 181

Hypothesentest für Regressionskoeffizienten

Frage: Hat eine unabhängige Variable x_j wirklich einen signifikanten Einfluss auf y ?
Mit anderen Worten: Ist ein Koeffizient β_j tatsächlich ungleich 0?

Wir wenden einen Hypothesentest (zweiseitigen t-Test) auf jeden Koeffizienten β_j an
(jeder Koeffizient β_j wird mit denselben kritischen Werten getestet)

Schritt 1: $H_0: \beta_j = 0$ ("kein Einfluss"), $H_1: \beta_j \neq 0$

Schritt 2: Bestimmung von $t_{kritisch}$: Wir wählen ein Signifikanzniveau (z.B. $\alpha = 0,05$)
und bestimmen die Freiheitsgrade mit $df = n - k - 1$
(n = Anzahl Beobachtungen, k = Anzahl unabhängige Variable)

Schritt 3: Der t -Wert des jeweiligen Koeffizienten wird dem Excel-Output entnommen

Schritt 4: wenn $|t| > t_{kritisch}$ ist, verwerfen wir die Nullhypothese und schließen, dass der Koeffizient signifikant ist (also signifikanter Einfluss von Variable x_j auf y)

Bei der Interpretation eines Koeffizienten sollte berücksichtigt werden, ob er signifikant ist!

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 182

Hyothesentest für Regressionskoeffizienten

Restaurant-Beispiel (s.o.): Haben die Radiospots einen signifikanten Einfluss auf den Umsatz?

Schritt 1: H_0 : echter Radiospot-Koeffizient $\beta_1 = 0$, H_1 : $\beta_1 \neq 0$ (zweiseitig)

Schritt 2: Mit $\alpha = 0,05$ und $df = 12 - 3 - 1 = 8$ ist $t_{\text{kritisch}} = \pm 2,3060$

Schritt 3: Ablesen des t -Werts in Excel: Für die Radiospots ist $t = 3,754$

Schritt 4: Schlussfolgerung: $t > t_{\text{kritisch}}$, also H_0 verwerfen.
Die Radiospots haben einen signifikanten Einfluss auf den Umsatz.

	Koeffizienten	Standardfehler	t-Statistik	P-Wert	Untere 95%	Obere 95%
Schnittpunkt	100,329	11,913	8,422	0,000	72,857	127,801
Radiospots	2,000	0,533	3,754	0,006	0,772	3,228
Radiospots (Konkurrent)	0,007	0,554	0,012	0,991	-1,272	1,285
Special Burger	30,026	10,801	2,780	0,024	5,120	54,933

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 183

Hyothesentest für Regressionskoeffizienten

Wir können auch die ebenfalls von Excel ausgegebenen **p-Werte** ansehen

Excel geht von einem zweiseitigen Test aus, also von zwei kritischen Bereichen

Restaurant-Beispiel: Der p-Wert von 0,006 für die Radiospots bedeutet, dass – wenn die Nullhypothese, das die Radiospots keinen Einfluss haben, wahr wäre – die Wahrscheinlichkeit, einen Wert von 2,000 für die Radiospots zu erhalten, 0,006 betragen würde

Das wäre sehr unwahrscheinlich ($0.006 < 0.05$), also gehen wir davon aus, dass die Nullhypothese nicht wahr ist und die Radiospots einen Einfluss haben

	Koeffizienten	Standardfehler	t-Statistik	P-Wert	Untere 95%	Obere 95%
Schnittpunkt	100,329	11,913	8,422	0,000	72,857	127,801
Radiospots	2,000	0,533	3,754	0,006	0,772	3,228
Radiospots (Konkurrent)	0,007	0,554	0,012	0,991	-1,272	1,285
Special Burger	30,026	10,801	2,780	0,024	5,120	54,933

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 184

Hythesentest für Regressionskoeffizienten

Übung: Regressionsmodell für Preise von $n = 34$ Gebrauchtwagen (s.o.)

Ergebnisse aus Excel:

	<i>Koeffizienten</i>	<i>Standardfehler</i>	<i>t-Statistik</i>	<i>P-Wert</i>	<i>Untere 95%</i>	<i>Obere 95%</i>
Schnittpunkt	12515,226	1627,804	7,688	0,000	9185,993	15844,460
km-Stand	-0,016	0,045	-0,347	0,731	-0,108	0,077
PS	95,207	8,977	10,606	0,000	76,848	113,566
Alter	-1713,974	384,816	-4,454	0,000	-2501,011	-926,937
Farbe = silber	-1227,009	1080,331	-1,136	0,265	-3436,535	982,516

Welche der unabhängigen Variablen haben einen signifikanten Einfluss auf den Preis?
Bitte wählen Sie $\alpha = 0.05$.

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 185

Kapitel 8

Hypothesentests

- 1 Test für einen Mittelwert
- 2 Test für einen Anteilswert
- 3 Test für zwei Mittelwerte
- 4 Chi-Quadrat-Tests
- 5 Test für Regressionskoeffizienten

6 Fehlerarten

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 186

Hypothesentests: Fehlerarten

Beim Testen einer Hypothese können zwei unterschiedliche Fehler auftreten:

	H_0 ist wahr	H_0 ist falsch
H_0 verwerfen	Fehler 1. Art Die Nullhypothese ist wahr, aber wir verwerfen sie	korrekt
H_0 nicht verwerfen	korrekt	Fehler 2. Art Die Nullhypothese ist falsch, aber wir verwerfen sie nicht

Natürlich können wir nicht wissen, ob wir einen Fehler machen, da wir ja nicht wissen, ob die Hypothese wahr ist (sonst würden wir ja keinen Test machen)!

Wahrscheinlichkeiten der Fehlerarten: $P(\text{Fehler 1. Art}) = \alpha$ und $P(\text{Fehler 2. Art}) = \beta$

- › Indem wir das Signifikanzniveau wählen (z.B. $\alpha = 0,05$), begrenzen wir die Wahrscheinlichkeit für einen Fehler 1. Art, also für das Verwerfen einer wahren H_0
- › Wenn wir ein kleineres α wählen, reduzieren wir die Wahrscheinlichkeit für einen Fehler 1. Art, erhöhen aber gleichzeitig die Wahrscheinlichkeit für einen Fehler 2. Art

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 187

Hypothesentests: Fehlerarten

Beispiel 1: Test eines Medikaments auf Nebenwirkungen

Nullhypothese: Das untersuchte Medikament hat keine Nebenwirkung

	H_0 ist wahr Es gibt keine Nebenwirkung	H_0 ist falsch Es gibt eine Nebenwirkung
H_0 verwerfen Wir finden eine Nebenwirkung	Fehler 1. Art Wir finden eine Nebenwirkung, die gar nicht existiert	korrekt
H_0 nicht verwerfen Wir finden keine Nebenwirkung	korrekt	Fehler 2. Art Wir finden eine existierende Nebenwirkung nicht

Je kleiner α , desto seltener wird man eine Nebenwirkung feststellen

- › Dann wird man seltener eine Nebenwirkung feststellen, die gar nicht existiert
- › Aber man wird auch seltener eine Nebenwirkung feststellen, die tatsächlich existiert

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 188

Hypothesentests: Fehlerarten


Beispiel 2: Gerichtsprozess

Nullhypothese: Der Angeklagte ist unschuldig

	H₀ ist wahr Der Angeklagte ist unschuldig	H₀ ist falsch Der Angeklagte ist schuldig
H₀ verwerfen Wir verurteilen den Angeklagten	Fehler 1. Art Ein unschuldiger Angeklagter wird verurteilt	korrekt
H₀ nicht verwerfen Wir lassen den Angeklagten frei	korrekt	Fehler 2. Art Ein schuldiger Angeklagter wird freigelassen

Wirtschaftsstatistik 2026 | © Sönke Hartmann | 189

Hypothesentests: Überblick



© Sönke Hartmann | 190