

Wirtschaftsstatistik

Zusatzmaterial

INHALT

Übungen: Deskriptive Statistik	2
Übungen: Korrelation und Regression	3
Übungen: Wahrscheinlichkeiten und Kombinatorik	5
Übungen: Diskrete Wahrscheinlichkeitsverteilungen	7
Übungen: Stetige Wahrscheinlichkeitsverteilungen	8
Übungen: Konfidenzintervalle und Stichprobengröße	10
Übungen: Hypothesentests	11
Klausur A	14
Klausur B	16
Lösungen zu den Übungen	18
Lösungen zu den Klausuren	27
Statistische Tabellen	29
Formeln	31

Übungen: Deskriptive Statistik

1. **Einkommen.** Im Rahmen einer Marktforschungsstudie wird das Kaufverhalten der Käuferinnen und Käufer einer bestimmten Marke untersucht. Die befragten Personen wurden unter anderem gebeten, ihr monatliches Einkommen anzugeben. Die Ergebnisse sind (in € pro Monat):

800	1200	2600	1900	2300	3200	2200	1900
-----	------	------	------	------	------	------	------

- a) Bitte berechnen Sie den Mittelwert, den Median und den Modus.
- b) Nun fällt auf, dass bei der Berechnung eine Person mit einem Einkommen von 8000 € vergessen wurde. Wie ändern sich die Ergebnisse?
2. **Biermarken.** In einer Marktforschungsstudie wurden zwei Biermarken untersucht. Ein Ziel war, das Alter der Personen, die die Marke A bzw. B bevorzugen, zu vergleichen. Die folgende Tabelle zeigt die erhobenen Altersangaben. Bitte berechnen Sie für jede der beiden Marken Durchschnittsalter, Spannweite, Standardabweichung und Quartile. Prüfen Sie beide Datensätze außerdem auf Ausreißer.

Marke A	19	26	48	27	29	37	34	27
Marke B	56	27	22	29	38	32	41	47

3. **Kaffeekonsum.** Eine Befragung von 239 Personen hat ergeben, dass Haushalte monatlich im Durchschnitt 28,24 € für Kaffee zum häuslichen Konsum ausgeben. Leider wurde die Angabe einer weiteren Person in Höhe von 45 € übersehen und muss noch berücksichtigt werden. Wie hoch ist der korrigierte Durchschnittswert?
4. **Paketdienstleister.** Ein Paketdienstleister möchte die Servicequalität untersuchen und hat hierzu eine Stichprobe von Paketsendungen genommen. Zunächst wird die Auslieferungszeit betrachtet, die Daten sind der folgenden Tabelle zu entnehmen. Bitte bestimmen Sie die durchschnittliche Auslieferungszeit, den Median, den Modus und die Standardabweichung.

Lieferzeit (in Tagen)	1	2	3	4	5
Anzahl Pakete	47	123	51	16	3

Übungen: Korrelation und Regression

1. **Ernährung und Lebenserwartung.** Einige Studien haben eine negative Korrelation zwischen Lebenserwartung und Fleischkonsum ergeben. Bedeutet das, dass jeder Vegetarier werden sollte, um länger zu leben? Diskutieren Sie den Zusammenhang beider Variablen.
2. **Gehalt und Produktivität.** Es besteht eine Korrelation zwischen höheren Gehältern und höherer Produktivität. Lässt sich daraus schließen, dass höhere Gehälter direkt zu höherer Produktivität führen?
3. **Attraktivität und Gehalt.** Es gibt Studien, die zeigen, dass sich ein attraktives Aussehen positiv auf das Gehalt auswirkt, siehe z. B. Pfeifer, C. (2012): Physical attractiveness, employment and earnings. *Applied Economics Letters* 19(6): 505-510. Wesentliches Ergebnis dieses Papers: "More attractive people are on average more likely to (...) earn on average higher wages. The effects are statistically significant and quite sizeable".

Wir betrachten ein stark vereinfachtes (und fiktives) Beispiel. Von den 1200 Personen in einer Stichprobe ist jeweils das Bruttomonatseinkommen (in €) bekannt; ebenso ist bekannt, ob eine Person einen Hochschulabschluss hat (Dummy-Variable mit 0=nein und 1=ja). Schließlich ist die Attraktivität der jeweiligen Person bekannt; diese wurde auf einer Skala von 0 (sehr unattraktiv) bis 12 (sehr attraktiv) vom Interviewer eingeschätzt. Es wurde eine lineare Regression gerechnet, dabei waren Attraktivität und Hochschulabschluss die unabhängigen Variablen und Einkommen die abhängige Variable. Die folgende Tabelle zeigt einen Ausschnitt der mit Excel erhaltenen Ergebnisse.

Regressions-Statistik		Koeffizienten		t-Statistik
Multipler Korrelationskoeffizient	0,4903	Schnittpunkt	2218,22	32,51
Bestimmtheitsmaß	0,2404	Attraktivität	56,92	2,93
Beobachtungen	1200	Hochschulabschluss	401,34	10,25

- a) Bitte erläutern Sie die Koeffizienten.
 - b) Haben Attraktivität und Hochschulabschluss einen signifikanten¹ Einfluss auf das Gehalt ($\alpha = 5\%$)?
 - c) Um wie viele Punkte müsste die Attraktivität im Durchschnitt steigen, um denselben Gehaltseffekt zu erzielen wie ein Hochschulabschluss?
 - d) Bitte bestimmen Sie das Residuum für eine Person der Stichprobe mit einem Einkommen von 2889,20 €, die einen Hochschulabschluss hat und deren Attraktivität mit 8 Punkten bewertet wurde.
 - e) Weshalb ist das Bestimmtheitsmaß relativ gering?
4. **Signifikanz.** Es wurde eine Regressionsfunktion der Form $\hat{y} = a_1x_1 + a_2x_2 + b$ ermittelt. Angenommen, a_1 ist signifikant¹, und es gilt $a_2 > a_1$. Bedeutet das, dass auch a_2 signifikant ist? Begründen Sie Ihre Antwort.
 5. **Koeffizient.** Gegeben ist die geschätzte Regressionsgleichung $\hat{y} = 6,52 - 0,23x$. Was lässt sich aus dem Koeffizienten von x folgern?
 - ☐ Der Korrelationskoeffizient von X und Y ist negativ.
 - ☐ Das Bestimmtheitsmaß ist negativ.
 - ☐ Die Prognosegüte des Regressionsmodells ist gering.
 - ☐ Der Koeffizient von x ist nicht signifikant.
 - ☐ Wenn x um eine Einheit steigt, sinkt $\hat{y}$ um 23%.

¹Hierfür werden Inhalte aus dem Kapitel zu Hypothesentests benötigt.

6. **Berechnungen.** Für zwei Variablen X und Y sind die folgenden Beobachtungen gegeben. Bitte berechnen Sie den Korrelationskoeffizienten. Führen Sie dann eine Regressionsanalyse durch, wobei X die unabhängige Variable ist. Bestimmen Sie die Regressionsgleichung, die Residuen und das Bestimmtheitsmaß. Zeichnen Sie schließlich die Beobachtungen und die Regressionsgerade in ein Koordinatensystem ein.

x_i	6	7	9	10
y_i	112	128	134	142

7. **Absatzentwicklung.** Ein Unternehmen analysiert die Absatzentwicklung eines bestimmten Produkts. Hierzu wurden die Absatzzahlen (verkaufte Stückzahlen) der zurückliegenden Monate mit Hilfe der linearen Regression untersucht. Der Datensatz enthält jeweils die Nummer des Monats als unabhängige Variable (beginnend bei 1 für den ersten Monat des ausgewerteten Zeitraums) und die in diesem Monat verkaufte Stückzahl als abhängige Variable. Die Ergebnisse der Regression sind wie folgt:

<i>Regressions-Statistik</i>		<i>Koeffizienten t-Statistik</i>		
Multipler Korrelationskoeffizient	0,7649	Schnittpunkt	20138,86	24,13
Bestimmtheitsmaß	0,5851	X Variable 1	72,61	4,22
Adjustiertes Bestimmtheitsmaß	0,5662			
Standardfehler	334,0302			
Beobachtungen	24			

- Aus wie vielen Jahren sind Daten in die Stichprobe eingegangen?
- Bitte stellen Sie die Gleichung der Regressionsgerade auf und geben Sie eine kurze, präzise Interpretation des Koeffizienten der unabhängigen Variable an.
- Im 8. Monat des Beobachtungszeitraums lag der tatsächliche Absatz bei 20.407 Stück. Bitte bestimmen Sie das zugehörige Residuum.

Übungen: Wahrscheinlichkeiten und Kombinatorik

1. **Lotterie.** Auf einer Party wird eine Lotterie veranstaltet. Es gibt 200 Lose, davon sind 5 Hauptgewinne, 45 Trostpreise und 150 Nieten. Mit welcher Wahrscheinlichkeit erhält man...
 - a) ...einen Hauptgewinn oder einen Trostpreis, wenn man ein Los kauft?
 - b) ...zwei Nieten, wenn man zwei Lose kauft?
 - c) ...keinen Hauptgewinn, wenn man zwei Lose kauft?
 - d) ...zuerst einen Trostpreis und dann einen Hauptgewinn, wenn man nacheinander zwei Lose kauft?
 - e) ...eine Niete und einen Hauptgewinn, wenn man zwei Lose kauft?
 - f) ...mindestens einen Hauptgewinn, wenn man drei Lose kauft?
2. **Kniffel.** Im folgenden wird das Spiel Kniffel (oder auch Yahtzee) betrachtet. Dabei werden fünf Würfel geworfen. Wie hoch ist die Wahrscheinlichkeit für...
 - a) ...einen Kniffel (alle 5 Würfel zeigen dieselbe Augenzahl) in einem Wurf, also ohne einen oder mehrere Würfel noch einmal zu werfen?
 - b) ...zwei Kniffel nacheinander, jeweils in einem Wurf?
 - c) ...einen Viererpasch (viermal dieselbe Augenzahl und eine andere) in einem Wurf?
 - d) ...ein Full House (eine Augenzahl auf drei Würfeln und eine andere auf zwei Würfeln) in einem Wurf?
3. **Telefonnummern.** In einer bestimmten deutschen Stadt bestehen die Telefonnummern aus sechs Ziffern. Die erste Ziffer darf keine 0 sein (denn das würde ein Ferngespräch bedeuten). Außerdem darf eine Nummer nicht mit den Notrufnummern 110 und 112 beginnen. Wie viele verschiedene Nummern gibt es?
4. **Vegetarische Ernährung.** 12% der Deutschen ernähren sich ausschließlich vegetarisch oder vegan (Quelle: Forsa-Befragung im Auftrag des Bundesverbandes des Deutschen Lebensmittelhandels (BVLH), 2023). Ein Lebensmittelhersteller führt Geschmackstests für neu entwickelte Produkte durch. 25 zufällig ausgewählte Personen nehmen teil. Wie hoch ist die Wahrscheinlichkeit, dass sich mindestens eine dieser Personen vegetarisch/vegan ernährt?
5. **Doping.** Von 20 Sportlern haben drei gedopt. Für einen Doping-Test werden zwei der 20 zufällig ausgewählt.
 - a) Mit welcher Wahrscheinlichkeit werden zwei der drei Dopingsünder erwischt?
 - b) Mit welcher Wahrscheinlichkeit wird mindestens einer der drei erwischt?
6. **Smart Home.** Eine Wohnung ist mit Smart Home-Technologie ausgestattet. Um vor Einbrüchen zu schützen, können fünf Lampen abends automatisch ein- und ausgeschaltet werden, wenn niemand zu Hause ist.
 - a) Wie viele verschiedene Beleuchtungskonstellationen sind möglich, wenn mindestens eine der fünf Lampen leuchten soll?
 - b) Wie viele Konstellationen sind möglich, wenn mindestens drei der fünf Lampen leuchten sollen?

7. **Passwort.** Es ist bekannt, dass ein Passwort aus sechs Zeichen besteht; die ersten fünf sind Buchstaben, das letzte ist eine Ziffer. (Es gibt 26 mögliche Buchstaben, und es werden nur Kleinbuchstaben betrachtet.)
- a) Mit welcher Wahrscheinlichkeit kann man das korrekte Passwort in einem Versuch raten?
 - b) Nun wird bekannt, dass die ersten beiden Buchstaben gleich sind. Wie ändert sich die Wahrscheinlichkeit?
 - c) Zusätzlich wird bekannt, dass die Buchstaben a, e und g an dritter, vierter und fünfter Stelle stehen, wobei nicht bekannt ist, in welcher Reihenfolge diese drei Buchstaben stehen. Wie groß ist die Wahrscheinlichkeit nun?
8. **Computer.** Bei einem Computer-Hersteller können die Kunden die Komponenten bei der Bestellung selbst auswählen. Dies soll in einer Werbekampagne anhand eines Computers gezeigt werden, für den es drei Prozessoren zur Auswahl gibt, drei Betriebssysteme, acht Monitore, vier Speicheroptionen, vier Festplattengrößen und drei Grafikkarten; außerdem kann auf Wunsch ein CD/DVD-Laufwerk hinzugefügt werden.
- a) Wie viele verschiedene Computer können damit erstellt werden?
 - b) Wie ändert sich die Zahl, wenn eine der Grafikkarten nicht mit drei der acht Monitore kombinierbar ist?
9. **Qualitätskontrolle.** Ein Unternehmen erhält 60% eines bestimmten Bauteils von Lieferant A und 40% von Lieferant B. Es ist bekannt, dass 8% aller Bauteile defekt sind. Eine weitere Untersuchung der Qualitätsmanagements ergab, dass 5% der Teile von Lieferant B defekt sind.
- a) Welcher Prozentsatz der Teile von Lieferant A ist defekt?
 - b) Ein Teil wurde getestet und ist defekt. Mit welcher Wahrscheinlichkeit kommt es von Lieferant A?
10. **Tourist.** Ein Tourist möchte im Urlaub New York, New Orleans, Boston, Chicago, San Francisco, LA, Seattle, Miami, San Diego und Las Vegas besuchen.
- a) In wie vielen Reihenfolgen können die Städte besucht werden?
 - b) Der Tourist möchte das Angebot einer Airline nutzen, das Flüge zu sechs amerikanischen Städten beinhaltet. Wie viele Möglichkeiten gibt es, sechs Städte aus den oben genannten auszuwählen?
 - c) Wie viele Möglichkeiten bleiben, wenn entweder beide Städte im Nordosten (New York und Boston) oder keine der beiden unter den sechs gewählten sein sollen?
11. **Familie.** Eine Familie hat zwei Kinder, eines ist ein Junge. Mit welcher Wahrscheinlichkeit ist das andere ein Mädchen?
12. **Wirtschafts-Speeddating.** Beim “Wirtschafts-Speeddating” können junge Bewerber in Kontakt mit Unternehmen treten. 50 Firmen sind vertreten, und jeder Teilnehmer spricht mit acht von ihnen. Wir nehmen an, dass diese acht Firmen jeweils zufällig ausgewählt werden. Eine Teilnehmerin hat besonderes Interesse an fünf der Firmen. Mit welcher Wahrscheinlichkeit wird sie mit mindestens einer dieser fünf sprechen?
13. **Spam-Mails.** Ein E-Mail-Filter soll Spam-Mails anhand bestimmter Wörter erkennen. Hierzu wurde ein großer Datensatz mit mehreren tausend E-Mails analysiert. Davon sind 20% Spam-Mails und 80% reguläre (nicht-Spam) Mails. Das Wort “Geld” kommt in 37% der Spam-Mails und in 2,75% der regulären Mails vor.
- a) Berechnen Sie die Wahrscheinlichkeit, dass eine E-Mail Spam ist, wenn sie das Wort “Geld” enthält.
 - b) Wie würde sich die Wahrscheinlichkeit aus Teil a) ändern, wenn die Anzahl der regulären Mails mit dem Wort “Geld” größer wäre? Bitte begründen Sie Ihre Antwort.

Übungen: Diskrete Wahrscheinlichkeitsverteilungen

1. **Würfel.** Ein Würfel wird 12-mal geworfen. Mit welcher Wahrscheinlichkeit erhält man a) mindestens drei Sechsen, b) genau sechs gerade Zahlen, c) höchstens eine Zahl unter drei?
2. **Münze.** Eine Münze wird 10-mal geworfen. Mit welcher Wahrscheinlichkeit tritt a) 4-mal Kopf, b) bis zu 8-mal Kopf, c) kein Kopf oder keine Zahl auf?
3. **Hotel.** In einem Hotel ist bekannt, dass im Schnitt jeder 20. Gast auf das (im Preis enthaltene) Frühstück verzichtet. Derzeit wohnen 52 Gäste in dem Hotel.
 - a) Wie viele Gäste sind zum Frühstück zu erwarten?
 - b) Wie groß ist die Wahrscheinlichkeit, dass alle Gäste zum Frühstück erscheinen?
 - c) Mit welcher Wahrscheinlichkeit reicht es aus, Frühstück für 50 Gäste vorzubereiten?
4. **Assessment Center.** Ein Multiple-Choice-Test eines Assessment Centers besteht aus acht Fragen mit fünf vorgegebenen Antwortmöglichkeiten pro Frage. Nur eine Antwort pro Frage ist korrekt.
 - a) Auf wie viele korrekte Antworten kommt man im Durchschnitt durch Raten?
 - b) Mit welcher Wahrscheinlichkeit hat man gar keine richtige Antwort, wenn man nur rät?
 - c) Die Entwickler des Tests hoffen, dass die Chance, mindestens fünf korrekte Antworten durch Raten zu erhalten (und damit den Test zu bestehen), unter 1% liegt. Ist das gegeben?
5. **Backpacker.** Die Wahrscheinlichkeit, dass ein Rucksackreisender, der aus einer bestimmten Region zurückkehrt, eine bestimmte Krankheit hat, liegt bei 7%. Geben Sie für eine Gruppe von fünf Reisenden die Wahrscheinlichkeiten an, dass 0, 1, 2 ... von ihnen die Krankheit haben.
6. **Glücksspiel.** Ein Mitarbeiter eines Anbieters für Online-Glücksspiele hat das folgende Spiel entwickelt: Teilnehmer zahlen einen Dollar pro Runde. Eine (simulierte) Münze wird 10-mal geworfen. Wenn 0-mal Kopf auftritt, gewinnt der Teilnehmer 100 €, bei 1- oder 2-mal Kopf 10 €, und bei 3-mal Kopf 4 €. Der Mitarbeiter präsentiert seine Idee der Geschäftsführung. Kurze Zeit später wird er entlassen. Weshalb?
7. **Smartphone.** Für ein Smartphone-Modell ist bekannt, dass 3% der Geräte Akku-Probleme haben. Ein Händler hat 25 Geräte bestellt. Mit welcher Wahrscheinlichkeit hat nicht mehr als eines der Geräte Akku-Probleme?
8. **Retouren.** Ein Online-Händler verkauft ein Produkt für 99 €, davon entfallen 64 € auf Herstellungs- und Versandkosten. Bei 86% der Bestellungen behalten die Kunden das Produkt, in den anderen Fällen wird es zurückgeschickt, so dass der Händler 6 € Rücksendekosten tragen muss. Die Retouren teilen sich wie folgt auf: 91% der Rücksendungen können als gebraucht für 50 € verkauft werden, der Rest ist so stark beschädigt, dass er nicht mehr verkauft werden kann. Als gebraucht verkaufte Produkte können nicht zurückgegeben werden. Welcher Gewinn pro Stück ist zu erwarten?
9. **Kopien.** An einer Universität ist bekannt, dass nur 75% der für Wahlfächer eingeschriebenen Studierenden tatsächlich teilnehmen. Um Kosten und Papierverschwendung zu reduzieren, wurde beschlossen, Skripte nicht mehr für alle eingeschriebenen Studierenden zu drucken. Es sollen so wenig Skripte wie möglich gedruckt werden, wobei die Wahrscheinlichkeit, dass ein Teilnehmer ein Skript bekommt, über 95% liegen soll. Wie viele Skripte sollten für einen Kurs mit 18 eingeschriebenen Studierenden gedruckt werden?

Übungen: Stetige Wahrscheinlichkeitsverteilungen

1. **IQ.** Der IQ ist normalverteilt mit $\mu = 100$ und $\sigma = 15$.
 - a) Was ist der maximale IQ der 10% am wenigsten intelligenten Personen?
 - b) Für wie viele Personen in einer Stichprobe mit 280 Personen ist ein IQ von höchstens 85 zu erwarten?
 - c) Bestimmen Sie die Quartile.
2. **Schrauben.** Die Länge von Schrauben eines bestimmten Typs ist normalverteilt mit einem Mittelwert von 50 mm und einer Standardabweichung von 0,4 mm.
 - a) Mit welcher Wahrscheinlichkeit ist eine Schraube kürzer als 50,5 mm?
 - b) Aufgrund von Qualitätsanforderungen müssen mindestens 99% der Schrauben zwischen 49 und 51 mm lang sein. Wird das erreicht?
 - c) Wieviel Prozent der Schrauben sind länger als 50,75 mm?
 - d) Was ist die maximale Länge der 5% kürzesten Schrauben?
3. **Zulassungstests.** Viele Universitäten führen Zulassungstests für Studienplatzbewerber durch. Oft sind solche Tests so konstruiert, dass die Ergebnisse annähernd normalverteilt sind, wie z.B. beim GMAT (Graduate Management Admission Test) oder beim TMS (Test für Medizinische Studiengänge, "Medizinertest"). Im Folgenden wird ein Zulassungstest betrachtet, dessen Ergebnisse normalverteilt sind mit einem Mittelwert von 300 Punkten und einer Standardabweichung von 50 Punkten.
 - a) Mit welcher Wahrscheinlichkeit erreicht man mehr als 360 Punkte?
 - b) Wieviel Prozent der Teilnehmer erzielen höchstens 275 Punkte?
 - c) Wie viele Punkte hat man höchstens, wenn man zu den unteren 20% gehört?
 - d) Den besten 5% wird ein Studienplatz garantiert. Gehört man mit 376 Punkten zu den besten 5%?
 - e) In welchem Bereich liegen die Punktezahlen der mittleren 50% der Teilnehmer?
 - f) Mit welcher Wahrscheinlichkeit liegt die durchschnittliche Punktezahl einer Gruppe von 25 Teilnehmern bei mindestens 306,5? Nehmen Sie außerdem an, dass 25 Personen tatsächlich im Durchschnitt 306,5 Punkte erzielt haben. Ist diese Abweichung von 300 Punkten ein Hinweis auf mögliche Unregelmäßigkeiten (z.B. Betrug)?
 - g) In einem anderen Zulassungstest (mit ebenfalls normalverteilten Ergebnissen) liegt der Mittelwert bei 450 Punkten. 30% der Teilnehmer erreichen mindestens 504,5 Punkte. Bitte bestimmen Sie die Standardabweichung.
4. **Äpfel.** Ein Obsthändler verkauft eine bestimmte Apfelsorte in 2-kg-Säcken. Diese Äpfel wiegen im Durchschnitt 214 g, die Standardabweichung liegt bei 17 g (das Gewicht der Äpfel ist näherungsweise normalverteilt). Der Händler füllt immer 10 Äpfel in einen Sack, ohne den Sack zu wiegen. Kann er trotzdem davon ausgehen, dass 99% der so abgefüllten Säcke tatsächlich mindestens 2 kg wiegen?
5. **LKW-Beladungszeiten.** In einem Logistikzentrum dauert die Beladung eines LKW durchschnittlich 34 Minuten bei einer Standardabweichung von 12 Minuten (es wird angenommen, dass die Beladungszeiten in etwa normalverteilt sind).
 - a) Mit welcher Wahrscheinlichkeit dauert eine Beladung länger als 45 Minuten?
 - b) Welcher Anteil der Beladungen dauert höchstens eine halbe Stunde?
 - c) Um welche Uhrzeit müsste man spätestens mit der Beladung eines LKW beginnen, damit sie mit 95% Wahrscheinlichkeit um 10:00 Uhr abgeschlossen ist?
 - d) Ist die Annahme der Normalverteilung hier gerechtfertigt oder wäre in der Praxis eher eine links- oder rechtsschiefe Verteilung zu erwarten? Weshalb?

6. **Handgepäck.** Eine Fluggesellschaft untersucht das Gewicht des Handgepäckes der Passagiere. Das Gewicht ist normalverteilt mit einem Mittelwert von 5,6 kg und einer Standardabweichung von 1,2 kg.
- a) Mit welcher Wahrscheinlichkeit wiegt das Handgepäck eines Passagiers mehr als 8 kg?
 - b) Bei welchem Anteil der Passagiere ist das Handgepäck leichter als 5 kg?
 - c) Mit welcher Wahrscheinlichkeit liegt das Gewicht zwischen 4 und 6 kg?
 - d) Wieviel wiegt das schwerste Prozent des Handgepäckes mindestens?
 - e) Bei der Berechnung der Kerosinmenge für einen Flug mit 200 Passagieren geht die Airline davon aus, dass das Handgepäck aller Passagiere insgesamt nicht mehr als 1160 kg wiegt. Ist dies gerechtfertigt, wenn die Wahrscheinlichkeit, dass das tatsächliche Gesamtgewicht über diesem Schätzwert liegt, nicht mehr als 1% betragen darf?
7. **Auto.** Der durchschnittliche Benzinverbrauch eines Autos liegt bei 5,2 l pro 100 km. Auf 25% der Fahrten liegt der Verbrauch bei über 5,5 l/100 km. Bei welchem Anteil der Fahrten liegt der Verbrauch unter 5 l/100 km, wenn man von der Normalverteilung ausgeht?

Übungen: Konfidenzintervalle und Stichprobengröße

1. **Bierpreis.** Eine Studie zu Bierpreisen in Restaurants wurde durchgeführt. In der Stichprobe von 64 Restaurants lag der Durchschnittspreis für 0,4 l bei 4,87 €, die Standardabweichung betrug 0,41 €. In welchem Intervall wird der tatsächliche durchschnittliche Bierpreis liegen (Konfidenzniveau 95%)?
2. **Nutzungsdauer.** Ein Unternehmen möchte die durchschnittliche Nutzungsdauer elektronischer Geräte untersuchen.
 - a) Eine Umfrage mit 400 Befragten hat für Smartphones eine durchschnittliche Nutzungsdauer von 42 Monaten bei einer Standardabweichung von 7 Monaten ergeben. Bitte ermitteln Sie das 95%-Konfidenzintervall für die Nutzungsdauer.
 - b) In einer weiteren Umfrage soll u.a. die durchschnittliche Nutzungsdauer von Laptops ermittelt werden. Wie groß muss die Stichprobe sein, um die Nutzungsdauer auf $\pm$ einen Monat genau zu bestimmen? Das Konfidenzniveau sei wieder 95%, außerdem wird die Standardabweichung auf 12 Monate geschätzt.
3. **Wahl.** Nehmen Sie an, dass eine neue Partei bei den nächsten Wahlen in Hamburg antritt. In einer Umfrage mit 800 Befragten kam die Partei auf 9%.
 - a) In welchem Intervall ist der Anteil der Wähler bei einem Konfidenzniveau von 99% zu erwarten?
 - b) In der nächsten Umfrage wird ein Intervall der Größe $\pm 1,5\%$ angestrebt (Konfidenzniveau wieder 99%). Wie viele Personen müssen befragt werden?
4. **Zahlungsbereitschaft.** In einer Studie mit 100 Befragten wurde untersucht, welchen Preis Konsumenten für ein bestimmtes Produkt zu zahlen bereit wären. Die Standardabweichung betrug 0,90 €. Das Ergebnis war, dass die Zahlungsbereitschaft zwischen 5,85 € und 6,15 € liegt. Welches Konfidenzniveau liegt dem zugrunde?
5. **Produktbewertung.** In einer Marktforschungsstudie wurden 25 Personen gebeten, ein neues Produkt auf einer Skala von 0 (schlecht) bis 10 (hervorragend) zu bewerten. Die durchschnittliche Bewertung lag bei 7,22, die Stichproben-Standardabweichung lag bei 1,41.
 - a) Bestimmen Sie das 95%-Konfidenzintervall für das Durchschnitts-Rating der Grundgesamtheit.
 - b) Wäre das Intervall größer oder kleiner, wenn das Konfidenzniveau angehoben wird? Weshalb?
6. **Verkehrspolitik.** Für eine Studie zur Verkehrspolitik hat das Meinungsforschungsinstitut *infratest dimap* eine Stichprobe von 1000 Personen befragt (ein Ergebnis war beispielsweise, dass 53% für ein Tempolimit auf Autobahnen sind). Auch die Genauigkeit der Ergebnisse wurde angegeben: Bei Anteilen von 50% liegt der Fehler demnach bei $\pm 3,1$ Prozentpunkten, bei Anteilen von 5% liegt er bei $\pm 1,4$ Prozentpunkten. Bitte bestätigen Sie diese Angaben zur Genauigkeit und geben Sie das verwendete Konfidenzniveau an.
7. **Mineralwasser.** Das Mineralwasser einer bestimmten Marke wurde analysiert. Mit Hilfe einer Stichprobe ergab sich ein Konfidenzintervall von 341 – 352 mg für den Kalziumgehalt pro Liter ($\alpha = 0,05$, $n = 50$). Wie hoch ist die Wahrscheinlichkeit, dass der Mittelwert der zugrundeliegenden Stichprobe in diesem Intervall liegt?
☐ 0% ☐ 2,5% ☐ 5% ☐ 10% ☐ 50% ☐ 90% ☐ 95% ☐ 97,5% ☐ 100%
☐ unbekannt

Übungen: Hypothesentests

1. **Kinder.** Bei der URMEL-ICE-Studie der Universitätsklinik Ulm wurde das Körpergewicht von 1065 Grundschulkindern untersucht. Das Durchschnittsgewicht betrug 26,43 kg bei einer Standardabweichung von 5,05. Wir nehmen an, dass die Daten normalverteilt sind. Lässt sich schlussfolgern, dass das Durchschnittsgewicht unter 27 kg liegt (bei einem Signifikanzniveau von 0,05)?
2. **Neuer Fernseher.** Bei einer Umfrage haben 214 von 400 Befragten angegeben, dass sie sich in den kommenden drei Jahren einen neuen Fernseher kaufen möchten. Lässt sich daraus die Aussage ableiten, dass sich mehr als jeder zweite Deutsche in den kommenden drei Jahren einen neuen Fernseher kaufen möchte? Bitte führen Sie einen Hypothesentest durch und wählen Sie $\alpha = 0,05$.
3. **Online-Zeit.** In einer Studie wurde untersucht, wieviel Zeit junge Leute zwischen 20 und 25 Jahren täglich online verbringen. In einer Stichprobe wurden die in der folgenden Tabelle dargestellten Zeiten ermittelt (in Stunden). Sind junge Leute täglich im Durchschnitt signifikant mehr als 3 Stunden online? Bitte verwenden Sie $\alpha = 0,05$.

3,5	1,0	2,5	3,5	4,5	5,0	6,0	4,0
-----	-----	-----	-----	-----	-----	-----	-----

4. **Cola.** Da Coke Light den Ruf hatte, ein Getränk besonders für Frauen zu sein, hat Coca Cola Coke Zero eingeführt, um männliche Konsumenten anzusprechen. Angenommen, Coca Cola hat eine Studie durchgeführt, um zu prüfen, ob es tatsächlich einen Unterschied zwischen den Geschlechtern bei der Wahl einer zuckerfreien Cola gibt. 131 Männer bevorzugten Coke Zero, 119 wählten Coke Light. Bei den Frauen bevorzugten 112 Coke Zero und 127 Coke Light. Ist der Unterschied signifikant bei einem Signifikanzniveau von 5%?
5. **Markenbekanntheit.** Ein Jahr nach der Einführung einer neuen Joghurt-Marke möchte das Unternehmen den Bekanntheitsgrad der Marke untersuchen. In einer Befragung gaben 112 von 400 Personen an, die Marke zu kennen. Liegt der Bekanntheitsgrad signifikant über 25%? Verwenden Sie ein Signifikanzniveau von 5%.
6. **Eistee.** Ein Unternehmen möchte den Verbrauch von Eistee in einer bestimmten Region untersuchen. In einer Befragung gaben 8 Personen einen monatlichen Verbrauch in Höhe von 7, 3, 0, 0, 1, 4, 10 und 2 Liter an. Bitte verwenden Sie im Folgenden $\alpha = 0,05$.
 - a) Kann man von einem Durchschnittsverbrauch von mehr als 3 l Eistee pro Monat ausgehen?
 - b) Was wäre der kleinstmögliche Durchschnittsverbrauch in dieser Stichprobe gewesen, der signifikant über 3 l gelegen hätte?
7. **Orangensaft.** Ein Institut möchte zwei Orangensäfte im Hinblick auf den Vitamin-C-Gehalt vergleichen. Von beiden Säften wurde eine Stichprobe von je 40 Flaschen untersucht. Bei Marke 1 lagen der Durchschnittsgehalt bei 34,0 mg/100 ml und die Standardabweichung bei 1,4, bei Marke 2 betrug der Mittelwert 33,1 mg/100 ml und die Standardabweichung 1,2. Ist der Unterschied signifikant ($\alpha = 5\%$)?
8. **Ostsee.** Eine Studie zu Urlaubsreisen mit 800 Deutschen wurde durchgeführt. Ein Ergebnis war, dass signifikant weniger als 50% sagten, dass sie sich einen längeren Urlaub an der Ostsee vorstellen könnten; der p-Wert lag bei 0,0119. Wie viele Personen der Stichprobe haben gesagt, dass sie sich einen längeren Urlaub an der Ostsee vorstellen könnten?

9. **Kundenzufriedenheit.** Eine Fluggesellschaft führt jedes Jahr eine Befragung ihrer Passagiere durch, um die Entwicklung der Kundenzufriedenheit zu überprüfen. In jedem Jahr wird eine neue Stichprobe mit 250 Passagieren befragt. Der Fragebogen umfasst 12 Fragen, z.B. zur Pünktlichkeit der Flüge und zur Freundlichkeit des Personals usw. Jede Frage wird auf einer Skala von 0 (sehr schlecht) bis 10 (sehr gut) beantwortet. Um die Gesamtzufriedenheit der Befragten zu messen, wird für jede Person die Summe der Punkte gebildet (die zwischen 0 und 120 liegt). In der Datei *Statistik – Kundenzufriedenheit.csv* sind die Werte (d.h. Punktesummen) der Befragten gegeben, sowohl für dieses Jahr als auch für das letzte Jahr. Nun sollen die Ergebnisse untersucht werden (wenn nichts anderes angegeben ist, soll im Folgenden $\alpha = 0,05$ gelten).
- Berechnen Sie den Mittelwert und die Standardabweichung für dieses und für das letzte Jahr (z.B. mit Excel).
 - Gibt es einen signifikanten Anstieg der Kundenzufriedenheit?
 - Liegt die durchschnittliche Kundenzufriedenheit in diesem Jahr signifikant über 90 Punkten? Würde man dasselbe Ergebnis erhalten, wenn α auf 0,01 reduziert würde?
 - Liegt der Anteil der Befragten, deren Zufriedenheit mindestens 90 Punkte beträgt, in diesem Jahr signifikant über 50%?
 - Lag die durchschnittliche Kundenzufriedenheit im letzten Jahr signifikant unter 90 Punkten? Bestimmen Sie außerdem den p-Wert und interpretieren Sie ihn.
10. **Wellness.** Eine große Hotelkette möchte untersuchen, ob das Interesse an Wellness-Urlaub vom Alter abhängt. Personen aus zwei Altersgruppen (jünger als 50 Jahre sowie 50 Jahre und älter) wurden befragt, ob sie Interesse an Wellness-Urlaub haben oder nicht. Bitte führen Sie einen Hypothesentest durch ($\alpha = 5\%$) und geben Sie die Schlussfolgerung an.

	< 50 Jahre	≥ 50 Jahre
interessiert	71	93
nicht interessiert	179	157

11. **Bilanz.** Die Bilanz eines Unternehmens soll mit Hilfe der Benford-Verteilung geprüft werden. Die Häufigkeiten der führenden Ziffern sind in der folgenden Tabelle angegeben (es sind echte Daten eines Unternehmens). Führen Sie einen Hypothesentest durch ($\alpha = 0,05$) und geben Sie Ihre Schlussfolgerung an.

Ziffer	1	2	3	4	5	6	7	8	9
Häufigkeit	250	141	88	69	48	48	40	37	37

12. **Antibiotika.** Ein Pharmaunternehmen hat ein neues Antibiotikum A entwickelt und möchte dessen Wirksamkeit mit einem bereits etablierten Antibiotikum B vergleichen. In einer klinischen Studie wurden zwei Patientengruppen untersucht, die jeweils eines der beiden Antibiotika erhielten. Die folgende Tabelle zeigt, wie viele Patienten an welchem Tag der Behandlung eine Wirkung des Antibiotikums zeigten. Bitte führen Sie einen geeigneten Hypothesentest durch, um zu überprüfen, ob sich die durchschnittliche Zeit bis zum Wirkungseintritt zwischen den beiden Antibiotika signifikant unterscheidet ($\alpha = 0,05$).

Tag	1	2	3	4
Antibiotikum A	7	24	16	3
Antibiotikum B	4	18	20	8

13. **Klausuren.** In einer Stichprobe mit 117 Statistik-Klausuren haben 49 Studierende die Interpretation eines Konfidenzintervalls korrekt angegeben (dies sind echte Werte der HSBA). Bedeutet dies, dass signifikant weniger als 50% der HSBA-Studierenden wissen, was ein Konfidenzintervall ist? Bitte führen Sie einen Hypothesentest mit einem Signifikanzniveau von 5% durch. Zeigen Sie außerdem, dass man mit dem p-Wert zum selben Ergebnis kommt.
14. **Überstunden.** Im Rahmen einer Studie wurde eine Stichprobe von Vollzeit-Angestellten einer bestimmten Branche gefragt, wie viele Überstunden sie üblicherweise pro Woche machen. Die verfügbaren Daten sind in der folgenden Tabelle aufgeführt. Kann man aus den Daten ableiten, dass mehr als ein Viertel der Angestellten dieser Branche regelmäßig mehr als fünf Überstunden pro Woche macht? Das Signifikanzniveau soll 0,05 betragen.

Anzahl Überstunden	0	1–5	6–10	11–15	16–20
Anzahl Personen	54	116	56	19	5

15. **Anwendung der Benford-Verteilung.** Wenn man einen χ^2 -Anpassungstest für die Benford-Verteilung anwendet (etwa im Rahmen einer Bilanzprüfung), dann muss die Stichprobe mindestens 110 Werte umfassen. Weshalb?

Klausur A

Aufgabe 1 (32 P.)

Ein Unternehmen hat ein neues Müsli entwickelt, das weniger Zucker als andere Müslis enthalten soll. Der Zuckergehalt dieses neuen Müslis wurde untersucht. Die Ergebnisse für die zehn Packungen der Stichprobe sind wie folgt (Zuckergehalt in g pro 100 g Müsli):

26 24 22 27 18 19 31 23 21 24

- a) Bitte bestimmen Sie den Mittelwert, den Median, die Varianz und die Standardabweichung. (12 P.)
- b) Das Unternehmen behauptet, dass das neue Müsli durchschnittlich weniger als 25 g Zucker pro 100 g enthält. Ist diese Aussage gerechtfertigt? Führen Sie einen Hypothesentest durch (5% Signifikanzniveau) und geben Sie Ihre Schlussfolgerung an. (10 P.)
- c) Gibt es unter den oben genannten Ergebnissen Werte, die als Ausreißer gelten können? Begründen Sie Ihre Antwort. (10 P.)

Aufgabe 2 (22 P.)

Im Rahmen einer Marketing-Kampagne verteilt ein Supermarkt Rubbellose an seine Kunden. Jedes Los enthält neun Felder, davon sollen vier freigerubbelt werden (werden mehr Felder freigerubbelt, wird das Los ungültig). Man gewinnt, wenn die vier gewählten Felder ein bestimmtes Symbol zeigen. (Vor einiger Zeit gab es bei Edeka ähnliche Rubbellose.)

- a) Mit welcher Wahrscheinlichkeit gewinnt man, wenn genau vier der neun Felder das Symbol enthalten? (6 P.)
- b) Mit welcher Wahrscheinlichkeit gewinnt man, wenn genau fünf der neun Felder das Symbol enthalten? (6 P.)
- c) Nehmen Sie nun an, dass genau vier der neun Felder das Symbol enthalten, und dass man 50 € gewinnt, wenn man die vier Felder mit dem Symbol freirubbelt. Wie viele Lose sollten produziert werden, wenn das Budget für Gewinne 10000 € beträgt? (5 P.)
- d) Nehmen Sie wieder an, dass genau vier der neun Felder das Symbol enthalten. Ein Kunde erhält drei Lose. Mit welcher Wahrscheinlichkeit gewinnt er mit mindestens einem davon? (5 P.)

Aufgabe 3 (20 P.)

Ein Unternehmen produziert unter anderem Eiskaffee, der in Supermärkten verkauft wird. Im Rahmen der Qualitätssicherung wird die Abfüllmaschine untersucht. Da die Füllmenge aus technischen Gründen ein wenig schwankt (die Standardabweichung beträgt 1,6 ml), ist die Maschine so eingestellt, dass im Durchschnitt 303 ml pro 300-ml-Flasche abgefüllt werden. Es kann angenommen werden, dass die Füllmenge normalverteilt ist.

- a) Welcher Anteil der Flaschen enthält weniger als 300 ml? (5 P.)
- b) Mit welcher Wahrscheinlichkeit enthält eine Flasche mehr als 305 ml? (5 P.)
- c) Nun werden die 10% der Flaschen, die die kleinste Füllmenge enthalten, betrachtet. Was ist die maximale Füllmenge dieser Flaschen? (5 P.)
- d) Das Unternehmen möchte sicherstellen, dass 99% der Flaschen mehr als 300 ml enthalten. Wie muss – bei gleicher Standardabweichung – der Mittelwert eingestellt werden, so dass dies erreicht wird? (5 P.)

Aufgabe 4 (12 P.)

Ein Internetshop hat eine Studie mit einer Stichprobe von 540 Teilnehmern durchgeführt, um die Akzeptanz der Regelungen für die Rückgabe zu untersuchen. 191 Personen haben gesagt, dass die diese Regelungen nicht gut finden, weil sie nicht kundenfreundlich seien.

- a) Bitte berechnen Sie das Konfidenzintervall für den Anteil der Personen, die die Rückgabe-Regelungen nicht mögen (90% Konfidenzniveau). (5 P.)
- b) Als nächstes soll (wieder mit 540 Befragten) untersucht werden, wie das Preisniveau des Shops beurteilt wird. Das Management hofft, dass mehr als ein Drittel das Preisniveau als sehr gut einstuft. Wie viele Befragte müssen sagen, dass sie das Preisniveau sehr gut finden, damit der Anteil signifikant über einem Drittel liegt? Als Signifikanzniveau soll 1% gewählt werden. (7 P.)

Aufgabe 5 (14 P.)

Eine Fluggesellschaft bietet Flüge auf einer bestimmten Strecke an. Das eingesetzte Flugzeug verfügt über 60 Plätze, der Ticketpreis beträgt 300 €. Einer Auswertung zufolge liegt die Wahrscheinlichkeit, dass eine Person mit Ticket den Flug nicht antritt, bei 3%. Das Management überlegt, die Flüge zu überbuchen, also mehr Tickets zu verkaufen als Plätze verfügbar sind. Da die Wahrscheinlichkeit, dass Personen den Flug nicht antreten, gering ist, kommt nur eine geringe Anzahl zusätzlich verkaufter Tickets in Frage.

Eine Person, die den Flug antreten möchte, aber trotz Ticket keinen Platz bekommt, verursacht Kosten in Höhe von 800 € für Entschädigung, Hotel, alternativen Flug usw. Sollen zusätzliche Tickets verkauft werden, und wenn ja, wie viele? Bestimmen Sie die optimale Anzahl Tickets und berücksichtigen Sie dabei Umsatz und Kosten. Bitte geben Sie einen nachvollziehbaren Rechenweg an.

Klausur B

Aufgabe 1 (18 P.)

Ein Unternehmen produziert Überraschungseier, die in einer Schokoladenhülle ein kleines Spielzeug enthalten. Derzeit gibt es zehn verschiedene Spielzeuge, die alle gleich häufig verwendet werden. Eines der Spielzeuge ist eine Figur, die sehr populär bei Kindern ist. Nehmen Sie an, dass Sie sechs Überraschungseier kaufen.

- a) Wie oft ist diese Figur in den sechs Eiern zu erwarten? (3 P.)
- b) Wie hoch ist die Wahrscheinlichkeit, dass keines der sechs Eier die Figur enthält? (5 P.)
- c) Wie hoch ist die Wahrscheinlichkeit, dass mindestens zwei der sechs Eier die Figur enthalten? (5 P.)
- d) Mit welcher Wahrscheinlichkeit erhalten Sie sechs verschiedene Spielzeuge in den sechs Eiern, ohne dass die Figur dabei ist? (5 P.)

Aufgabe 2 (28 P.)

Eine Firma bietet verschiedene Diätprodukte an, die beim Abnehmen helfen sollen. Das Management möchte die Wirkung eines neu entwickelten Produkts analysieren. In einer Stichprobe mit acht Personen haben sich innerhalb von vier Wochen die folgenden Gewichtsreduktionen (in kg) ergeben:

7,0 1,2 5,0 5,4 4,2 3,8 4,6 2,5

- a) Bestimmen Sie den Mittelwert, den Median, die Spannweite und die Standardabweichung. (10 P.)
- b) Ermitteln Sie die Quartile und erläutern Sie kurz Ihr Ergebnis für das dritte Quartil. (8 P.)
- c) Die Firma möchte in einer Marketing-Kampagne herausstellen, dass Nutzer des Produkts innerhalb von vier Wochen im Durchschnitt um mehr als 4 kg abnehmen. Ist diese Behauptung gerechtfertigt? Führen Sie einen Hypothesentest mit 5% Signifikanzniveau durch. (10 P.)

Aufgabe 3 (20 P.)

Die Lebensdauer einer elektrischen Zahnbürste einer bestimmten Marke beträgt durchschnittlich 5,8 Jahre (dabei wurde vorausgesetzt, dass eine Person täglich zweimal die Zähne putzt). Die Standardabweichung beträgt 1,6 Jahre. Für die folgenden Berechnungen soll näherungsweise eine Normalverteilung der Lebensdauer angenommen werden.

- a) Mit welcher Wahrscheinlichkeit liegt die Lebensdauer einer Zahnbürste bei höchstens 7 Jahren? (5 P.)
- b) Ab welcher Lebensdauer gehört eine Zahnbürste zu den 10% langlebigsten? (5 P.)
- c) Das Management überlegt, Zahnbürsten kostenlos zu ersetzen, wenn sie nach weniger als 3 Jahren kaputtgehen. Welcher Anteil der Zahnbürsten müsste ersetzt werden? (5 P.)
- d) Wie weit müsste die mittlere Lebensdauer angehoben werden (bei unveränderter Standardabweichung), damit nur 2,5% der Zahnbürsten eine kürzere Lebensdauer als 3 Jahre haben? (5 P.)

Aufgabe 4 (22 P.)

Ein Unternehmen stellt ein bestimmtes Produkt her und verkauft es über den eigenen Online-Shop. Zur Absatzsteigerung werden Fernsehwerbung und Internet-Banner eingesetzt. Ein einzelnen Wochen ist das Produkt im Sonderangebot und wird für einen um 10% niedrigeren Preis angeboten. Das Management möchte den Erfolg dieser Aktivitäten untersuchen. Auf der Basis der Daten der letzten Wochen wurde eine Regressionsanalyse durchgeführt, bei der der Umsatz pro Woche (in 1000 €) die abhängige Variable war. Die unabhängigen Variablen waren:

- Für Fernsehwerbung verwendetes Budget (in 1000 €) in der jeweiligen Woche
- Für Banner verwendetes Budget (in 1000 €) in der jeweiligen Woche
- Die Angabe, ob das Produkt in der jeweiligen Woche im Sonderangebot war (Variable = 1) oder nicht (Variable = 0)

Die folgenden Tabellen fassen die mit Excel erhaltenen Regressionsergebnisse zusammen:

<i>Regressions-Statistik</i>			
Multipler Korrelationskoeffizient	0,9141		
Bestimmtheitsmaß	0,8356		
Adjustiertes Bestimmtheitsmaß	0,8153		
Beobachtungen	15		

	<i>Koeffizienten</i>	<i>Standardfehler</i>	<i>t-Statistik</i>
Schnittpunkt	312,2278	17,5805	17,7599
Fernsehwerbung	1,7596	1,3860	1,2695
Internet-Banner	3,9250	0,8757	4,4822
Sonderangebot	32,8518	9,9720	3,2944

- a) Geben Sie die Gleichung der Regressionsfunktion an und interpretieren Sie kurz die Koeffizienten. (10 P.)
- b) Führen Sie t-Tests für die Koeffizienten durch (5% Signifikanzniveau) und geben Sie Ihre Schlussfolgerungen an. (12 P.)

Aufgabe 5 (12 P.)

Ein neues Medikament wurde entwickelt. Es soll untersucht werden, ob das Medikament die durchschnittliche Reaktionszeit erhöht (diese würde bedeuten, dass Personen, die das Medikament nehmen, nicht Auto fahren sollten).

Es ist bekannt, dass die Reaktionszeit (ohne die Einnahme eines Medikaments) in einem bestimmten standardisierten Experiment normalverteilt ist mit einem Mittelwert von 220 Millisekunden (ms) und einer Standardabweichung von 25 ms in der Grundgesamtheit. Nun soll eine Stichprobe von Personen, die das betrachtete Medikament genommen haben, an diesem Experiment teilnehmen. Dabei wird jeweils die Reaktionszeit gemessen. Anschließend soll dann ein Hypothesentest (mit 1% Signifikanz-Niveau) durchgeführt werden, um festzustellen, ob die Reaktionszeit bei Personen, die das Medikament genommen haben, signifikant höher ist als 220 ms.

- a) Gehen Sie zunächst von einer Stichprobengröße von 100 Personen aus. Was wäre die größtmögliche durchschnittliche Reaktionszeit in der Stichprobe, die gerade noch nicht zur Schlussfolgerung führen würde, dass das Medikament die Reaktionszeit signifikant erhöht? (6 P.)
- b) Nehmen Sie nun an, dass die Stichprobe größer ist als 100. Wie würde sich die größtmögliche durchschnittliche Reaktionszeit ändern? Begründen Sie Ihre Antwort allgemein (also nicht auf der Basis einer Rechnung für einen Beispielwert). (6 P.)

Lösungen zu den Übungen

Deskriptive Statistik

1. Einkommen.

a) $\bar{X} = 2012,50$, $M_d = 2050$, $M_o = 1900$

b) $\bar{X} = 2677,78$, $M_d = 2200$, $M_o = 1900$

2. Biermarken.

Marke A: $\bar{X} = 30,88$, $s = 8,774$, Spannweite = 29, $Q_1 = 26,5$, $Q_2 = 28$, $Q_3 = 35,5$

$IQR = 35,5 - 26,5 = 9$, keine Werte unter $26,5 - 1,5 \cdot 9 = 13$ oder über $35,5 + 1,5 \cdot 9 = 49$, also keine milden Ausreißer und damit auch keine extremen.

Marke B: $\bar{X} = 36,50$, $s = 11,28$, Spannweite = 34, $Q_1 = 28$, $Q_2 = 35$, $Q_3 = 44$

$IQR = 44 - 28 = 16$, keine Werte unter $28 - 1,5 \cdot 16 = 4$ oder über $44 + 1,5 \cdot 16 = 68$, also keine milden Ausreißer und damit auch keine extremen.

3. **Kaffeeconsum.** $\bar{X}_{neu} = \frac{239 \cdot 28,24 + 45}{240} = 28,31 \text{ €}$

4. **Paketdienstleister.** $\bar{X} = \frac{1}{240}(47 \cdot 1 + 123 \cdot 2 + \dots) = 2,19 \text{ Tage}$
 $M_d = 2$ (der Wert zwischen dem 120. und dem 121. Wert), $M_o = 2$

$$s = \sqrt{\frac{1}{239}(47 \cdot (1 - 2,19)^2 + 123 \cdot (2 - 2,19)^2 + \dots)} = 0,8692 \text{ Tage}$$

Korrelation und Regression

1. **Ernährung und Lebenserwartung.** Weniger Fleisch zu essen hilft, das Risiko für bestimmte chronische Krankheiten zu reduzieren und trägt somit zu einem längeren Leben bei. Allerdings handelt es sich dabei nicht um eine rein kausale Beziehung. Eine dritte Variable – der persönliche Lebensstil insgesamt – muss ebenfalls berücksichtigt werden. Menschen, die weniger (oder kein) Fleisch essen, achten oft mehr auf ihre Gesundheit: Sie konsumieren weniger ungesunde Fette, rauchen weniger, treiben mehr Sport und führen generell einen gesünderen Lebensstil. Dadurch sind sie gesünder und leben länger.
2. **Gehalt und Produktivität.** Gut bezahlte Mitarbeiter sind oft motivierter und dadurch produktiver. Es handelt sich jedoch nicht um eine rein kausale Beziehung. Das Arbeitsumfeld kann als dritte Variable betrachtet werden: Unternehmen mit einem guten Arbeitsumfeld zahlen oft höhere Gehälter, bieten aber zusätzlich bessere Bedingungen wie mehr Wertschätzung und Weiterbildung – Faktoren, die ebenfalls die Produktivität steigern. Höhere Gehälter allein steigern die Produktivität also oft nicht bzw. nicht so stark.

3. Attraktivität und Gehalt.

- Das Durchschnittseinkommen einer unattraktiven Person (0 auf der Skala) ohne Hochschulabschluss beträgt 2218,22 €. Mit jedem zusätzlichen Attraktivitäts-Punkt steigt das ein Einkommen im Schnitt um 56,92 €. Ein Hochschulabschluss erhöht das Einkommen im Schnitt um 400 €.
- Ja, weil $t_{kritisch} \approx \pm 1,96$ ($t \approx z$ für sehr große n) und für beide Variablen $t > t_{kritisch}$ ist.
- $401,34/56,92 \approx 7$
- $e = y - \hat{y} = 2889,20 - (2218,22 + 56,92 \cdot 8 + 401,34 \cdot 1) = 2889,20 - 3074,92 = -185,72$
- Viele für das Gehalt relevante Faktoren sind nicht berücksichtigt (Berufserfahrung, Branche, Führungsposition usw.). Es ging hier jedoch um spezifische Faktoren und nicht darum, alle möglichen Faktoren zu untersuchen.

4. **Signifikanz.** Nein, die Größe des Koeffizienten sagt nichts über die Signifikanz aus. Beispiel: Ein Preis könnte in Euros oder Cents gemessen werden. Der Koeffizient für Euros wäre 100 mal größer als der für Cents, aber die t-Statistik und der p-Wert (und damit die Signifikanz) wären für Euros und Cents gleich.

5. **Koeffizient.** Der Korrelationskoeffizient von X und Y ist negativ.


6. **Berechnungen.** Vorbereitung: $\bar{X} = 8$ $\bar{Y} = 129$

$$r = \frac{\sum (x_i - \bar{X}) \cdot (y_i - \bar{Y})}{\sqrt{\sum (x_i - \bar{X})^2} \cdot \sqrt{\sum (y_i - \bar{Y})^2}} = \frac{(6-8) \cdot (112-129) + (7-8) \cdot (128-129) + \dots}{\sqrt{(6-8)^2 + (7-8)^2 + \dots} \cdot \sqrt{(112-129)^2 + (128-129)^2 + \dots}} = 0,9487$$

$$b_1 = \frac{\sum (x_i - \bar{X}) \cdot (y_i - \bar{Y})}{\sum (x_i - \bar{X})^2} = \frac{(6-8) \cdot (112-129) + (7-8) \cdot (128-129) + \dots}{(6-8)^2 + (7-8)^2 + \dots} = 6,60 \quad b_0 = \bar{Y} - b_1 \bar{X} = 129 - 6,6 \cdot 8 = 76,20$$

$$\hat{y} = b_0 + b_1 x = 76,2 + 6,6x \quad R^2 = 0,90$$

x_i	6,0	7,0	9,0	10,0
y_i	112,0	128,0	134,0	142,0
$\hat{y}_i$	115,8	122,4	135,6	142,2
e_i	-3,8	5,6	-1,6	-0,2



7. Absatzentwicklung.

a) $n = 24$ Monate, also 2 Jahre

b) $\hat{y} = 20138,86 + 72,61x$

Die verkaufte Stückzahl steigt mit jedem Monat um durchschnittlich 72,61 Stück.

c) $\hat{y} = 20138,86 + 72,61 \cdot 8 = 20719,74$ Stück

$e = 20407 - 20719,74 = -312,74$ Stück

Wahrscheinlichkeiten und Kombinatorik

1. **Lotterie.** a) $\frac{50}{200}$ b) $\frac{150}{200} \cdot \frac{149}{199}$ c) $\frac{195}{200} \cdot \frac{194}{199}$ d) $\frac{45}{200} \cdot \frac{5}{199}$ e) $\frac{150}{200} \cdot \frac{5}{199} + \frac{5}{200} \cdot \frac{150}{199}$ f) $1 - \frac{195}{200} \cdot \frac{194}{199} \cdot \frac{193}{198}$

2. Kniffel.

a) $P(\text{Kniffel}) = \frac{6}{6} \cdot \frac{1}{6} \cdot \frac{1}{6} \cdot \frac{1}{6} \cdot \frac{1}{6} = \left(\frac{1}{6}\right)^4 = 0,000772$

b) $P(2 \text{ Kniffel}) = P(\text{Kniffel})^2 = 0,000000595$

c) $P(\text{Viererpasch}) = \frac{6}{6} \cdot \frac{1}{6} \cdot \frac{1}{6} \cdot \frac{1}{6} \cdot \frac{5}{6} \cdot \binom{5}{1} = 0,01929$

d) $P(\text{Full House}) = \frac{6}{6} \cdot \frac{1}{6} \cdot \frac{1}{6} \cdot \frac{5}{6} \cdot \frac{1}{6} \cdot \binom{5}{3} = 0,03858$

3. **Telefonnummern.** $9 \cdot 10^5 - 2 \cdot 10^3 = 898\,000$

4. **Vegetarische Ernährung.** $1 - 0,88^{25} = 0,9591$

5. Doping.

a) $P(2 \text{ erwischt}) = \frac{3}{20} \cdot \frac{2}{19} = 0,01579 \left(= \frac{\binom{3}{2} \cdot \binom{17}{0}}{\binom{20}{2}} \right)$

b) $P(\text{mindestens einer erwischt}) = 1 - P(\text{keiner erwischt}) = 1 - \frac{17}{20} \cdot \frac{16}{19} = 0,2842 \left(= 1 - \frac{\binom{3}{0} \cdot \binom{17}{2}}{\binom{20}{2}} \right)$

6. Smart Home.

a) $\binom{5}{1} + \binom{5}{2} + \binom{5}{3} + \binom{5}{4} + \binom{5}{5} = 31$ (oder $2^5 - 1 = 31$)

b) $\binom{5}{3} + \binom{5}{4} + \binom{5}{5} = 16$

7. **Passwort.** a) $\frac{1}{26^5 \cdot 10}$ b) $\frac{1}{26^4 \cdot 10}$ c) $\frac{1}{26 \cdot 3! \cdot 10}$

8. Computer.

a) $3 \cdot 3 \cdot 8 \cdot 4 \cdot 4 \cdot 3 \cdot 2 = 6912$

b) $3 \cdot 3 \cdot 8 \cdot 4 \cdot 4 \cdot 2 \cdot 2 + 3 \cdot 3 \cdot 5 \cdot 4 \cdot 4 \cdot 1 \cdot 2 = 6048$

9. Qualitätskontrolle.

a) $P(A) \cdot P(\text{def}|A) + P(B) \cdot P(\text{def}|B) = P(\text{def})$, also $0,6 \cdot P(\text{def}|A) + 0,4 \cdot 0,05 = 0,08$ und $P(\text{def}|A) = 0,1$

b) Satz von Bayes: $P(A|\text{def}) = \frac{P(\text{def}|A) \cdot P(A)}{P(\text{def})} = \frac{0,1 \cdot 0,6}{0,08} = 0,75$

10. **Tourist.** a) $10! = 3\,628\,800$ b) $\binom{10}{6} = 210$ c) $\binom{8}{6} + \binom{8}{4} = 28 + 70 = 98$

11. **Familie.** Drei Möglichkeiten (J/M, M/J, J/J), zwei davon enthalten ein Mädchen, also $p = \frac{2}{3}$

12. **Wirtschafts-Speeddating.** $P(X \geq 1) = 1 - P(X = 0) = 1 - \frac{45}{50} \cdot \frac{44}{49} \cdot \frac{43}{48} \cdot \dots \cdot \frac{38}{43} = 0,5985 \left(= 1 - \frac{\binom{5}{0} \cdot \binom{45}{8}}{\binom{50}{8}} \right)$

13. **Spam-Mails.** S = Spam, G = enthält "Geld"

a) $P(S) = 0,2$, $P(R) = 0,8$, $P(G|S) = 0,37$, $P(G|R) = 0,0275$

Wir brauchen außerdem $P(G) = P(G|S) \cdot P(S) + P(G|R) \cdot P(R) = 0,37 \cdot 0,2 + 0,0275 \cdot 0,8 = 0,096$

Satz von Bayes: $P(S|G) = \frac{P(G|S) \cdot P(S)}{P(G)} = \frac{0,37 \cdot 0,2}{0,096} = 0,7708$

b) Das Wort "Geld" kommt vor allem in Spam-Mails vor. Wenn mehr reguläre Mails "Geld" enthalten, verliert es an Aussagekraft als Spam-Merkmal. Der Spam-Filter kann sich daher weniger sicher sein, dass eine Mail, die "Geld" enthält, tatsächlich Spam ist – die Wahrscheinlichkeit sinkt also.

In der Praxis wird der Satz von Bayes oft zur Spam-Erkennung genutzt, meist in Form des sogenannten Naive Bayes Classifiers. Dieser erweitert den Ansatz durch vereinfachende Annahmen, um mehrere Wörter gleichzeitig zu berücksichtigen, da ein Wort allein nicht ausreicht, um Spam zu identifizieren.

Diskrete Wahrscheinlichkeitsverteilungen

1. Würfel.

a) $p = \frac{1}{6}$, $P(X \geq 3) = 1 - P(X = 0) - P(X = 1) - P(X = 2)$
 $= 1 - \left(\frac{5}{6}\right)^{12} - \binom{12}{1} \cdot \left(\frac{1}{6}\right)^1 \cdot \left(\frac{5}{6}\right)^{11} - \binom{12}{2} \cdot \left(\frac{1}{6}\right)^2 \cdot \left(\frac{5}{6}\right)^{10} = 0,3226$

b) $p = \frac{1}{2}$, $P(X = 6) = \binom{12}{6} \cdot \left(\frac{1}{2}\right)^6 \cdot \left(\frac{1}{2}\right)^6 = 0,2256$

c) $p = \frac{1}{3}$, $P(X \leq 1) = P(X = 0) + P(X = 1) = \left(\frac{2}{3}\right)^{12} + \binom{12}{1} \cdot \left(\frac{1}{3}\right)^1 \cdot \left(\frac{2}{3}\right)^{11} = 0,05395$

2. Münze. $n = 10$, Erfolg = Kopf, $p = 0,5$

a) $P(X = 4) = 0,2051$

b) $P(X \leq 8) = 1 - P(X = 9) - P(X = 10) = 0,9893$

c) $P(X = 0) + P(X = 10) = 0,0020$

3. Hotel.

a) $E(X) = 52 \cdot 0,95 = 49,4$

b) $P(X = 52) = 0,95^{52} = 0,0694$

c) $P(X \leq 50) = 1 - 0,95^{52} - \binom{52}{51} \cdot 0,95^{51} \cdot 0,05^1 = 0,7405$

4. Assessment Center.

a) $E(X) = n \cdot p = 8 \cdot 0,2 = 1,6$

b) $P(X = 0 \text{ korrekt}) = P(X = 8 \text{ falsch}) = 0,8^8 = 0,1678$

c) $n = 8$, $p = 0,2$; $P(X \geq 5 \text{ korrekt}) = \binom{8}{5} \cdot 0,2^5 \cdot 0,8^3 + \binom{8}{6} \cdot 0,2^6 \cdot 0,8^2 + \dots = 0,0104 > 0,01 \rightarrow \text{nein}$

5. Backpacker.

0	1	2	3	4	5
0,6957	0,2618	0,0394	0,0030	0,0001	0,0000

6. **Glücksspiel.** $E(X) = 100 \cdot P(X = 0) + 10 \cdot P(X = 1) + 10 \cdot P(X = 2) + 4 \cdot P(X = 3)$
 $= 100 \cdot 0,0009766 + 10 \cdot 0,009766 + 10 \cdot 0,04395 + 4 \cdot 0,1172 = \$1,11 > \$1 \implies \text{erwarteter Gewinn} < 0$

7. **Smartphone.** $P(X \leq 1) = P(X = 0) + P(X = 1) = \binom{25}{0} \cdot 0,03^0 \cdot 0,97^{25} + \binom{25}{1} \cdot 0,03^1 \cdot 0,97^{24} = 0,8280$
8. **Retouren.** Behalten: Gewinn = $99 - 64 = 35 \text{ €}$, $p = 0,86$
 Retour, brauchbar: Gewinn = $50 - 64 - 6 = -20 \text{ €}$ (Verlust), $p = 0,14 \cdot 0,91 = 0,1274$
 Retour, unbrauchbar: Gewinn = $-64 - 6 = -70 \text{ €}$ (Verlust), $p = 0,14 \cdot 0,09 = 0,0126$
 $E(X) = 35 \cdot 0,86 + (-20) \cdot 0,1274 + (-70) \cdot 0,0126 = 26,67 \text{ €}$
9. **Kopien.** 16 Kopien sind erforderlich.
 16 Kopien: $P(X \leq 16) = 1 - P(X = 17) - P(X = 18) = 1 - \binom{18}{17} \cdot 0,75^{17} \cdot 0,25^1 - 0,75^{18} = 0,9605 > 0,95$
 15 Kopien: $P(X \leq 15) = 1 - P(X = 16) - P(X = 17) - P(X = 18)$
 $= 1 - \binom{18}{16} \cdot 0,75^{16} \cdot 0,25^2 - \binom{18}{17} \cdot 0,75^{17} \cdot 0,25^1 - 0,75^{18} = 0,8647 < 0,95$

Stetige Wahrscheinlichkeitsverteilungen

1. IQ.

- a) $P(X \leq x) = 0,1$, also $z = -1,28$ und $x = 100 - 1,28 \cdot 15 = 80,8$
- b) $P(X \leq 85) = P(Z \leq \frac{85-100}{15}) = P(Z \leq -1,0) = 1 - P(Z \leq 1,0) = 0,1587$; $280 \cdot 0,1587 = 44,4$ Personen
- c) $P(X \leq Q_1) = 0,25 \implies z = -0,67$ und $Q_1 = 100 - 0,67 \cdot 15 = 89,95$; $Q_2 = Md = \mu = 100$
 $P(X \leq Q_3) = 0,75 \implies z = 0,67$ und $Q_3 = 100 + 0,67 \cdot 15 = 110,05$

2. Schrauben.

- a) $P(X < 50,5) = P(Z < \frac{50,5-50}{0,4}) = P(Z < 1,25) = 0,8944$
- b) $P(49 \leq X \leq 51) = P(X \leq 51) - P(X < 49) = P(Z \leq 2,5) - P(Z < -2,5)$
 $= P(Z \leq 2,5) - (1 - P(Z < 2,5)) = 0,9938 - 1 + 0,9938 = 0,9876 < 0,99 \rightarrow \text{nein}$
- c) $P(X > 50,75) = 1 - P(X \leq 50,75) = 1 - P(Z \leq 1,88) = 1 - 0,9699 = 0,0301$
- d) Kürzeste 5%: $z = -1,6449$; $50 - 1,6449 \cdot 0,4 = 49,34 \text{ mm}$

3. Zulassungstests.

- a) $P(X > 360) = 1 - P(X \leq 360) = 1 - P(Z \leq \frac{360-300}{50}) = 1 - P(Z \leq 1,20) = 0,1151$
- b) $P(X \leq 275) = P(Z \leq \frac{275-300}{50}) = P(Z \leq -0,50) = 1 - P(Z \leq 0,50) = 0,3085 = 30,85\%$
- c) Untere 20%: $z = -0,84$; $x = \mu + z\sigma = 300 - 0,84 \cdot 50 = 258$ Punkte
- d) Beste 5%: $z = 1,6449$; $x = \mu + z\sigma = 300 + 1,6449 \cdot 50 = 382,25$ Punkte.
 Mit 376 Punkten liegt man nicht darüber und gehört folglich nicht zu den besten 5%.
 Alternativer Ansatz: $P(X \geq 376) = 1 - P(X < 376) = 1 - P(Z \leq \frac{376-300}{50}) = 1 - P(Z \leq 1,52) = 0,0643$, also nur beste 6,43%, nicht beste 5%.
- e) Die mittleren 50% entsprechen dem Bereich zwischen dem ersten und dem dritten Quartil:
 Q1: 25%: $z = -0,6745$; $x = 300 - 0,6745 \cdot 50 = 266,28$ Punkte
 Q3: 75%: $z = 0,6745$; $x = 300 + 0,6745 \cdot 50 = 333,73$ Punkte
- f) $P(\bar{X} \geq 306,5) = 1 - P(\bar{X} < 306,5) = 1 - P(Z < \frac{306,5-300}{50/\sqrt{25}}) = 1 - P(Z < 0,65) = 0,2578$
 Ein Durchschnitt von 306,5 Punkten wäre kein Hinweis auf Unregelmäßigkeiten. Eine solche Abweichung von den üblichen 300 Punkten ist bei 25 Personen nicht besonders unwahrscheinlich und kann daher leicht zufällig auftreten.
- g) Beste 30%: $z = 0,52$; $z = \frac{x-\mu}{\sigma} \implies \sigma = \frac{x-\mu}{z} = \frac{504,5-450}{0,52} = 104,81$

4. **Äpfel.** $10 \text{ Äpfel} \geq 2000 \text{ g} \implies \text{Durchschnittsgewicht pro Apfel} \geq \frac{2000}{10} = 200 \text{ g}$
 $P(\bar{X} \geq 200) = 1 - P(\bar{X} < 200) = 1 - P(Z < \frac{200-214}{17/\sqrt{10}}) = 1 - P(Z < -2,60) = P(Z < 2,60) = 0,9953$

5. **LKW-Beladungszeiten.**

- a) $P(X > 45) = 1 - P(X \leq 45) = 1 - P(Z \leq \frac{45-34}{12}) = 1 - P(Z \leq 0,92) = 1 - 0,8212 = 0,1788$
b) $P(X \leq 30) = P(Z \leq \frac{30-34}{12}) = P(Z \leq -0,33) = 1 - P(Z \leq 0,33) = 1 - 0,6293 = 0,3707$
c) 95%: $z = 1,6449$; $z = \frac{x-\mu}{\sigma} \implies x = \mu + z \cdot \sigma = 34 + 1,6449 \cdot 12 = 53,74 \text{ Minuten}$,
also um 9:06 Uhr starten
d) Sind die Beladungsprozesse standardisiert und treten kaum Ausreißer auf, kann die Annahme einer Normalverteilung plausibel sein. Wenn aber Ausreißer auftreten, sind dies meist Verzögerungen und Störungen, die zu längeren Beladungszeiten führen, während extreme Verkürzungen kaum möglich sind – daher wäre eher eine rechtsschiefe Verteilung zu erwarten.

6. **Handgepäck.**

- a) $P(X > 8) = 1 - P(X \leq 8) = 1 - P(Z \leq \frac{8-5,6}{1,2}) = 1 - P(Z \leq 2) = 1 - 0,9772 = 0,0228$
b) $P(X < 5) = P(Z < \frac{5-5,6}{1,2}) = P(Z < -0,5) = 1 - P(Z < 0,5) = 1 - 0,6915 = 0,3085$
c) $P(4 \leq X \leq 6) = P(X \leq 6) - P(X < 4) = P(Z \leq \frac{6-5,6}{1,2}) - P(Z < \frac{4-5,6}{1,2})$
 $= P(Z \leq 0,33) - P(Z < -1,33) = P(Z \leq 0,33) - (1 - P(Z < 1,33)) = 0,5375$
d) 1% schwerste: $z = 2,33$; $z = \frac{x-\mu}{\sigma} \implies x = \mu + z\sigma = 5,6 + 2,33 \cdot 1,2 = 8,396 \text{ kg}$
e) Gesamtgewicht $> 1160 \text{ kg} \implies \text{Durchschnittsgewicht} > \frac{1160}{200} = 5,8 \text{ kg}$
 $P(\bar{X} > 5,8) = 1 - P(\bar{X} \leq 5,8) = 1 - P(Z \leq \frac{5,8-5,6}{1,2/\sqrt{200}}) = 1 - P(Z \leq 2,36) = 0,0091 = 0,91\% < 1\%$

7. **Auto.** $P(X > 5,5) = 0,25$, also $z = 0,67$; $\sigma = \frac{5,5-5,2}{0,67} = 0,44476$

$$P(X < 5) = P(Z < \frac{5-5,2}{0,44476}) = P(Z < -0,45) = 1 - P(Z < 0,45) = 1 - 0,6736 = 0,3264$$

Konfidenzintervalle und Stichprobengröße

1. **Bierpreis.** $4,87 \pm 1,96 \frac{0,41}{\sqrt{64}} = [4,77, 4,97 \text{ €}]$

2. **Nutzungsdauer.** a) $42 \pm 1,96 \frac{7}{\sqrt{400}} = [41,31, 42,69]$ b) $n = (z_{\alpha/2} \frac{\sigma}{E})^2 = (1,96 \frac{12}{1})^2 = 553,2 \approx 554$

3. **Wahl.**

a) $z_{\alpha/2} = 2,5758 \implies 0,09 \pm 2,5758 \cdot \sqrt{\frac{0,09 \cdot 0,91}{800}} = [6,39\% - 11,61\%]$

b) $n = 0,09 \cdot 0,91 \cdot \left(\frac{2,5758}{0,015}\right)^2 = 2415,1 \approx 2416 \text{ Personen}$

4. **Zahlungsbereitschaft.** $E = \frac{6,15-5,85}{2} = 0,15$, $E = z_{\alpha/2} \cdot \frac{s}{\sqrt{n}} \implies 0,15 = z_{\alpha/2} \cdot \frac{0,9}{\sqrt{100}} \implies z_{\alpha/2} = 1,67$
 $\implies \alpha/2 \approx 5\% \implies \alpha \approx 10\% \implies \text{Konfidenzniveau} \approx 90\%$

5. **Produktbewertung.**

a) $t_{\alpha/2} = 2,0639$ ($\alpha = 5\%$, $df = 25 - 1 = 24$), $7,22 \pm 2,0639 \frac{1,41}{\sqrt{25}} = [6,638, 7,802]$

- b) Größer, weil $t_{\alpha/2}$ größer wird (mathematische Erklärung) und weil das Intervall größer werden muss, wenn man sicherer sein will, dass der tatsächliche Wert im Intervall liegt (logische Erklärung).

6. **Verkehrspolitik.** $E = z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$, $n = 1000$

Fall 1: $E = 0,031$, $\hat{p} = 0,5 \implies z_{\alpha/2} \approx 1,96$, Fall 2: $E = 0,014$, $\hat{p} = 0,05 \implies z_{\alpha/2} \approx 2,03$

In beiden Fällen ist das Konfidenzniveau $\approx 95\%$.

7. **Mineralwasser.** 100%

Hypothesentests

1. **Kinder.** $H_0: \mu = 27$, $H_1: \mu < 27$ (linksseitig)

$$z_{kritisch} = -1,6449 \quad (\alpha = 0,05), \quad z = \frac{26,43-27}{5,05/\sqrt{1065}} = -3,683$$

$z < z_{kritisch}$, H_0 verwerfen. Das Durchschnittsgewicht liegt signifikant unter 27 kg.

2. **Neuer Fernseher.** $H_0: p = 0,5$, $H_1: p > 0,5$ (rechtsseitig)

$$z_{kritisch} = 1,6449 \quad (\alpha = 0,05), \quad \hat{p} = \frac{214}{400} = 0,535, \quad z = \frac{0,535-0,5}{\sqrt{\frac{0,5 \cdot 0,5}{400}}} = 1,40$$

$z < z_{kritisch}$, H_0 nicht verwerfen. Der Anteil der Personen, die in den nächsten drei Jahren einen neuen Fernseher kaufen möchten, liegt nicht signifikant über 50%.

3. **Online-Zeit.** $H_0: \mu = 3$, $H_1: \mu > 3$ (rechtsseitig)

$$t_{kritisch} = 1,8946 \quad (\alpha = 0,05, df = 7), \quad t = \frac{3,75-3}{1,535/\sqrt{8}} = 1,382$$

$t < t_{kritisch}$, H_0 nicht verwerfen. Junge Leute sind im Durchschnitt nicht signifikant länger als drei Stunden pro Tag online.

4. **Cola.** H_0 : Variablen sind unabhängig, H_1 : Variablen sind abhängig

$$\chi^2_{kritisch} = 3,841 \quad (\alpha = 0,05, df = 1), \quad \chi^2 = 1,499$$

E_i	Männer	Frauen	$\frac{(O_i-E_i)^2}{E_i}$	Männer	Frauen
Zero	124,23	118,77	Zero	0,3686	0,3855
Diet/Light	125,77	120,23	Diet/Light	0,3641	0,3808

$\chi^2 < \chi^2_{kritisch}$, H_0 nicht verwerfen. Die Präferenz hängt nicht signifikant vom Geschlecht ab.

5. **Markenbekanntheit.** $H_0: p = 0,25$, $H_1: p > 0,25$ (rechtsseitig)

$$z_{kritisch} = 1,6449 \quad (\alpha = 0,05), \quad z = \frac{0,28-0,25}{\sqrt{\frac{0,25 \cdot 0,75}{400}}} = 1,3856$$

$z < z_{kritisch}$, H_0 nicht verwerfen. Die Bekanntheit der Marke liegt nicht signifikant über 25%.

6. **Eistee.**

- a) $H_0: \mu = 3$, $H_1: \mu > 3$ (rechtsseitig)

$$t_{kritisch} = 1,8946 \quad (\alpha = 0,05, df = 7), \quad t = \frac{3,375-3}{3,543/\sqrt{8}} = 0,2996$$

$t < t_{kritisch}$, H_0 nicht verwerfen. Es gibt keine ausreichenden Hinweise, dass der Durchschnittsverbrauch von Eistee über drei Litern liegt.

- b) $3 + t_{kritisch} \cdot \frac{s}{\sqrt{n}} = 3 + 1,8946 \cdot \frac{3,543}{\sqrt{8}} = 5,37$ Liter.

7. **Orangensaft.** $H_0: \mu_1 = \mu_2$, $H_1: \mu_1 \neq \mu_2$ (zweiseitig)

$$z_{kritisch} = \pm 1,96 \quad (\alpha = 0,05), \quad z = \frac{34-33,1}{\sqrt{\frac{1,4^2}{50} + \frac{1,2^2}{50}}} = 3,09$$

$z > z_{kritisch}$, H_0 verwerfen. Der Unterschied zwischen den beiden Marken ist signifikant.

8. **Ostsee.** Weniger als 50%, daher linksseitiger Test, und $p = 0,0119$, also $z = -2,26$

$$z = \frac{\hat{p}-p}{\sqrt{\frac{p(1-p)}{n}}} \Rightarrow -2,26 = \frac{\hat{p}-0,5}{\sqrt{\frac{0,5(1-0,5)}{800}}} \Rightarrow \hat{p} = 0,4600, x = \hat{p} \cdot n = 0,46 \cdot 800 = 368 \text{ Personen}$$

9. **Kundenzufriedenheit.** Notation: dieses Jahr $\rightarrow d$, letztes Jahr $\rightarrow l$

a) $\bar{X}_d = 91,80, s_d = 14,10, \bar{X}_l = 89,36, s_l = 12,66$ (aus csv-Datei)

b) $H_0: \mu_d = \mu_l, H_1: \mu_d > \mu_l$

$$z_{kritisch} = 1,6449 (\alpha = 0,05), z = \frac{91,8-89,36}{\sqrt{\frac{14,1^2}{250} + \frac{12,66^2}{250}}} = 2,036$$

$z > z_{kritisch}$, H_0 verwerfen. Der Anstieg der Kundenzufriedenheit ist signifikant.

c) $H_0: \mu_d = 90, H_1: \mu_d > 90$ (rechtsseitig)

$$z_{kritisch} = 1,6449 (\alpha = 0,05), z = \frac{91,8-90}{14,1/\sqrt{250}} = 2,019$$

$z > z_{kritisch}$, H_0 verwerfen. Die durchschnittliche Kundenzufriedenheit liegt in diesem Jahr signifikant über 90 Punkten.

Für $\alpha = 0,01$ hätte man $z_{kritisch} = 2,3263$, also wäre der Wert dann nicht signifikant.

d) $H_0: p_d = 0,5, H_1: p_d > 0,5$ (rechtsseitig)

$$z_{kritisch} = 1,6449 (\alpha = 0,05), \hat{p}_d = \frac{135}{250} = 0,54, z = \frac{0,54-0,5}{\sqrt{\frac{0,5 \cdot (1-0,5)}{250}}} = 1,265$$

$z < z_{kritisch}$, H_0 nicht verwerfen. Der Anteil der Passagiere mit einer Zufriedenheit von mindestens 90 Punkten liegt in diesem Jahr nicht signifikant über 50%.

e) $H_0: \mu_l = 90, H_1: \mu_l < 90$ (linksseitig)

$$z_{kritisch} = -1,6449 (\alpha = 0,05), z = \frac{89,36-90}{12,66/\sqrt{250}} = -0,7996$$

$z > z_{kritisch}$, H_0 nicht verwerfen. Die durchschnittliche Kundenzufriedenheit lag im letzten Jahr nicht signifikant unter 90 Punkten.

$z = -0,7996 \approx -0,80$ ergibt einen p-Wert von 0,2119. Das bedeutet, dass die Wahrscheinlichkeit über 20% läge, einen Durchschnitt von 89,36 Punkten oder weniger in der Stichprobe zu erhalten, wenn der Mittelwert in der Grundgesamtheit aller Passagiere 90 Punkte wäre. Das ist relativ wahrscheinlich (mehr als 5%), also reicht ein Wert von 89,36 in der Stichprobe nicht aus, um zu sagen, dass der tatsächliche Durchschnitt der Grundgesamtheit unter 90 Punkten liegt.

10. **Wellness.** H_0 : unabhängig (Altersgruppe hat keinen Einfluss), H_1 : abhängig (sie hat einen Einfluss)

$$\chi^2_{kritisch} = 3,841 (\alpha = 0,05, df = 1), \chi^2 = 4,392$$

E_i	< 50	≥ 50	$\frac{(O_i-E_i)^2}{E_i}$	< 50	≥ 50
interessiert	82,0	82,0	interessiert	1,4756	1,4756
nicht interessiert	168,0	168,0	nicht interessiert	0,7202	0,7202

$\chi^2 > \chi^2_{kritisch}$, H_0 verwerfen. Der Unterschied zwischen den Altersgruppen ist signifikant.

11. **Bilanz.** H_0 : Benford-Verteilung gilt, H_1 : Sie gilt nicht

$$\chi^2_{kritisch} = 15,51 (\alpha = 0,05, df = 8), \chi^2 = 6,403 (\sum_i O_i = 758, \text{ z.B. } E_1 = 758 \cdot 0,301 = 228,2)$$

	1	2	3	4	5	6	7	8	9
E_i	228,2	133,5	94,7	73,5	60,0	50,7	44,0	38,8	34,7
$\frac{(O_i-E_i)^2}{E_i}$	2,086	0,424	0,475	0,271	2,407	0,149	0,356	0,081	0,155

$\chi^2 < \chi^2_{kritisch}$, H_0 nicht verwerfen. Die Abweichung von der Benford-Verteilung ist nicht signifikant, es gibt also keine besonderen Hinweise auf eine Manipulation der Bilanz.

12. **Antibiotika.** $\bar{X}_A = \frac{1}{50}(7 \cdot 1 + 24 \cdot 2 + \dots) = 2,300$ Tage, $\bar{X}_B = 2,640$ Tage, $s_A = 0,7890$, $s_B = 0,8514$
 $H_0: \mu_A = \mu_B$, $H_1: \mu_A \neq \mu_B$ (zweiseitig)
 $z_{kritisch} = \pm 1,96$ ($\alpha = 5\%$), $z = \frac{2,300 - 2,640}{\sqrt{\frac{0,7890^2}{50} + \frac{0,8514^2}{50}}} = -2,071$
 $|z| > z_{kritisch}$, H_0 verwerfen. Es gibt einen signifikanten Unterschied in der durchschnittlichen Zeit, bis die beiden Antibiotika wirken.
13. **Klausuren.** $H_0: p = 0,5$, $H_1: p < 0,5$ (linksseitig)
 $z_{kritisch} = -1,6449$ ($\alpha = 0,05$), $\hat{p} = \frac{49}{117} = 0,4188$, $z = \frac{0,4188 - 0,5}{\sqrt{\frac{0,5 \cdot 0,5}{117}}} = -1,757$
 $z < z_{kritisch}$, H_0 verwerfen. Signifikant weniger als 50% der Studierenden können eine korrekte Interpretation eines Konfidenzintervalls angeben.
 $p = 0,0392 < 0,05 = \alpha$ führt ebenfalls zum Ablehnen von H_0 .
14. **Überstunden.** $H_0: p = 0,25$, $H_1: p > 0,25$ (rechtsseitig)
 $z_{kritisch} = 1,6449$ ($\alpha = 0,05$), $\hat{p} = \frac{56 + 19 + 5}{250} = 0,32$, $z = \frac{0,32 - 0,25}{\sqrt{\frac{0,25 \cdot (1 - 0,25)}{250}}} = 2,556$
 $z > z_{kritisch}$, H_0 verwerfen. Signifikant mehr als ein Viertel der Angestellten der Branche macht regelmäßig mehr als fünf Überstunden pro Woche.
15. **Anwendung der Benford-Verteilung.** Um einen χ^2 -Anpassungstest durchführen zu können, müssen alle $E_i \geq 5$ sein. Die kleinste Wahrscheinlichkeit der Benford-Verteilung ist $p_9 = 0,0458$. Es muss $E_9 = n \cdot p_9 \geq 5$ gelten, also $n \geq \frac{5}{p_9} = \frac{5}{0,0458} = 109,17$.

Lösungen zu den Klausuren

Klausur A

1. a) $\bar{X} = 23,50$; $M_d = 23,50$; $s^2 = 14,94$; $s = 3,8658$
b) $H_0: \mu = 25$, $H_1: \mu < 25$ (linksseitig)
 $t_{kritisch} = -1,8331$ ($\alpha = 0,05$, $df = 9$), $t = \frac{23,5-25}{3,8658/\sqrt{10}} = -1,227$
 $t > t_{kritisch}$, H_0 nicht verwerfen. Keine ausreichenden Hinweise, dass das Müsli weniger als 25g Zucker pro 100 g enthält.
c) $Q_1 = 21$; $Q_3 = 26$; $IQR = Q_3 - Q_1 = 5$, milde Ausreißer müssten über 33,5 bzw. unter 13,5 liegen, also keine Ausreißer
2. a) $p = \frac{4}{9} \cdot \frac{3}{8} \cdot \frac{2}{7} \cdot \frac{1}{6} = 0,00794 \left(= \frac{\binom{4}{4} \cdot \binom{5}{0}}{\binom{9}{4}} \right)$
b) $p = \frac{5}{9} \cdot \frac{4}{8} \cdot \frac{3}{7} \cdot \frac{2}{6} = 0,0397 \left(= \frac{\binom{5}{4} \cdot \binom{4}{0}}{\binom{9}{4}} \right)$
c) $E(X) = 50 \text{ €} \cdot \frac{1}{126} = 0,3968 \text{ €}$ erwarteter Gewinn pro Los, also Anzahl Lose = $\frac{10,000 \text{ €}}{0,3968 \text{ €}} = 25,200$
d) $P(\text{mindestens eins gewinnt}) = 1 - P(\text{keins gewinnt}) = 1 - \left(\frac{125}{126}\right)^3 = 1 - 0,976 = 2,4\%$
3. a) $P(X < 300) = P(Z < \frac{300-303}{1,6}) = P(Z < -1,88) = 1 - P(Z \leq 1,88) = 1 - 0,9699 = 0,0301$
b) $P(X > 305) = 1 - P(X \leq 305) = 1 - P(Z \leq \frac{305-303}{1,6}) = 1 - P(Z \leq 1,25) = 1 - 0,8944 = 0,1056$
c) $P(X \leq x) = 10\% \Rightarrow z = -1,2816$; $x = \mu + z\sigma = 303 - 1,2816 \cdot 1,6 = 300,95$
d) $P(X \leq 300) = 0,01 \Rightarrow z = -2,3263$; $z = \frac{x-\mu}{\sigma} \Rightarrow -2,3263 = \frac{300-\mu}{1,6} \Rightarrow \mu = 303,72$
4. a) $\hat{p} = \frac{191}{540} = 0,3537$, $z_{\alpha/2} = 1,6449$ ($\alpha = 0,1$), $0,3537 \pm 1,6449 \cdot \sqrt{\frac{0,3537 \cdot 0,6463}{540}} = [0,3199, 0,3875]$
b) $z = 2,3263$ für $\alpha = 0,01$ (rechtsseitig). $z = \frac{\hat{p}-p}{\sqrt{\frac{p \cdot (1-p)}{n}}} \Rightarrow 2,3263 = \frac{\hat{p}-0,3333}{\sqrt{\frac{0,3333 \cdot 0,6667}{540}}}$
 $\Rightarrow \hat{p} = 0,3805 \Rightarrow x \geq 0,3805 \cdot 540 = 205,46 \approx 206$ Personen.
5. *61 Tickets*: Binomialverteilung mit $n = 61$, erscheinen = Erfolg, $p = 0,97$
 $P(X = 61 \text{ erscheinen}) = \binom{61}{61} \cdot 0,97^{61} \cdot 0,03^0 = 0,1560$ (oder einfach $0,97^{61}$)
Erwartete Kosten: $E(X) = 0,1560 \cdot 800 \text{ €} = 124,79 \text{ €}$
Zusätzliche Erlöse: 300 €
Differenz: $300 \text{ €} - 124,79 \text{ €} = 175,21 \text{ €}$
62 Tickets: Binomialverteilung mit $n = 62$, erscheinen = Erfolg, $p = 0,97$
 $P(X = 61 \text{ erscheinen}) = \binom{62}{61} \cdot 0,97^{61} \cdot 0,03^1 = 0,2901$
 $P(X = 62 \text{ erscheinen}) = \binom{62}{62} \cdot 0,97^{62} \cdot 0,03^0 = 0,1513$
Erwartete Kosten: $E(X) = 0,2901 \cdot 800 \text{ €} + 0,1513 \cdot 1600 \text{ €} = 474,19 \text{ €}$
Zusätzliche Erlöse: 600 €
Differenz: $600 \text{ €} - 474,19 \text{ €} = 125,81 \text{ €}$
Beste Option: 61 Tickets verkaufen

Klausur B

1. a) $n \cdot p = 6 \cdot 0,1 = 0,6$
b) $p = 0,9^6 = 0,531441$
c) $P(X \geq 2) = 1 - P(X = 0) - P(X = 1) = 1 - \binom{6}{0} \cdot 0,1^0 \cdot 0,9^6 - \binom{6}{1} \cdot 0,1^1 \cdot 0,9^5 = 0,1143\%$
d) $\frac{9}{10} \cdot \frac{8}{10} \cdot \frac{7}{10} \cdot \frac{6}{10} \cdot \frac{5}{10} \cdot \frac{4}{10} = 0,06048$
2. a) $\bar{X} = 4,2125$, $M_d = 4,40$, Spannweite = 5,80, $s = 1,7780$
b) $Q_1 = 3,15$, $Q_2 = 4,40$, $Q_3 = 5,20$
75% der Personen haben bis zu 5,2 kg abgenommen (oder 25% haben mindestens 5,2 kg abgenommen)
c) $H_0: \mu = 4$, $H_1: \mu > 4$ (rechtsseitig)
 $t_{kritisch} = 1,8946$ ($\alpha = 0,05$, $df = 7$), $t = 0,3380$
 $t < t_{kritisch}$, H_0 nicht verwerfen. Die Personen haben im Schnitt nicht signifikant mehr als 4 kg abgenommen.
3. a) $P(X \leq 7) = P(Z \leq \frac{7-5,8}{1,6}) = P(Z \leq 0,75) = 0,7734$
b) Top 10%: $z = 1,2816$ $x = \mu + z \cdot \sigma = 5,8 + 1,2816 \cdot 1,6 = 7,85$ Jahre
c) $P(X < 3) = P(Z < \frac{3-5,8}{1,6}) = P(Z \leq -1,75) = 1 - P(Z < 1,75) = 1 - 0,9599 = 0,0401$
d) Untere 2,5%: $z = -2,3263$ $z = \frac{x-\mu}{\sigma} \implies \mu = x - z \cdot \sigma = 3 - (-2,3263) \cdot 1,6 = 6,72$ Jahre
4. a) $\hat{y} = 312,23 + 1,76 \cdot x_{TV} + 3,92 \cdot x_{Banner} + 32,85 \cdot x_{Angebot}$
Ohne Marketing-Aktivitäten ist pro Woche ein durchschnittlicher Umsatz von 312.230 € zu erwarten.
1000 € für Fernsehwerbung erhöhen den Umsatz um durchschnittlich 1760 €.
1000 € für Banner erhöhen den Umsatz um durchschnittlich 3920 €.
Eine Senkung des Preises um 10% erhöht den Umsatz um durchschnittlich 32.850 €.
b) $H_0: \beta_j = 0$, $H_1: \beta_j \neq 0$
 $t_{kritisch} = 2,2010$ ($\alpha = 5\%$, $df = 15 - 4 = 11$).
Der Koeffizient der Fernsehwerbung ist nicht signifikant, es liegt also kein signifikanter Einfluss der Fernsehwerbung auf den Umsatz vor. Die anderen Koeffizienten sind signifikant, Banner und Preissenkung haben also einen signifikanten Einfluss auf den Umsatz. Die Konstante ist ebenfalls signifikant, d.h. dass der Umsatz auch ohne Marketing-Aktivitäten signifikant über 0 liegt.
5. a) Rechtsseitiger z-Test, $z_{kritisch} = 2,3263$ ($\alpha = 0,01$)
Kritische Reaktionszeit: $z_{kritisch} = \frac{\bar{X}_{kritisch} - \mu}{\sigma/\sqrt{n}} \implies \bar{X}_{kritisch} = 220 + 2,3263 \cdot \frac{25}{\sqrt{100}} = 225,82$
b) Bei einer größeren Stichprobe wäre die kritische Reaktionszeit kleiner als 225,82.
Mathematische Erklärung: Wenn n größer wird, dann wird ein kleinerer Wert zu 220 addiert.
Intuitive Erklärung: In einer größeren Stichprobe hat man mehr Informationen, also kann man bereits bei kleineren Abweichungen von Signifikanz ausgehen.

Statistische Tabellen

Kumulative Standardnormalverteilung

z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964
2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974
2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,9980	0,9981
2,9	0,9981	0,9982	0,9982	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986
3,0	0,9987	0,9987	0,9987	0,9988	0,9988	0,9989	0,9989	0,9989	0,9990	0,9990
3,1	0,9990	0,9991	0,9991	0,9991	0,9992	0,9992	0,9992	0,9992	0,9993	0,9993
3,2	0,9993	0,9993	0,9994	0,9994	0,9994	0,9994	0,9994	0,9995	0,9995	0,9995
3,3	0,9995	0,9995	0,9995	0,9996	0,9996	0,9996	0,9996	0,9996	0,9996	0,9997
3,4	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9998
3,5	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998

Inverse Standardnormalverteilung

α	0,25	0,1	0,05	0,025	0,01	0,005	0,001	0,0005
z_{α}	0,6745	1,2816	1,6449	1,9600	2,3263	2,5758	3,0902	3,2905

Inverse t-Verteilung

df	$\alpha =$	0,25	0,1	0,05	0,025	0,01	0,005	0,001	0,0005
1		1,0000	3,0777	6,3138	12,7062	31,8205	63,6567	318,3088	636,6192
2		0,8165	1,8856	2,9200	4,3027	6,9646	9,9248	22,3271	31,5991
3		0,7649	1,6377	2,3534	3,1824	4,5407	5,8409	10,2145	12,9240
4		0,7407	1,5332	2,1318	2,7764	3,7469	4,6041	7,1732	8,6103
5		0,7267	1,4759	2,0150	2,5706	3,3649	4,0321	5,8934	6,8688
6		0,7176	1,4398	1,9432	2,4469	3,1427	3,7074	5,2076	5,9588
7		0,7111	1,4149	1,8946	2,3646	2,9980	3,4995	4,7853	5,4079
8		0,7064	1,3968	1,8595	2,3060	2,8965	3,3554	4,5008	5,0413
9		0,7027	1,3830	1,8331	2,2622	2,8214	3,2498	4,2968	4,7809
10		0,6998	1,3722	1,8125	2,2281	2,7638	3,1693	4,1437	4,5869
11		0,6974	1,3634	1,7959	2,2010	2,7181	3,1058	4,0247	4,4370
12		0,6955	1,3562	1,7823	2,1788	2,6810	3,0545	3,9296	4,3178
13		0,6938	1,3502	1,7709	2,1604	2,6503	3,0123	3,8520	4,2208
14		0,6924	1,3450	1,7613	2,1448	2,6245	2,9768	3,7874	4,1405
15		0,6912	1,3406	1,7531	2,1314	2,6025	2,9467	3,7328	4,0728
16		0,6901	1,3368	1,7459	2,1199	2,5835	2,9208	3,6862	4,0150
17		0,6892	1,3334	1,7396	2,1098	2,5669	2,8982	3,6458	3,9651
18		0,6884	1,3304	1,7341	2,1009	2,5524	2,8784	3,6105	3,9216
19		0,6876	1,3277	1,7291	2,0930	2,5395	2,8609	3,5794	3,8834
20		0,6870	1,3253	1,7247	2,0860	2,5280	2,8453	3,5518	3,8495
21		0,6864	1,3232	1,7207	2,0796	2,5176	2,8314	3,5272	3,8193
22		0,6858	1,3212	1,7171	2,0739	2,5083	2,8188	3,5050	3,7921
23		0,6853	1,3195	1,7139	2,0687	2,4999	2,8073	3,4850	3,7676
24		0,6848	1,3178	1,7109	2,0639	2,4922	2,7969	3,4668	3,7454
25		0,6844	1,3163	1,7081	2,0595	2,4851	2,7874	3,4502	3,7251
26		0,6840	1,3150	1,7056	2,0555	2,4786	2,7787	3,4350	3,7066
27		0,6837	1,3137	1,7033	2,0518	2,4727	2,7707	3,4210	3,6896
28		0,6834	1,3125	1,7011	2,0484	2,4671	2,7633	3,4082	3,6739
29		0,6830	1,3114	1,6991	2,0452	2,4620	2,7564	3,3962	3,6594
30		0,6828	1,3104	1,6973	2,0423	2,4573	2,7500	3,3852	3,6460
50		0,6794	1,2987	1,6759	2,0086	2,4033	2,6778	3,2614	3,4960
100		0,6770	1,2901	1,6602	1,9840	2,3642	2,6259	3,1737	3,3905
1000		0,6747	1,2824	1,6464	1,9623	2,3301	2,5808	3,0984	3,3003

Inverse Chi-Quadrat-Verteilung

df	$\alpha =$	0,25	0,1	0,05	0,025	0,01	0,005	0,001	0,0005
1		1,3233	2,7055	3,8415	5,0239	6,6349	7,8794	10,8276	12,1157
2		2,7726	4,6052	5,9915	7,3778	9,2103	10,5966	13,8155	15,2018
3		4,1083	6,2514	7,8147	9,3484	11,3449	12,8382	16,2662	17,7300
4		5,3853	7,7794	9,4877	11,1433	13,2767	14,8603	18,4668	19,9974
5		6,6257	9,2364	11,0705	12,8325	15,0863	16,7496	20,5150	22,1053
6		7,8408	10,6446	12,5916	14,4494	16,8119	18,5476	22,4577	24,1028
7		9,0371	12,0170	14,0671	16,0128	18,4753	20,2777	24,3219	26,0178
8		10,2189	13,3616	15,5073	17,5345	20,0902	21,9550	26,1245	27,8680
9		11,3888	14,6837	16,9190	19,0228	21,6660	23,5894	27,8772	29,6658
10		12,5489	15,9872	18,3070	20,4832	23,2093	25,1882	29,5883	31,4198

Benford-Verteilung

d	1	2	3	4	5	6	7	8	9
$P(X = d)$	0,3010	0,1761	0,1249	0,0969	0,0792	0,0669	0,0580	0,0512	0,0458

Formeln

Deskriptive Statistik

Kennzahlen für Stichprobendaten:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^k f_i X_i$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2} = \sqrt{s^2}$$

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^k f_i (X_i - \bar{X})^2}$$

Perzentile:

$$i = \frac{n \cdot p}{100}$$

$$X = \begin{cases} \frac{X_i + X_{i+1}}{2} & \text{wenn } i \text{ eine ganze Zahl ist} \\ X_{\lceil i \rceil} & \text{sonst} \end{cases}$$

Ausreißer:

$$IQR = Q_3 - Q_1$$

$$X_i < Q_1 - 1,5 \cdot IQR, \quad X_i > Q_3 + 1,5 \cdot IQR$$

$$X_i < Q_1 - 3 \cdot IQR, \quad X_i > Q_3 + 3 \cdot IQR$$

Korrelation

Kovarianz:

$$Cov(X, Y) = \frac{1}{n-1} \sum (x_i - \bar{X}) \cdot (y_i - \bar{Y})$$

Korrelationskoeffizient:

$$r = \frac{Cov(X, Y)}{s_X s_Y} = \frac{\sum (x_i - \bar{X}) \cdot (y_i - \bar{Y})}{\sqrt{\sum (x_i - \bar{X})^2} \cdot \sqrt{\sum (y_i - \bar{Y})^2}}$$

Lineare Regression

Einfache lineare Regression:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

$$\hat{y} = b_0 + b_1 x$$

$$b_1 = \frac{\sum (x_i - \bar{X}) \cdot (y_i - \bar{Y})}{\sum (x_i - \bar{X})^2} = \frac{Cov(X, Y)}{s_X^2}$$

$$b_0 = \bar{Y} - b_1 \bar{X}$$

Multiple lineare Regression:

$$\hat{y} = b_0 + \sum b_j x_j$$

Analyse der Regressionsergebnisse:

$$e_i = y_i - \hat{y}_i$$

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{Y})^2}$$

Wahrscheinlichkeiten

Gegenereignis:

$$P(\bar{E}) = 1 - P(E)$$

Additions- und Multiplikationsregeln:

$$P(A \text{ oder } B) = P(A) + P(B) - P(A \text{ und } B)$$

$$P(A \text{ und } B) = P(A) \cdot P(B|A)$$

Totale Wahrscheinlichkeit:

$$P(B) = P(B|A_1)P(A_1) + \dots + P(B|A_n)P(A_n)$$

Satz von Bayes:

$$P(A|B) = \frac{P(A) \cdot P(B|A)}{P(B)}$$

Kombinatorik

Fundamentalprinzip der Kombinatorik:

$$k_1 \cdot k_2 \cdot \dots \cdot k_n$$

Permutationen und Kombinationen:

$$n! = n \cdot (n-1) \cdot (n-2) \cdot \dots \cdot 2 \cdot 1$$

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} = {}_n C_k$$

Diskrete Wahrscheinlichkeitsverteilungen

Erwartungswert und Varianz:

$$E(X) = \mu = \sum_i x_i \cdot P(X = x_i)$$

$$\sigma^2 = \sum_i (x_i - \mu)^2 \cdot P(X = x_i)$$

Binomialverteilung:

$$P(X = x) = \frac{n!}{x!(n-x)!} \cdot p^x \cdot q^{n-x}$$

$$\mu = n \cdot p$$

$$\sigma = \sqrt{n \cdot p \cdot q}$$

Gleichverteilung:

$$P(X = x) = \frac{1}{k}$$

Benford-Verteilung:

$$P(X = d) = \log_{10} \left(1 + \frac{1}{d} \right)$$

Normalverteilung

z-Wert und Wahrscheinlichkeit:

$$z = \frac{x - \mu}{\sigma}$$

$$x = \mu + z\sigma$$

$$P(X \leq x) = P(Z \leq z)$$

$$P(X \leq x) = P(X < x)$$

$$P(Z \leq -z) = 1 - P(Z \leq z)$$

z-Wert für Stichprobenmittelwerte:

$$z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

Konfidenzintervalle

Für Mittelwerte:

$$\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

$$\bar{X} - t_{\alpha/2} \frac{s}{\sqrt{n}} < \mu < \bar{X} + t_{\alpha/2} \frac{s}{\sqrt{n}} \quad df = n - 1$$

Für Anteile:

$$\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} < p < \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Stichprobengröße:

$$n = \left(z_{\alpha/2} \frac{\sigma}{E} \right)^2$$

$$n = \hat{p}(1-\hat{p}) \left(\frac{z_{\alpha/2}}{E} \right)^2$$

Hypothesentests

z-Test für einen Mittelwert:

$$z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

t-Test für einen Mittelwert:

$$t = \frac{\bar{X} - \mu}{s/\sqrt{n}} \quad df = n - 1$$

z-Test für einen Anteilswert:

$$z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}}$$

z-Test für zwei Mittelwerte:

$$z = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

Chi-Quadrat-Unabhängigkeitstest:

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

$$df = (\text{Zeilen} - 1) \cdot (\text{Spalten} - 1)$$

Chi-Quadrat-Anpassungstest:

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

$$df = k - 1 \quad (\text{für Gleich- und Benford-Vert.})$$

Regressionskoeffizienten:

$$df = n - k - 1 \quad (\text{für t-Test})$$